

智能无人系统

智能无人系统

无人驾驶平台和系统

自动驾驶的分级

美国汽车工程师学会 SAE 分级标准

美国国家公路交通安全管理局 NHTSA 分级标准

无人驾驶系统

算法端

传感

GPS/IMU

雷达 *LiDAR*

摄像头

雷达和声呐

感知

定位

物体识别与跟踪

决策

Client端

云端

传感器平台

激光雷达

检测原理

波段

优势

劣势

功能

分类

飞行时间测距法

毫米波雷达

检测原理

波段

主频段

优势

劣势

功能

摄像头

检测原理

优势

劣势

功能

类型

车内的安装位置及适用场景

GPS全球定位系统

检测原理

优势

劣势

功能

IMU惯性导航单元

检测原理

- 功能

- 两者相结合的优势

- 融合两者数据的方式

- 多传感器融合

- V2X通信传感系统

- 检测原理

- 劣势

- 三大优势

- 政策支撑

- 功能

- 计算平台

- 基于GPU的解决方案

- 优势

- 特点

- 基于DSP的解决方案

- 优势

- 特点

- 基于FPGA的解决方案

- 优势

- 特点

- 基于 ASIC 的解决方案

- 优势

- 特点

- 控制平台

- 通信网络协议

- 无人驾驶的安全性

- 常见攻击方式和解决方法

- 传感器的安全

- 攻击方式

- 多传感器融合防御策略

- 操作系统的安全

- 攻击方式

- 控制系统的安全

- CAN入侵方式

- 对ECU接收的信息进行加密验证

- 车联网通信系统的安全性

- 安全威胁方式

- PRESERVE三层防护

- 无人驾驶系统的定位方法

- 定位技术

- 基于激光雷达点云数据的定位

- 迭代最近点 *Iterative Closest Point, ICP*

- 特点

- 算法原理

- 基本思想

- 实现步骤

- 求解

- 正态分布变换 *Normal Distribution Transform, NDT*

- 算法原理

- 基本思想

- 实现步骤

- 基于GPS+ INS信息的定位

坐标系4'

坐标转换的方法：三次旋转

全球卫星导航系统 GNSS 系统 *Global Navigation Satellite System*

组成部分

差分GPS定位

RTK (Real – Time Kinematic, 实时动态)

分类

三角定位法

影响GPS定位准确度的因素4'

GPS定位误差

惯性测量单元 *Inertial Measurement Unit, IMU*

加速度计

比力方程

惯性导航系统 *Integrated Positioning System, INS*

INS工作原理

惯性导航原理：递推式行位推算

优点

缺点

基于SLAM技术的定位 *Simultaneous Localization and Mapping*

视觉SLAM定位系统完整架构

视觉里程计

点云预处理：去地面

特征点提取

特征点匹配

相对运动：迭代最近点(Iterative Closest Point, ICP)

光流法

回环检测

主流方法：基于外观的几何关系

核心问题：如何计算图像间的相似性

词袋模型 (Bag-of-Words, BoW)

基于高精度地图的定位技术

状态估计和传感器融合

卡尔曼滤波

基本思想

普通卡尔曼滤波的使用条件

五个基本步骤

扩展卡尔曼滤波 (EKF)

基本思想

五个基本步骤

无损卡尔曼滤波 (UKF)

深度学习

机器学习概述

机器学习的基本分类

经验风险最小化

损失函数

风险

经验风险 (Empirical Risk)

欠拟合和过拟合

梯度下降

学习率的大小设置对学习过程的影响

神经网络基础

感知机的定义和模型

激活函数 (Activation Function)

感知机与神经网络

前馈神经网络输出方式

One-hot编码

SoftMax分类

前向传播和反向传播

深度神经网络

正则化方法 (Regularization)

数据集增强

提前终止 Early Stopping

参数范数惩罚 / ℓ_1 和 ℓ_2 正则化

丢弃技术

卷积神经网络的优势

稀疏交互

权重共享

等变表示

卷积和池化

YOLOv3网络结构-降采样

残差网络的作用

多通道卷积

YOLO

无人驾驶视觉感知

基于激光雷达的路缘石检测

点云预处理

按类划分选定区域内的点

划分左右子集

左右子点集排序

滑窗算法

聚类拟合

基于摄像机的车道线检测

1.保留ROI、去畸变

2.形态学处理

中值滤波

颜色空间转换

车道线提取

3.车道线拟合

计算车道线下端起点

滑动窗口

拟合车道线

4.坐标系转换

像素坐标系转换至车体坐标系

迁移学习

迁移学习的必要性

常见的迁移学习方法分类

迁移学习应用场景

强化学习

端到端无人驾驶

基本思路与模型

马尔可夫性和马尔可夫过程

非确定性策略和确定性策略

及时奖励和累计期望奖励

状态-值函数和状态-行为值函数之间的关系 $V_{\pi}(\mathbf{s}) = \sum_{\mathbf{a} \in A} \pi(\mathbf{a}|\mathbf{s})q_{\pi}(\mathbf{s}, \mathbf{a})$

贝尔曼方程

Q值函数

策略梯度

深度确定性策略梯度算法 DDPG

无人驾驶的规划

无人车路径规划和A*算法

深度优先搜索

广度优先搜索

Dijkstra算法

A*算法

混合A*算法

比较A*和混合A*算法

节点字段定义

节点扩展方式

碰撞检测方式

距离定义

无人车路径规划-局部路径规划-TEB算法

局部优化

约束目标函数

优化算法

无人车行为规划

有限状态机

算法基本原理

分类

存在问题

分层有限状态机

算法基本原理

优点

无人车路径生成-三次样条插值算法

三次曲线(单一的三次多项式 $y = ax^3 + bx^2 + cx + d$ 来拟合所有给定的数据点)和三次样条插值生成路径的区别

性质

基于Frenet优化轨迹的无人车动作规划方法

动作规划

最优的动作序列

Frenet坐标系

横向、纵向轨迹优化

横向轨迹

纵向轨迹

碰撞避免

车辆模型和高级控制

自行车模型

自行车模型的假设

不同的参考点

运动学自行车模型

四个状态变量描述车辆状态 (位置、偏航角、速度)

两个控制输入 (a, δ_f)

根据运动学定理, 定义了运动学自行车模型中各个状态量的更新公式

动力学自行车模型

PID控制

比例、积分、微分项各项的作用

比例P

积分I

微分D

临界比例法进行PID控制器参数的整定步骤

PID调试一般原则

PID调试一般步骤

模型预测控制

模型预测控制三个因素

相较于PID控制，它解决了哪方面的问题

轨迹追踪

基本原理和分析过程

转角控制表达式

P控制器 $\kappa = \frac{2}{l_d^2} e_l$

前视距离对追踪效果的影响

无人驾驶平台和系统

自动驾驶的分级

美国汽车工程师学会 SAE 分级标准

1. **Level 0**：无自动化
2. **Level 1**：单一功能级自动化。无法做到手和脚同时不操控。
3. **Level 2**：部分自动化。在某些预设环境下可以不操作汽车，即手脚同时离开控制。
4. **Level 3**：有条件自动化。特定条件部分任务。人类提供适当的应答。
5. **Level 4**：高度自动化。特定条件全部任务。限定道路和环境条件。
6. **Level 5**：完全自动化。全部条件全部任务。


美国国家公路交通安全管理局 NHTSA 分级标准

NHTSA 的定义在自动驾驶 0-3 级与 SAE 一致，分别强调的是无自动化、驾驶支持、部分自动化与条件下的自动化。SAE对完全自动化进行了进一步细分，强调了行车对环境与道路的要求。

美国国家公路交通安全管理局(NHTSA)，美国汽车工程师学会(SAE)自动驾驶分级标准							
分级	NHTSA	L0	L1	L2	L3	L4	
	SAE	L0	L1	L2	L3	L4	L5
称呼(SAE)		无自动化	驾驶支持	部分自动化	有条件自动化	高度自动化	完全自动化
SAE定义		由人类驾驶者全权驾驶汽车，在行驶过程中可以得到警告	通过驾驶环境对方向盘和加速减速中的一项操作提供支援，其余由人类操作	通过驾驶环境对方向盘和加速减速中两项以上操作提供支援，其余由人类操作	由无人驾驶系统完成所有的驾驶操作，根据系统要求，人类提供适当的应答	由无人驾驶系统完成所有的驾驶操作，根据系统要求，人类不一定提供所有的应答。限定道路和环境条件	由无人驾驶系统完成所有的驾驶操作，可能的情况下，人类接管，不限定道路和环境条件
主体	驾驶操作	人类驾驶者	人类驾驶者/系统	系统			
	周边监控	人类驾驶者			系统		
	支援	人类驾驶者				系统	
	系统作用域	无					全域

NHTSA	L0	L1	L2	L3	L4	
SAE	L0	L1	L2	L3	L4	L5
	无自动化	驾驶支持	部分自动化	有条件自动化	高度自动化	完全自动化
功能	夜视 行人检测 交通标志识别 盲点检测 并线辅助 后排路口交通警报 车道偏离警告	自适应巡航驾驶系统 自动紧急制动 停车辅助系统 前向碰撞预警系统 车身电子稳定系统	车道保持辅助系统	拥挤辅助驾驶	停车场自动泊车	
特征	传感探测和决策警报	单一功能（以上之一）	组合功能（L1/L2组合）	特定条件部分任务	特定条件全部任务	全部条件全部任务
	ADSA			自动驾驶		

无人驾驶系统



算法端

传感

GPS/IMU

通过全球定位和惯性传感单元更新数据，以帮助无人车完成**准确且实时**的自我定位。

- *GPS* 相对准确，但更新频率过低，仅有 $10Hz$ 。
- *IMU* 的准确度随着时间降低，在长时间距离内不能保证位置更新准确性；但有**实时性**，更新频率可达 $200Hz$ 或者更高。

雷达 *LiDAR*

激光雷达可被用来绘制地图、定位及避障。

准确率高，常为主传感器。每秒钟能够向外界发送数百万个激光脉冲，内部**机械式旋转结构**，以 $10Hz$ 左右的频率对周围环境进行旋转扫描，每一次扫描的结果为密集点构成的三维图，能实时建立起周围环境的三维地图。

- 点云数据：空间坐标 (x, y, z) 信息
- 点云图 *Point Cloud Graph*：点云数据构建的图

摄像头

物体识别、物体追踪等，用于车道线检测、交通灯侦测、人行道检测。为了加强安全性，现有的无人车实现通常在车身周围使用至少8个 $60Hz$ 摄像头，分别从前、后、左、右四个维度完成**物体发现、识别、追踪**等任务。同时工作时，将产生高达 $1.8GB$ 每秒的巨额数据量。

雷达和声呐

避障的最后一道保障，其数据不需要过多处理，可实现**转向、刹车或预警式安全带**等紧急功能。

雷达把电磁波的能量发射至空间中某一方向，处在此方向上的物体反射该电磁波，雷达通过接收此反射波，以提取该物体的某些有关信息，包括目标物体至雷达的**距离、距离变化率或径向速度、方位、高度**等。

感知

定位

1. 基于*GPS/IMU*的定位：使用卡尔曼滤波整合
2. 基于立体视觉测距定位：激光雷达粒子滤波 (*Particle Filter*)
3. 多传感器融合定位

物体识别与跟踪

卷积神经网络(*CNN*)是一类在物体识别中被广泛应用的深度神经网络。

①卷积层；②激活层；③汇聚层；④一旦某物体被 *CNN* 识别出来，下一步将自动预测它的运行轨迹或进行物体追踪。

决策

以便可靠、安全地抵达目的地，行为预测、路径规划、避障

Client端

包括机器人操作系统及硬件平台

云端

包括数据存储、模拟、高精度地图绘制及深度学习模型训练

传感器平台

主流的无人驾驶传感平台以**激光雷达**和**车载摄像头**为主，并呈现**多传感器融合**发展的趋势。

了解各类传感器--激光雷达、毫米波雷达、摄像头、GPS/IMU、V2X通信传感系统的**检测原理、优势、劣势以及功能**。

传感器	成本	优势	劣势	功能
激光雷达	8000美元以上	扫描周围环境得到精确环境信息	成本高,大雾、雨雪天气效果差,无法图像识别	周边环境3D建模
毫米波雷达	300~500美元	不受天气影响,测量精度高,距离范围广	无法识别道路指示牌,无法识别行人	无法应用视觉识别要求较高功能
摄像头	35~50美元	成本比较低,通过算法可以实现各种功能	极端恶劣环境下会失效,难以测距,距离较近,算法要求高	能实现大多数ADAS功能,测距功能难以实现
V2X	150~200美元	不受距离现实,V2X成本较低,深度融合智能系统	精度较低,技术协议仍在讨论中,普及难度大	利用通信协议,感知实时路况,道路信息和行人信息
红外传感器	600~2000美元	夜视效果极佳	成本较高,技术仍由国外垄断	夜视
超声波传感器	15~20美元	成本低	探测距离较近,应用局限大	侧方超车提醒、倒车提醒

GPS+惯导：开阔环境首选，绝对定位能力强，GPS怕遮挡

激光SLAM：几何特征丰富环境首选，精确但成本高、怕恶劣天气

视觉SLAM: 纹理特征丰富环境可用, 成本低但怕弱纹理、光照变化

纯惯导(IMU)：短期备用方案，任何环境都能工作但误差累积

传感方案的选择:

环境场景	主传感器	辅助传感器	为什么这样配
无GPS+有结构	激光雷达	IMU	激光提供绝对位置，IMU填补扫描间隔
有GPS+开阔地	GPS	IMU	GPS提供全局定位，IMU提高更新频率
有GPS+有纹理	视觉+GPS	IMU	视觉提供局部精度，GPS防止漂移
恶劣天气	GPS+IMU	-	激光/视觉受影响，回归最可靠组合

激光雷达

检测原理

利用可见和近红外光波（多为 950nm 波段附近的红外光）发射、反射和接收来探测物体。

波段

可见和近红外光波（多为 950nm 波段附近的红外光）

优势

- 1. 角分辨率、距离分辨率高
- 2. 探测精度高、范围广

劣势

无法探测被遮挡的物体、光束无法达到的物体，在雨雪雾天气下性能较差。

功能

可以探测白天或黑夜下的特定物体与车之间的距离。由于反射度的不同，也可以区分车道线和路面。






- 1. 3D建模进行环境感知
- 2. SLAM 加强定位

分类

机械式激光雷达：通过旋转部件360度水平扫描和定向垂直扫描，发射器和接收器随扫描部件旋转。

半固态激光雷达：发射器和接收器固定，通过少量运动部件（转镜、MEMS、棱镜）实现扫描。

固态激光雷达：无运动部件，利用半导体技术进行光束发射、扫描和接受，分为Flash和OPA两种类型。

类型	机械式	半固态			全固态	
		转镜	MEMS	棱镜	Flash	OPA
原理						
优点	1.可以做到360°扫描，测量距离远； 2.技术成熟度高。	1.技术成熟度高，体积适中。 2.技术成熟度高。	1.激光器和探测器数量较少，成本较低，尺寸较小； 2.MEMS 微振镜商用化应用多年，供应链较为成熟。	1.激光器和接收器数量少，成本较低；	1.没有运动部件，容易满足车规； 2.降本潜力大；	1.结构简单，体积更小； 2.FOV可以通过算法灵活调整； 3.可以动态控制扫描频率、分辨率和焦距调整，同时多线多维扫描能获得更高的数据采集。
缺点	1.扫描速度慢，体积大； 2.精密制造要求高，成本高； 3.可靠性低，难以满足车规。	1.存在有运动部件，可靠性有一定设计挑战	1.MEMS对于振动和温度较为敏感，车规级较难； 2.MEMS镜面尺寸和偏转角度难以做大，影响应用； 3.MEMS代工资源较少。	1.帧率不足，外圈扫描点数不足； 2.成像范围离散，无法连续成像，在高速场景应用时受限。	1.难以兼顾探测距离和FOV； 2.角分辨率受限于探测器集成度，性能不足	1.器件工艺成熟度不足； 2.目前器件光路损耗大，性能差； 3.当前没有车规级器件。

飞行时间测距法

距离 $r=0.5 \times \text{光速}c \times \text{往返飞行时间}t$

毫米波雷达

检测原理

通过发射 无线电信号（毫米波波段的电磁波） 并接收反射信号来测定汽车车身周围的物理环境信息（如汽车与其他物体之间的相对距离、相对速度、角度、运动方向等）， 然后根据所探知的物体信息进行目标追踪和识别分类，进而结合车身动态信息 进行数据融合，完成合理决策，减少事故发生几率。

波段

工作频段为 30~300GHz 毫米波，毫米波的波长为波长为 1~10mm， 介于厘米波和光波之间。

主频段

- 中短距测量：24GHz
- 中长距测量：77GHz

优势

- 1. 由于波段，可以微波制导和光电制导。
- 2. 雷达可以检测30-100米远的物体。
- 3. 毫米波雷达不受天气状况限制，穿透雾、烟、灰尘的能力强。具有全天候、全天时的工作特性，且探测距离远，探测精度高， 被广泛应用于车载距离探测。

劣势

- 1. 相比激光雷达，毫米波雷达精度低、可视范围的角度也偏小。
- 2. 传输的是电磁波信号，因此它无法检测上过漆的木头或是塑料。
- 3. 行人的反射波弱，对雷达免疫。
- 4. 对金属表面非常敏感。
- 5. 在大桥和隧道里的效果不佳。

功能

77GHz毫米波分辨准确度、测速和测距精确度高，能检测行人和自行车，设备体积更小，更便于在车辆上安装和部署。

长距离雷达的侦测范围更广，可适配开行速度更快的车辆，但是相应地探测精度下降，更适用于 ACC 自适应巡航。

短距离雷达适用于车辆环境监测。

摄像头

检测原理

- 1. 采集图像进行处理，将图片转换为二维数据
- 2. 进行模式识别，通过图像匹配进行识别
- 3. 依据物体的运动模式或使用双目定位，以估算目标物体与本车的相对距离和相对速度

优势

- 1. 最接近人眼获取周围环境信息的工作模式，通过较小的数据量获得最为全面的信息
- 2. 摄像头技术成熟，成本较低

劣势

- 1. 基于视觉的解决方案受光线、天气影响大
- 2. 物体识别基于机器学习资料库，需要的训练样本大，训练周期长，也难以识别非标准障碍物
- 3. 广角摄像头边缘畸变，得到的距离准确度较低

功能

快速，在高速行驶场合，系统必须能记录关键驾驶状况、并评估，实时启动相应措施。

为避免两次图像信息获取间隔期间自动驾驶的距离过长，要求相机具有**最慢不低于30帧/秒的影像捕捉速率**。

在复杂的运动路况环境下都都能保证采集到稳定的数据：

高动态	在较暗环境以及明暗差异较大下仍能实现识别
中低像素	降低计算处理负担，目前30-120万像素已经满足要求
角度要求	环视和后视一般采用135度以上的广角镜头，前置摄像头对视距要求更大，一般采用55度的范围

在安全级别上要求更高，尤其是对与前置ADAS的镜头安全等级要求更高。主要体现在：

温度要求	车载摄像头温度范围在-40~80℃
防磁抗振	汽车启动时会产生极高的电磁脉，车载摄像头必须具备极高的防磁抗震的可靠性
较长的寿命	车载摄像头的寿命至少要在8-10年以上才能满足要求

类型

(1) **单目摄像头**：一般安装在前挡风玻璃上部，用于探测车辆前方环境，识别道路、车辆、行人等。单目视觉方案的技术难点在于模型机器学习的智能程度或者模式识别的精度。(2D)

(2) **后视摄像头**：一般安装在车尾，用于探测车辆后方环境，技术难点在于如何适应不同的恶劣环境。

(3) **立体(双目)摄像头**：依靠两个平行布置的摄像头产生的“视差”，找到同一个物体所有的点，依赖三角测距，算出摄像头与前方障碍物距离。使用这种方案，需要两个摄像头有**较高的同步率和采样率**，因此技术难点在于**双目标定及双目定位**。

相比单目，双目的解决方案没有识别率的限制，无需先识别可直接进行测量；直接利用视差计算距离精度更高；无需维护样本数据库。但因为检测原理上的差异，双目视觉方案在距离测算上相比单目以及毫米波雷达、激光雷达，其硬件成本和计算量级的加倍。

车内的安装位置及适用场景

- **前视摄像头**：采用55度左右的镜头来得到较远的有效距离(单目和双目)，自动紧急刹车、自适应巡航等主动控制功能的信号入口，安全等级高。
- **环视**：广角摄像头，通常在车四周装备四个进行图像拼接实现全景图，通过辅助算法可实现道路线感知。
- **后视**：广角或者鱼镜头，主要为**倒车后视**使用。
- **侧视**：两个广角摄像头，完成**盲点检测**等工作，也可代替后视镜。
- **内置**：广角镜头，安装在车内后视镜处，完成在行驶过程中对驾驶员的**闭眼提醒**。

GPS全球定位系统

检测原理

GPS系统由空间段(卫星)、控制段(地面站)和用户段(接收机)组成。

1. **信号接收与测量**：GPS接收机接收来自至少4颗GPS卫星(为解算三维位置和时间需要至少4颗)发射的无线电信号。这些信号包含卫星的精确时间戳、轨道参数(星历数据)和健康状态等信息。
2. **伪距计算**：接收机通过比较接收信号的时间和信号内嵌的发射时间，计算出信号从卫星传输到接收机所需的时间。将这个时间乘以光速，得到接收机到每颗卫星的**伪距**。这个“伪”是因为信号在传播过程中会受到大气层延迟等因素影响，引入误差。
3. **三角定位法**：接收机利用已知的多颗卫星的精确空间位置(通过星历数据获取)和计算出的伪距，通过三角定位法，解算出自身在地球上的三维绝对位置(经度、纬度、高度)以及精确的时间。

优势

1. **全球覆盖，全天候工作**：无论地球任何角落，任何天气条件下都能提供定位服务(只要能接收到卫星信号)。
2. **提供绝对位置信息**：直接给出车辆在地球坐标系下的经度、纬度、高度，具有全局一致性。
3. **无累积误差**：每次定位都是独立的，定位误差不会随时间累积，即使有漂移也是瞬时误差。
4. **提供高精度时间**：GPS卫星携带原子钟，能提供非常精确的时间同步服务，对车辆系统内部各模块同步至关重要。
5. **提供速度信息**：通过卫星信号的多普勒频移效应，可以精确计算车辆的速度。

劣势

1. **易受遮挡影响：** 信号需要直射路径，在高楼林立的城市峡谷、隧道、地下停车场、茂密的森林中，信号容易被遮挡或减弱，导致定位精度下降甚至信号丢失。
2. **多路径效应：** 信号经过高楼、地面等反射后到达接收机，导致测量距离不准确，严重影响定位精度。
3. **易受干扰和欺骗：** GPS信号功率弱，容易受到无线电干扰（Jamming）或欺骗（Spoofing）攻击。
4. **更新频率相对较低：** 通常为1-10Hz，对于需要高动态响应的自动驾驶车辆来说，更新频率不够。
5. **垂直精度低于水平精度：** 由于卫星分布和几何结构原因，高度方向的定位精度通常低于水平方向。
6. **冷启动时间较长：** 首次定位或长期关机后启动时，需要较长时间（几秒到几分钟）才能获取卫星星历并完成定位。

功能

1. **全局定位与导航：** 提供车辆在地图上的绝对位置，实现路径规划、导航指引。
2. **速度测量：** 精确测量车辆的行驶速度，作为车辆控制和安全系统的重要输入。
3. **时间同步：** 为车辆内部的多个传感器（如摄像头、雷达、激光雷达）和控制单元提供统一的高精度时间戳，确保数据融合的准确性。
4. **辅助传感器融合：** 作为其他传感器（如IMU、视觉里程计）的绝对位置基准，纠正其累积误差。

IMU惯性导航单元

检测原理

IMU是一种测量物体三轴姿态角（俯仰、滚转、偏航）以及加速度的传感器，通常由以下核心部件组成：

1. **加速度计 (Accelerometers)：** 测量物体在三维空间（X, Y, Z轴）沿三个正交轴的**线性加速度**。它能够检测重力加速度和非重力加速度。
2. **陀螺仪 (Gyroscopes)：** 测量物体在三维空间中绕三个正交轴的**角速度（旋转速率）**。
3. **工作方式：** IMU通过实时测量这些加速度和角速度数据。
 - 对角速度进行一次积分，可以得到物体在短时间内的**姿态变化（角度）**。
 - 对线性加速度进行一次积分，可以得到物体的**速度变化**。
 - 对线性加速度进行二次积分，可以得到物体的**相对位移**。

功能

1. **姿态估计与控制：** 实时提供车辆的精确姿态（俯仰、滚转、航向），是车辆稳定控制系统（如ESP、ABS）和动力学控制的基础。
2. **短时航位推算 (Dead Reckoning)：** 在GPS信号丢失（如进入隧道）时，IMU可以作为唯一的独立传感器，提供短期的相对位置和速度估计，维持车辆的连续定位。
3. **车辆动力学监测：** 监测车辆的加速、减速、转弯时的G值，对驾驶行为分析、碰撞检测和安全系统有重要意义。
4. **抖动与振动补偿：** 用于稳定自动驾驶车辆上其他传感器（如摄像头、激光雷达）的平台，补偿车辆行驶过程中的振动和颠簸，提高数据质量。
5. **高精度地图匹配辅助：** 辅助车辆在高精地图中进行位姿估计和匹配，尤其是在GPS信号不佳时。

两者相结合的优势

GPS 的**路径反射**：导致获得的 GPS 定位信息很容易产生几米的误差。

GPS 的**更新频率低**：车辆快速行驶时很难给出精准的实时定位。

IMU 是检测加速度与旋转运动的高频传感器，但也有**偏差积累与噪音**等问题影响结果。

GPS通常辅助以惯性传感器（IMU）用来增强定位的精度。

1. 系统精度的提高
2. 系统抗干扰能力的增强
3. 导航信息的补全

融合两者数据的方式

使用基于卡尔曼滤波的传感器融合技术，融合 GPS 与 IMU 数据

- 导航设备之间优势互补，增强系统适应动态的能力，使整个系统获得优于局部系统的精度
- 提高了空间和时间的覆盖范围，实现真正意义上的连续导航

多传感器融合

- 场景：无GPS环境，使用激光雷达和IMU进行定位，融合中采用卡尔曼滤波

1. IMU作为预测模型

系统模型（ F_k ）：基于IMU测量的加速度和角速度

通过运动学方程预测车辆下一时刻状态

关键：IMU的高频（100-200Hz）提供连续的预测

2. 激光雷达作为观测更新

观测模型（ H_k ）：激光雷达提供位置观测

通过点云匹配（如ICP、NDT）获得车辆位姿

关键：激光雷达的低频（5-10Hz）提供高精度绝对位置

3. 融合更新

卡尔曼滤波利用激光雷达提供的观测值来修正IMU累积的预测误差。通过卡尔曼增益计算，系统将IMU的预测与激光雷达的观测进行融合，得到一个更准确的状态估计。

- 多传感器融合，系统更相信哪个传感器提供的数据？

权重调整：在卡尔曼滤波等融合框架中，**噪声协方差**是调参关键。

为每个传感器的预测或观测数据分配一个噪声协方差矩阵。当某个传感器的健康指标显示其数据质量高时，系统将其噪声协方差调小，增大其在状态估计中的权重；反之则调大噪声协方差，降低其影响力。

V2X通信传感系统

检测原理

V2X是车联网通信机制的总称（V2V车车通信、V2I车路通信、V2P车人通信），V2X通信系统可以看作是一个超级传感器，它提供了比其他车载传感器都高得多的感知能力和可靠性。

劣势

- 高昂的部署成本与渗透率挑战：** V2X需要大规模的基础设施（如路侧单元RSU）建设投资，以及所有车辆都安装V2X通信模块。在系统初期，只有少量车辆和基础设施支持V2X时，其价值难以充分体现（即“鸡生蛋，蛋生鸡”的渗透率问题），这反过来又阻碍了大规模推广和投资。
- 技术标准不统一及互操作性难题：** 全球范围内，V2X技术标准（如DSRC与C-V2X）存在竞争，不同地区、不同厂商之间的设备和协议可能无法完全兼容。这种标准碎片化导致互操作性差，限制了V2X的全球性和通用性应用。
- 通信安全、数据隐私及信息信任风险：** V2X系统涉及大量车辆和道路环境的实时数据交换，容易受到黑客攻击、数据窃取、伪造信息或恶意干扰。如何确保通信的加密、认证，保护用户隐私，并建立一个可靠的信息信任机制（识别和过滤虚假信息），是其面临的重大挑战。

三大优势

- 覆盖面更广：** 300~500米的通信范围，不仅是前方障碍物，身旁和身后的建筑物、车辆都会互相连接，大大拓展了驾驶员的视野范围。
- 有效避免盲区：** 由于所有物体都接入互联网，每个物体都会有单独的信号显示，因此即便是视野受阻，通过实时发送的信号可以显示视野范围内看不到的物体状态。
- 对于隐私信息的安全保护性更好：** 系统将采用5.9GHz频段进行专项通信，相比传统通信技术更能确保安全性和私密性。

政策支撑

2019年，发改委发布了《智能网联汽车创新发展战略（征求意见稿）》，指出2020年中国的大城市高速路要达到90% 覆盖C-V2X，2025年实现人、车、路、云的高度协调。5G-V2X要满足ICV要求。

工信部国标委也发表了《国家车联网产业标准体系建设指南》，明确要求LTE-V2X作为广域和中短程智能网联汽车关键技术。

工信部也发布了《车联网(智能网联汽车)产业发展行动计划》，明确了到2020年实现LTE-V2X在部分城市主要道路和高速公路覆盖，开展5G-V2X示范应用，车联网用户渗透率达到 30% 以上。

从“对人友好”到“对车友好”，供应用于无人驾驶的实时高精地图。

功能

V2X是无人驾驶必要技术和智慧交通的重要一环。通过V2X可以获得实时路况、道路信息、行人信息等一系列交通信息，从而带来远距离环境信号。

计算平台

基于GPU的解决方案

优势

- 大规模并行计算能力：** 拥有数千个处理核心，擅长处理数据并行任务，如矩阵乘法、卷积神经网络运算，非常适合深度学习模型的推理和训练。

2. **高吞吐量：** 在短时间内能处理大量数据，对自动驾驶中处理摄像头图像、激光雷达点云等海量感知数据非常高效。
3. **成熟的生态系统：** 拥有如NVIDIA CUDA、OpenCL等强大的编程模型，以及TensorFlow、PyTorch等丰富的深度学习框架支持，开发相对便捷。
4. **灵活性：** 编程相对灵活，可以通过软件更新支持不同的算法和模型迭代。

特点

1. **高功耗与散热：** 通常功耗较大，发热量高，需要复杂的散热系统，这在车载环境中是一个挑战。
2. **擅长浮点运算：** 对浮点数运算支持良好，适合高精度的科学计算和深度学习。
3. **通用性强：** 适合GPGPU（通用计算）任务，不仅仅局限于图形处理。
4. **架构复杂：** 内部调度机制和内存访问模式相对复杂，有时会导致不可预测的延迟（相对于DSP/FPGA的确定性）。
5. **成本：** 高性能GPU芯片价格相对较高。

基于DSP的解决方案

优势

1. **实时性强，确定性高：** DSP采用的是哈佛设计，允许取出指令和执行指令完全重叠，并进行译码，这大大提高了微处理器的速度。增加了器件的灵活性，允许在程序空间和数据空间之间进行传输。它不仅具有可编程性，而且其实时运行速度可达每秒数以千万条复杂指令程序，远远超过通用微处理器。
2. 运算能力很强，速度很快，体积很小。
3. 采用软件编程具有高度的灵活性。

特点

1. **并行度有限：** 相对于GPU，DSP的并行处理能力有限，不适合大规模的通用并行计算。
2. **编程更底层：** 通常需要更底层的编程（C/C++或汇编），开发难度相对较大，通用性不如CPU/GPU。
3. **架构专用：** 专为信号处理优化，不适用于复杂的操作系统和通用计算任务。
4. **适用于传感器预处理：** 常用于雷达、激光雷达、超声波等原始数据的滤波、降噪和特征提取。

基于FPGA的解决方案

优势

1. **硬件级并行与低延迟：** 硬件配置灵活，每个任务都可以有独立的硬件线路并行执行，因此延迟极低且具有高度确定性。
2. **可重构性：** 硬件逻辑可以在部署后根据需求进行更改或升级，具有高度的灵活性和未来兼容性。
3. **低能耗：** 在能源受限的情况下，FPGA相对于CPU 与GPU有明显的性能与能耗优势。
4. **定制化：** 可以根据特定算法和数据流定制最优的硬件加速器，例如自定义数据路径和处理单元。

特点

低能耗、高性能、可编程，适合感知计算。

感知算法不断发展意味着感知处理器需要不断更新，FPGA具有硬件**可升级、可迭代**的优势。

随着FPGA与传感器结合方案的快速普及，视觉、语音、深度学习的算法在FPGA上进一步优化，FPGA极有可能逐渐取代GPU 与CPU成为无人车、机器人等感知领域上的主要芯片。

基于 ASIC 的解决方案

优势

- 1. **极致性能与功耗效率：** 针对特定算法和任务进行深度优化，能提供最高的性能和最低的功耗，是性能功耗比最佳的解决方案。
- 2. **最小尺寸与最高集成度：** 可以在最小的物理空间内集成最复杂的功能，满足车载对尺寸和重量的严格要求。
- 3. **量产成本最低：** 在大规模量产的情况下，单片ASIC的制造成本远低于GPU、FPGA。

特点

- 1. **开发周期长，NRE成本极高：** 设计和流片（fabrication）过程复杂，开发周期长，一次性工程费用（Non-Recurring Engineering, NRE）极高，通常需要数千万甚至上亿美元。
- 2. **功能固化，不可更改：** 一旦ASIC设计完成并制造出来，其硬件功能就完全固化，无法像FPGA那样重新编程，也无法像GPU那样通过软件更新实现大的功能变更。
- 3. **风险高：** 如果设计有缺陷或市场需求发生变化，高昂的NRE成本将面临巨大损失。
- 4. **适用于稳定、大批量应用：** 只有在算法和市场需求非常稳定，且出货量极大的情况下，ASIC才能展现其成本和性能优势，如特斯拉FSD芯片、谷歌TPU等。

控制平台

控制平台主要包括了**电子控制单元 ECU** 与**通信总线**两大部分：

- ECU主要实现控制算法
- 通信总线主要实现ECU以及机械部件间的通信功能

通信网络协议

几种典型通信总线的数据传输方式、工作机制和适用场景：

- 局部互联协议 LIN
 - 低速网络
 - 适用于车内分布式电控系统
 - 模式：单个主控制器多个从设备
 - 主机节点的主机任务发起通讯，确定当前通讯内容，发送帧头并为报文帧分配帧通道。总线上的从机节点接收帧头之后，判断是否做出响应、做出何种响应。
- 控制器局域网 CAN
 - 中速网络

- 线型结构、所有节点并联在总线上
- **仲裁机制**：各节点持续监听总线，一旦发现空闲便开始发送数据。若多个节点同时发送，则通过基于ID的仲裁机制竞争：各节点首先发送数据ID，**ID值越小优先级越高，高优先级ID会自动覆盖低优先级ID**。当节点发现自己的ID被覆盖时，会立即停止发送。最终，优先级最高的消息获得总线使用权，完成数据发送。数据发送完毕后，各节点将重新开始竞争总线。
- 能最大程度利用总线
- 高速容错网络协议 FlexRay
 - 高速、安全、可靠
 - 时间触发和事件触发
 - 不仅限于多媒体传输

无人驾驶的安全性

常见攻击方式和解决方法

传感器的安全

攻击方式

1. 针对**传感器**的攻击不需要进入无人驾驶系统内部，外部攻击法技术门槛相当低，简单直接。
2. 进入**无人驾驶操作系统**，黑客可以造成系统崩溃导致停车，也可以窃取车辆敏感信息。
3. 进入**无人驾驶控制系统**，黑客可以直接操控机械部件，劫持无人车去伤人。
4. 车联网连接不同的无人车，以及中央云平台系统，劫持**车联网通信系统**可以造成无人车间的沟通混乱。

多传感器融合防御策略

攻击单个传感器很容易，但是如果同时攻击所有传感器难度相当大。当无人车发现不同传感器的数据相互间不一致，就知道自己可能正在被攻击。

例如，无人车检测到交通灯，但是高精地图在此处并未标注有交通灯，那么就很可能是被攻击了。又例如 GPS 系统与激光雷达系统定位的位置极不一致，无人车也很可能是被攻击了。

操作系统的安全

攻击方式

1. 一个 **ROS 节点被劫持**，然后不断地进行分配内存，导致其系统内存消耗殆尽，造成系统 OOM 而开始关闭不同的 ROS 节点进程，造成整个无人驾驶系统崩溃。
 - **原因**
 1. ROS 节点本身是一个进程，可以无节制分配资源导致崩溃
 2. ROS 节点可以访问磁盘以及网络资源，并无很好的隔离机制
 - **解决方案**
 1. **容器技术**管理每一个 ROS 节点进程，限制每一个节点可供使用的资源数

2. **沙盒方式**确保节点的运行独立，最大限度地防止资源泄露

2. **ROS的话题或服务被劫持**，导致 ROS 节点之间传递的信息被伪造，从而导致无人驾驶系统的异常行为。

- **原因**：通信的信息没有被加密，以至于攻击者可以轻易得知通信内容。
- **解决方案**：目前业界有不少对 ROS 节点间通信的加密尝试，比如使用 DES 加密算法。
- **缺点**：在通信的信息量十分小的时候，加密与否对性能影响不大。但随着信息量变大，加密时间相对信息量成几何级增长。另外，由于 ROS 通信系统的设计缺陷，加密时间也与接收信息的节点数量有直接关系。当接受信息的节点数量增长时，加密时间也随之增长。

控制系统的安全

CAN入侵方式

1. **OBD-II入侵**：OBD-II 端口主要用于检测车辆状态，通常在车辆进行检修时，技术人员会使用每个车厂开发的检测软件接入 OBD-II 端口并对汽车进行检测。由于 OBD-II 连接到 CAN 总线，只要黑客取得检测软件，便能轻易截取车辆信息。
2. **电动车充电器入侵**：电动车的充电装置在充电时会与外部充电桩通信，而且电动车的充电装置会连接 CAN 总线，这就给了黑客们通过外部充电桩入侵 CAN 系统的机会。
3. **车载 CD机入侵**：攻击代码编码到音乐 CD 中，当用户播放 CD 时，恶意攻击代码便会通过 CD 播放机侵入 CAN 总线，从而可以取得总线控制以及盗取车辆核心信息。
4. **蓝牙入侵**：用户可以通过蓝牙给 CAN 发送信息以及从 CAN 读取信息，这也给黑客们攻击的窗口。除了取得车主手机的控制权，黑客们也可以使用蓝牙进行远程攻击。
5. **TPMS 入侵**：TPMS 是车轮压力管理系统。黑客先把攻击代码放置在车辆 TPMS ECU中，当 TPMS 检测到某个胎压值的时候，恶意代码便会被激活，从而对车辆进行攻击。

对ECU接收的信息进行加密验证

对 ECU 接收的信息进行**加密验证**，以保证信息是由可信的 ECU，而不是由黑客发出。

使用加密验证可以选择**对称**或者**非对称密码**。对称密码的计算量小但是需要通信双方预先知道密码。非对称密码无需预先知道密码，但是计算量大。

车联网通信系统的安全性

安全威胁方式

1. **篡改数据 (Data Tampering)**：修改传输中的合法信息。
2. **伪造/欺骗 (Spoofing)**：冒充合法实体发送虚假信息。
3. **拒绝服务 (DoS)**：阻塞通信或使系统过载。
4. **窃听/泄密 (Eavesdropping)**：未经授权监听获取隐私。

PRESERVE三层防护

1. **硬件**：在每个车辆中存储了大量密钥，如果使用普通的 Flash 与 RAM，密钥会被轻易盗取。另外，使用加密解密技术会对计算资源消耗极大。为了解决这些问题，PRESEVER 提出了设计**安全存储硬件**，以及使用**ASIC 硬件加速加解密**。

2. 软件：在安全硬件上，PRESEVER 提供了一整套开源软件栈提供安全通信。这套软件栈提供了加密解密软件库、电子证书认证库、与受信任的证书颁发机构的安全通信库等。
3. 安全证书：为了确保信息来源于可信设备，可以使用受信任的证书颁发机构来提供安全证书与密钥。

无人驾驶系统的定位方法

定位技术

基于激光雷达点云数据的定位

优点：测距精准、测距远、分辨率高、隐蔽性好、抗有源干扰能力强

缺点：成本太高，暴雨、大雪、大雾等天气下易受影响

点云：3D 激光雷达采集到的一系列分散的、具有准确角度和距离信息的点

激光 SLAM 系统：通过对不同时刻两片点云的匹配与比对来计算激光雷达相对运动的距离和姿态的改变，从而完成对机器人自身的定位。将 Lidar 当前扫描出的点云片段与之前采集的全局点云地图进行迭代匹配。

迭代最近点 *Iterative Closest Point, ICP*

特点

1. 对点云噪声和缺失敏感
2. 易陷入局部最优
3. 计算量大且依赖较好的初值

算法原理

给定参考点集 P 和数据点集 Q （在给定初始估计的旋转矩阵 R 和平移向量 t 的条件下），对 Q 中的每一个点寻找 P 中的对应最近点，构成匹配点对，全部匹配点对的欧氏距离之和作为误差目标函数 $error$ 的值，利用 SVD （奇异值分解）求出新的 R 和 t ，使得 $error$ 最小，匹配的过程实际上就是寻找最小均方误差的过程。将 Q 按照 R 和 t 做旋转变换，并以此为基础再次计算，重新寻找对应点对，计算无人车与当前地图环境最匹配的位置坐标。

基本思想

启发式思想，其对于一个点云中每个点来说，其在定义点云中对应点为其欧式距离最近的点

实现步骤

1. 计算 Q 中的每一个点在 P 点集中的对应近点
2. 求得使上述对应点对平均距离最小的刚体变换，求得平移参数和旋转参数
3. 对 Q 使用上一步求得的平移和旋转参数，得到新的变换点集

如果新的变换点集与参考点集满足两点集的平均距离小于某一给定阈值，则停止迭代，否则新的变换点集作为新的 Q 继续迭代，直到达到目标函数的要求

求解

- 利用线性代数（主要 SVD ）
点云配准的过程即为寻找一个空间的最优转换矩阵 T （由旋转 R 和平移 t 组成），使得点集 P 和 Q 之间的距离最小

1. 将点集 P 、 Q 中的点均减去自身的质心

$$P' = \{p_i - \frac{1}{n} \sum_{i=1}^n p_i\} = \{p'_i\}$$

$$Q' = \{q_i - \frac{1}{n} \sum_{i=1}^n q_i\} = \{q'_i\}$$

2. 根据优化问题计算旋转矩阵 $R^* = \arg \min_R \frac{1}{2} \sum_{i=1}^n \|p'_i - R q'_i\|^2$, 求去中心后两点集的协方差矩阵 $W = \sum_{i=1}^n q'_i (p'_i)^T$
3. 计算旋转矩阵 R , 对 W 进行 SVD 分解, $W = U \Sigma V^T$, 当 W 满秩的时候, 有唯一解 $R = U V^T$
4. 计算平移矢量 $t = \mu_q - R \mu_p$

- 利用非线性优化方式

不再用一次 SVD 的封闭解, 而是把位姿变量置于李群 $SE(3)$ 上, 构建可微的代价函数 (点到点或点到面、可加权与鲁棒核), 用迭代的数值优化 (高斯-牛顿/ LM 等) 最小化

正态分布变换 *Normal Distribution Transform, NDT*

算法原理

基于标准正态分布的配准算法, 它应用于三维点的统计模型, 使用标准最优化技术来确定两个点云间的最优匹配, 因为其在配准过程中不利用对应点的特征计算和匹配, 所以计算速度比其他方法快。耗时相对稳定, 与给定的初值关系不大。

$$\text{多元正态分布概率密度函数: } f(\vec{x}) = \frac{1}{(2\pi)^{\frac{D}{2}} \sqrt{|\Sigma|}} e^{-\frac{(\vec{x}-\vec{\mu})^T \Sigma^{-1} (\vec{x}-\vec{\mu})}{2}}$$

其中 $\vec{x}$ 表示均值向量, D 是维度, Σ 表示协方差矩阵, 其对角元素表示的是对应元素的方差, 而非对应元素 (行与列) 的相关性。

基本思想

先根据参考数据来构建多维变量的正态分布, 如果变换参数能使得两幅激光数据匹配得很好, 那么变换点在参考系中的概率密度将会很大。

实现步骤

1. 将参考点云网格化, 并计算每个网格的多维正态分布参数

- 将参考点云所占的空间划分成指定大小的网格。对于三维地图, 用小立方体将整个空间的扫描点划分为网格。然后基于每个网格内的点计算均值和协方差。

- 均值: $\vec{\mu} = \frac{1}{n} \sum_{k=1}^n \vec{y}_k$, 协方差矩阵: $\Sigma = \frac{1}{n} \sum_{k=1}^n (\vec{y}_k - \vec{\mu})(\vec{y}_k - \vec{\mu})^T$

2. 初始化变换参数和求最大似然

- 对当前的点云进行变换 (平移、旋转等), 用 $\vec{p}$ 表示变换参数。当前扫描的结果为点云

$X = [\vec{x}_1, \dots, \vec{x}_k, \dots, \vec{x}_m]$, 给定扫描集合 X , 初始化变换参数 $\vec{p}$ 。用空间转换函数 $T(\vec{p}, \vec{x}_k)$ 来表示使用姿态变换 $\vec{p}$ 来移动点 $\vec{x}_k$ $\vec{x}'_k = T(\vec{p}, \vec{x}_k) = R\vec{x}_k + t$

- 旋转和平移后的点与目标点集中的点在同一坐标系下, 此时可计算各点在参考系中的概率密度

$$f(\vec{x}'_k) = \frac{1}{(2\pi)^{\frac{3}{2}} \sqrt{|\Sigma|}} e^{-\frac{(\vec{x}'_k - \vec{\mu})^T \Sigma^{-1} (\vec{x}'_k - \vec{\mu})}{2}}$$

- 使用 NDT 配准的目标是找到当前扫描的姿态, 使得当前扫描的点位于参考扫描表面上的可能性最大化。那么最好的变换参数 $\vec{p}$ 就应该是最大化似然函数/最小负对数似然 $-\log \theta$ 的姿态变换

$$\text{Likelihood: } \theta = \prod_{k=1}^m f(T(\vec{p}, \vec{x}_k)), \quad -\log\theta = -\sum_{k=1}^m \log(f(T(\vec{p}, \vec{x}_k)))$$

3. 优化参数：使用优化算法来调整变换参数 $\vec{p}$ ，令负对数似然最小化，在 *NDT* 算法中使用了牛顿法来进行。

在噪声大、点云缺失严重且初始位姿不够准确的情况下，一般认为 **NDT 比 ICP 更合适**。

NDT 通过体素划分并用高斯分布描述点云的统计特性进行概率匹配，能够对噪声起到平滑作用，同时不依赖严格的一一对应关系，因此对缺失点更鲁棒、收敛域更大。


而 ICP 依赖最近邻建立点对点或点到面的对应关系，点云质量下降时容易产生错误对应，导致收敛不稳定或陷入局部最优。不过当点云重叠率高且初值可靠时，ICP 仍具有精度高、局部收敛速度快的优势，可用于精配准。

1. **点云预处理（降低噪声与离群点影响）**：先进行离群点剔除，如统计离群点滤波（SOR）或半径离群点滤波（ROR），并可做简单平滑处理，减少噪声点导致的错误对应与发散风险。
2. **降采样与均匀化（稳定对应、降低计算量）**：使用体素栅格降采样，使点云密度更均匀、减少冗余点，同时降低计算复杂度；必要时对远近点进行密度均衡或按曲率采样，避免局部过密或过稀造成匹配偏置。
3. **选择更稳健的误差模型（改进 ICP 形式）**：优先采用点到面 ICP（**Point-to-Plane**）而非点到点 ICP，通过利用法向信息，使误差更符合几何约束，通常收敛更快、对噪声更稳健；在平面或结构明显的场景下效果更好。
4. **对应关系筛选（减少错误匹配）**：在最近邻匹配阶段加入约束，如最大对应距离阈值、法向夹角阈值、重叠率约束等，剔除不可信匹配；必要时采用双向匹配一致性检查，降低缺失点导致的“错配牵引”。
5. **提供更好的初始位姿（避免陷入局部最优）**：ICP 强依赖初值，应先进行粗配准（如特征匹配 + RANSAC / SAC-IA）或利用里程计/IMU 提供初值，再进入 ICP 精配准；初值越准，稳定性越高。

基于GPS+ INS信息的定位

坐标系4'

1. 地心惯性坐标系（ECI）：不参与地球自转
以地球质心为原点的坐标系，它不参与地球自转，Z轴沿地球自转轴指向北极方向，X轴位于赤道平面内指向春分点，Y轴符合右手笛卡尔坐标系。惯性传感器所测得的载体运动信号都是相对于惯性坐标系的绝对量。
2. 地心地固坐标系（ECEF）：与地球保持同步旋转
相同的原点及Z轴，但与地球保持同步旋转，X轴指向赤道与本初子午线交点，Y轴符合右手笛卡尔坐标系，其常用的一种表达方式为大地坐标系
3. 导航坐标系：指北导航坐标系
O位于车辆质心处，X轴指向东向，Y轴指向北向，Z轴沿垂线方向指向天向
4. 车体坐标系：与车辆固连的坐标系
为适应车辆姿态变化对传感器测量的影响而建立，O位于车辆质心，X轴沿车辆纵轴指向前方，Y轴沿车辆横轴指向左侧，Z轴符合右手笛卡尔坐标系。
地心地固坐标系/导航坐标系/车体坐标系之间的关系如下




坐标转换的方法：三次旋转

姿态矩阵：从导航坐标系(n系)到车体坐标系(b系)的变换矩阵


$$\mathbf{r}^b = \mathbf{C}_\phi \mathbf{C}_\theta \mathbf{C}_\psi \mathbf{r}^n$$

$$\mathbf{C}_n^b = \mathbf{C}_\phi \mathbf{C}_\theta \mathbf{C}_\psi = \begin{bmatrix} c\theta c\psi & c\theta s\psi & -s\theta \\ -c\phi s\psi + s\phi s\theta c\psi & c\phi c\psi + s\phi s\theta s\psi & s\phi c\theta \\ s\phi s\psi + c\phi s\theta c\psi & -s\phi c\psi + c\phi s\theta s\psi & c\phi c\theta \end{bmatrix}$$


ψ 为航向角， θ 为俯仰角， γ 为翻滚角，先按z轴旋转，之后沿y轴旋转，最后沿x轴旋转，最终得到车体坐标系



对第1个轴旋转



对第2个轴旋转




对第3个轴旋转

$$\mathbf{C}_3 = \begin{bmatrix} \cos \theta_3 & \sin \theta_3 & 0 \\ -\sin \theta_3 & \cos \theta_3 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad \mathbf{C}_2 = \begin{bmatrix} \cos \theta_2 & 0 & -\sin \theta_2 \\ 0 & 1 & 0 \\ \sin \theta_2 & 0 & \cos \theta_2 \end{bmatrix} \quad \mathbf{C}_1 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos \theta_1 & \sin \theta_1 \\ 0 & -\sin \theta_1 & \cos \theta_1 \end{bmatrix}$$

旋转坐标系 θ ，等效于将向量 v 沿着 **相反方向** 旋转 $-\theta$ 。所以，被动旋转矩阵就是主动旋转矩阵中 θ 换成 $-\theta$ 的结果

注：GPS设备信号更新频率较低，一般在1~20Hz级别，**INS**这些设备的更新频率很高，通常在**50~200Hz**左右，INS设备输出的主要数据包含x、y、z方向的加速度，以及对应旋转角速度信息，通过对这些测量值进行时间积分操作，可以得到x、y、z方向的速度信息，以及相对位置信息和roll、pitch、yaw等角度信息。如果GPS定位信号的频率提高到100Hz的水平，对于100km/h运行的车辆来说，即大约每28cm更新一次位置信息，可以保证自动驾驶的最小基本安全要求

全球卫星导航系统 **GNSS** 系统 *Global Navigation Satellite System*



组成部分

1. **空间段**：由卫星或航天器 (SV) 组成，用于传输包含卫星轨道、位置、传输时间的导航电文
2. **控制段**：地面监测站和主控中心，用于跟踪卫星信号、收集伪距测量数据和大气层模型数据、提供导航信息更新、大气信息和校正信息以及进行卫星控制
3. **用户段**：GNSS 接收机

差分GPS定位

差分 *GPS* (*DGPS*) 通过在一个精确的已知位置 (基准站) 上安装 *GPS* 监测接收机，计算得到基准站与 *GPS* 卫星的距离，再据误差修正结果，提高定位精度。

RTK (*Real - Time Kinematic*, 实时动态)

新常用 测量方法，以前的静态、快速静态、动态测量都需要事后进行解算，才能获得厘米级的精度，而 *RTK* 能够在野外实时得到厘米级定位精度的测量方法，采用了载波相位动态实时差分方法。*RTK* 技术建立在实时处理两个测量站的载波相位基础上，它能实时提供观测点的三维坐标，并达到厘米级的高精度，但硬件成本高。

分类

- 位置差分
- 距离差分
 - 伪距差分

几何距离 ρ 和伪距 $\tilde{\rho}$ 之间的关系式： $\rho = \tilde{\rho} + \delta\rho_{ion} + \delta\rho_{trop} - c \cdot V_{t_a} + c \cdot V_{T_b}$

电离层折射改正 $\delta\rho_{ion}$ ，对流层折射改正 $\delta\rho_{trop}$ ，发射时刻卫星钟的改正数 V_{t_a} ，接收时刻接收机钟的改正数 V_{T_b}
 - 载波相位差分

三角定位法

几何距离 ρ 与卫星坐标 (x_s, y_s, z_s) 和接收机坐标 (天线相位中心的坐标) (X, Y, Z) ：

$$\rho = [(x_s - X)^2 + (y_s - Y)^2 + (z_s - Z)^2]^{\frac{1}{2}}$$

卫星坐标可根据收到的卫星导航电文求得，三个卫星组成一个三角形，另外一个卫星提供对时校准，在任何一个观测瞬间用户至少需要同时测定4颗卫星的距离，以便同时解算出4个未知数 X, Y, Z 和 V_{T_b} ，

$$[(x_s - X)^2 + (y_s - Y)^2 + (z_s - Z)^2]^{\frac{1}{2}} - cV_{T_b}$$

$$= \tilde{\rho}_i + (\delta\rho_i)_{ion} + (\delta\rho_i)_{trop} - cv_{t_{a_i}}$$

影响GPS定位准确度的因素4'

1. 大气层影响：电离层和对流层对电磁波的折射效应，使得GPS信号的传播速度发生变化，从而让GPS信号产生延迟。
2. 卫星星历误差：卫星运行中受到复杂的外力作用，而地面控制站和接收终端无法测定和掌握其规律，从而无法消除产生的误差。
3. 卫星钟差：GPS卫星时钟与GPS标准时间的差别。卫星上使用铯原子钟，两者时间也许不同步。
4. 多路径效应：GPS信号可能在不同的障碍物上反射后才被接收到。

GPS定位误差

接收机的公有误差

卫星钟误差、星历误差、电离层误差、对流层误差
可以通过差分技术**完全消除**

接收机自身存在的误差

内部噪声、通道延迟、多路径效应
硬件设备的内在误差**无法消除**

基准站接收机与流动站接收机之间

传播延迟误差
取决于移动站与基站之间的距离

惯性测量单元 *Inertial Measurement Unit, IMU*

- **优点**：IMU 测量频率高，不易受干扰
- **缺点**：在捷联惯性导航解算中，通过积分来确定导航信息，定位误差会累加

加速度计

用于测量相对于惯性参考系的加速度计 (称之为**比力**) 的传感器，测量**非刚体运动加速度**，加计输出读数是比力，非重力导致的加速度

比力方程

惯导比力方程： $f = a - g$

f = 加速度输出 (比力, *Specific Force*)

a = 相对于惯性空间的运动加速度

单位: m/s^2 ; $1g = 9.8m/s^2$; $1mGal = 10^{-5}m/s^2$

惯性导航系统 *Integrated Positioning System, INS*

基于**3轴陀螺仪**和**3轴加速度计**的信号组合的自主式导航系统，可以运行在水、陆、空等多种环境中

INS工作原理

1. 以牛顿力学定律为基础，测量载体在惯性参考系的加速度和角速度信息
2. 将测量值对时间进行**积分**，把它变换到导航坐标系中
3. 得到导航坐标系中的速度 v 、偏航角 yaw 和位置 x/y 等信息

惯性导航原理：递推式行位推算

1D：假设有一小车在水平直线轨道上运动，沿运动方向安装一只加速度计

2D/3D：平台式系统和捷联式系统 (*Gimbal vs. Strapdown*)

- 由传感器数据获得载体相对于参考坐标系的方向及其变化
- 将传感器数据从“相对于惯性坐标系”转换到“相对于参考坐标系”
- 需要补偿地球万有引力（重力）加速度

平台式系统（物理平台）

- 加速度计敏感轴始终指向东向和北向
- 载体航向的变化由陀螺感知，据此控制稳定平台的转动，使其始终跟踪东向和北向

捷联式系统（数学平台）

- 加速度计和陀螺与载体固联 (*strapdown*)
- 根据陀螺输出更新姿态矩阵，将比力向量投影变换至E-N坐标系

优点

1. 不依赖于任何外部信息，也不向外部辐射能量，故隐蔽性好，且不受外界电磁干扰的影响
2. 可全天候工作于空中、地面及水下
3. 能提供位置、速度、航向和姿态角数据，所产生的导航信息连续性好而且噪声低
4. 数据更新率高、短期精度、稳定性好

缺点

1. 惯性导航误差随时间累积（下依次为初始姿态误差、加计误差、陀螺误差）：

$$\delta r_N = \delta r_{N,0} + \delta v_{N,0} \cdot t + \frac{1}{2} \left[(g \cdot \delta \theta_0) + b_{a_N} \right] t^2 + \frac{1}{6} (g \cdot b_{g_E}) t^3$$

通过器件标定来加以补偿


1. IMU 惯性器件的标定技术由于加速度计、陀螺仪等惯性器件本身存在缺陷，会产生一些器件误差，如零偏、刻度因子误差、噪声等。
2. 对 IMU 进行集成的时候，各个器件之间的非正交安装会引起交叉耦合误差。

只能**短期（10-30s）独立推算**，提供相对准确的位移估计。IMU必须依赖如GPS、激光雷达等绝对定位传感器进行定期校正，不能作为长期独立的定位源。

2. 需要初始信息
3. 成本高、笨重

基于SLAM技术的定位 *Simultaneous Localization and Mapping*

视觉SLAM定位系统完整架构



SLAM框架

传感器数据：对图像信息的读取和预处理

前端（视觉里程计）：从读取的图像信息中，根据相邻时间的图像信息计算相机的运动，以及构建局部地图。方法：特征点法、直接法

后端（非线性优化）：接受不同时刻前端测量的相机位姿，以及回环检测信息，因为图像信息具有噪声或匹配过程中的误差，所以需要对它们进行优化，得到全局一致的轨迹和地图。

回环检测：判断机器人是否到达过先前的位置。如果检测到回环，它会把信息提供给后端进行处理。

1. 关系到估计的轨迹和地图在长时间下的正确性
2. 提供了当前数据与所有历史数据的关联，可以进行重定位

建图：根据轨迹信息，建立地图


计算同一个向量在不同坐标系里的坐标：旋转加平移 $\mathbf{a}' = \mathbf{R}\mathbf{a} + \mathbf{t}$ 。

视觉里程计

点云预处理：去地面

特征点提取

特征点：图像当中具有代表性的部分



- 可重复性
- 可区别性
- 高效性
- 本地性

特征点由关键点和描述子组成

关键点：特征点在图像中的位置、大小、方向等。

描述子：特征点周围的图像信息。按照“外观相似的特征应该有相似的描述子”原则设计。

角点的提取算法：Harris角点，FAST角点，GFTT角点等。

优秀的算法：SIFT，SURF，ORB等。

SIFT特征：尺度不变特征变换 Scale-Invariant Feature Transform

充分考虑光照、尺度、旋转等变化

精确

计算量大

FAST关键点

没有描述子，不具有方向性

降低精度和鲁棒性

提升计算速度

ORB特征

关键点 *Oriented FAST* (改进的 *FAST* 角点)

FAST: 连续N个点的灰度有明显差异

Oriented FAST: 在 *FAST* 基础上计算旋转。特征点计算仅仅是比较像素之间的亮度差异，所以它不具有方向信息，也存在尺度问题。*ORB* 增添了尺度和旋转的描述。

尺度不变性：构建图像金字塔，并在金字塔的每一层上检测角点

特征的旋转：灰度质心法，质心是指以图像块灰度值作为权重的中心

描述子BRIEF：对前一步提取出来的关键点周围区域进行描述

二进制描述子，0和1编码了关键点附近两个随机像素

原始BRIEF描述子不具有旋转不变性，图像旋转时容易丢失，*ORB* 在 *FAST* 角点提取阶段计算了关键点的方向，计算旋转后的 *BRIEF* 特征，*ORB* 的描述子具有较好的旋转不变性

特征点匹配

特征点数目很大时，暴力匹配法的运算量很大（对图像 I_t 中每一个特征点 x_t^m 与图像 I_{t+1} 中所有的 x_{t+1}^n 测量描述子之间的距离,然后进行排序,取距离最小最近的一个匹配点），快速近似最近邻FLANN算法更适合匹配点数量极多的情况

相对运动：迭代最近点(Iterative Closest Point, ICP)

光流法

分类

稀疏光流：计算部分像素运动的称为稀疏光流，以 *Lucas - Kanade (LK)* 光流为代表

稠密光流：计算所有像素运动的称为稠密光流，以 *Horn - Schunck (HS)* 光流为代表

灰度不变假设：同一个空间点的像素灰度值在各个图像中固定不变，设 t 时刻位于 (x, y) 处像素点的灰度值为 $I(x, y, t)$ ，在 $t + dt$ 时刻, 该像素运动到 $I(x + dx, y + dy)$ ， $I(x, y, t) = I(x + dx, y + dy, t + dt)$

时间持续性假设：相邻帧之间物体位移很小，不会瞬移

空间一致性假设：一个 $w \times w$ 的窗口含有 W^2 个像素, 该窗口内像素具有相同的运动，通过超定最小二乘解求得运动 u, v ，当 t 取离散时刻而不是连续时，可以估计某块像素在若干个图像中出现的位置。

LK光流的结果依赖于图像梯度

1. 梯度不够平滑，可能剧烈变化

2. 局部的梯度不能用于预测长期图像走向

3. 若相机运动较快，两张图像差异明显，单层图像光流法容易达到一个局部极小值

解决方式：多层光流，引入图像金字塔来改善

在计算光流的时候，先从顶层的图像开始计算，然后把上层的跟踪结果，作为下一层光流的初始值。由于上层的图像相对粗糙，所以这个过程称作由粗到精的光流，也是实用光流的通常流程。

仅有前端和局部后端的系统称为视觉里程计，而带有回环检测和全局后端的系统才称为SLAM

回环检测

主流方法：基于外观的几何关系

和前端、后端的估计都无关，仅根据两幅图像的相似性确定回环检测关系。摆脱了累积误差，使回环检测模块成为SLAM系统中一个**相对独立**的模块。

核心问题：如何计算图像间的相似性

计算相似性得分。图像能够表示成矩阵，直接让两幅图像灰度相减，然后取某种范数 $s(A, B) = \|A - B\|$ 。

ROC曲线（Precision-Recall曲线） Precision和Recall通常是矛盾的，SLAM中对**准确率**的要求更高，对召回率则相对宽容一些

准确率 $\text{Precision} = \frac{TP}{TP+FP}$, 提取的所有回环中确实是真实回环的概率

召回率 $\text{Recall} = \frac{TP}{TP+FN}$, 所有真实回环中被正确检测出来的概率


词袋模型（Bag-of-Words, BoW）

用“图像上的哪几种特征”来描述一幅图像，图像转换成向量的描述

单词：聚类，经典的 **k-means** 聚类: N个特征点 ----> k类

1. 随机选取 k 个中心点: $c_1, \dots, c_k$
2. 对每个样本，计算它与每个中心点之间的距离，取最小的作为它的归类
3. 重新计算每个类的中心点
4. 如果每个中心点都变化很小，则算法收敛，退出；否则返回第2步

字典：当实际拿到一个特征时，需要查询它对应的单词是什么，遍历比较: $O(n)$ ，k叉树: 每次分叉为k，深度为d， k^d 个单词，d次比较



相似度计算：TF-IDF（频率-逆文档频率）

单词在图像中频率越高，区分度越高
在字典中出现频率越低，区分度越高

- TF部分：假设图像A中的视觉单词 ω_i 出现了 n_i 次，而一共出现的单词次数为 n ， $\text{TF}_i = \log \frac{n_i}{n}$
- IDF部分：叶子节点 ω_i 中的特征数量相对于所有特征数量的比例，设所有ORB特征的总数量为 n ，视觉单词 ω_i 的数量为 n_i ， $\text{IDF}_i = \log \frac{n}{n_i}$
- 视觉单词 ω_i 的权重等于TF乘以IDF的积: $\eta_i = \text{TF}_i \times \text{IDF}_i$

对于某幅图像A，它的特征点可对应到许多个单词，组成它的词袋

$A = \{(w_1, \eta_1), (w_2, \eta_2), \dots, (w_N, \eta_N)\} = \mathbf{v}_A$ 对于一幅图像A，它被表示为一个向量 $\mathbf{v}_A$ ，其中的每个维度对应一个独立的视觉单词 ω_k ，其值为该视觉单词在图像A中的权重 η_k

相似度: $s(\mathbf{v}_A - \mathbf{v}_B) = 2 \sum_{i=1}^N |\mathbf{v}_{Ai}| + |\mathbf{v}_{Bi}| - |\mathbf{v}_{Ai} - \mathbf{v}_{Bi}|$

基于词袋的回环检测完全依赖于外观，导致外观相似的图像容易被误认为回环，通常需进行时间上的一致性和空间上的一致性检测。

- 时间上的一致性检测：设立回环的缓存机制，在一段时间中一直检测到的回环，才是正确的回环。
- 空间上的一致性检测：对回环检测到的两个帧进行特征匹配，计算运动关系。根据重投影关系验证回环是否成立。

提升系统鲁棒性：还可结合语义信息或激光点云结构进行辅助判断，避免仅依赖外观相似性。融合 IMU 里程计，通过运动连续性辅助判断是否真正回到历史位置。

基于高精度地图的定位技术

融合了激光雷达点云数据、GPS 信号、语义矢量地图（车道线、道路标志标线、红绿灯、交通信号标志等）综合信息

状态估计和传感器融合

卡尔曼滤波

基本思想

预测—实测—修正： $x_2 = w_1 * x_{pre} + w_2 * z_2$ 利用前一时刻的估计值和现时刻的观测值来更新对状态变量的估计，求出现在时刻的估计值。通过卡尔曼增益比较预测和观测的不确定性程度，来判断是更相信经验还是更相信传感器。

普通卡尔曼滤波的使用条件

线性系统、观测噪声和过程噪声服从高斯分布

五个基本步骤

1. 状态预测： $\mathbf{x}'_k = \mathbf{A}\hat{\mathbf{x}}_{k-1} + \mathbf{B}u_k$
 2. 计算预测误差： $P'_k = \mathbf{A}P_{k-1}\mathbf{A}^T + Q$
 3. 计算卡尔曼增益： $K_k = P'_k\mathbf{H}^T(\mathbf{H}P'_k\mathbf{H}^T + R)^{-1}$
 4. 计算最优估计值： $\hat{\mathbf{x}}_k = \mathbf{x}'_k + K_k(z_k - \mathbf{H}\mathbf{x}'_k)$
 5. 计算最优估计值的误差： $P_k = (\mathbf{I} - K_k\mathbf{H})P'_k$
- 思考：第四步已经算出最优估计值，为什么还要计算最优估计值的误差？
考虑到误差累计，计算这一时刻最优估计值，即下一时刻预测起始值的不确定程度
其中 A 为状态转移矩阵, Q 过程噪声的协方差矩阵, H 为状态域到观测域的转换矩阵, R 为观测噪声的协方差矩阵

扩展卡尔曼滤波（EKF）

基本思想

扩展卡尔曼滤波的本质是使用线性变换来近似非线性变换
EKF 是通过偏导数或连续差分, 经雅克比矩阵, 对非线性函数 $f(x)$ 本身进行近似(线性化), 但是忽略了高阶导数

五个基本步骤

1. 状态预测: $x'_k = g(\hat{x}_{k-1}, u)$
2. 计算预测误差: $P'_k = J_A P_{k-1} J_A^T + Q$
3. 计算卡尔曼增益: $K_k = P'_k J_H^T (J_H P'_k J_H^T + R)^{-1}$
4. 计算最优估计值: $\hat{x}_k = x'_k + K_k (z_k - J_H (x'_k))$
5. 计算最优估计值的误差: $P_k = (I - K_k J_H) P'_k$
 分别用雅可比矩阵 J_A 和 J_H 来代替线性系统中的状态转移矩阵和观测矩阵, Q 为过程噪声的协方差矩阵, R 为观测噪声的协方差矩阵。

无损卡尔曼滤波 (UKF)


基本思想: 近似概率分布比近似非线性函数更容易

UKF是对非线性函数的概率分布(均值 μ 和方差 σ^2) 进行近似 (sigma points), 用一系列确定的样本来逼近状态的后验概率分布。

深度学习

机器学习概述

机器学习的基本分类



1. 监督学习 (Supervised Learning): 数据集既包含样本 (手写字图片), 又包含其对应的标签 (每张手写字图片对应的是哪个数字)
2. 无监督学习 (Unsupervised Learning): 与监督学习相对应, 数据集仅包含样本, 不包含样本对应的标签, 机器学习算法需要自行确定样本的类别归属。
3. 强化学习 (Reinforcement Learning): 又称为增强学习, 是一种半监督学习, 强调如何基于环境而行动, 以取得最大化的预期利益

经验风险最小化

损失函数

损失函数学习: 通过算法学得函数 $f(x)$ 的输出和 x 样本对应的真实值 y 之间的距离 $L(f(x), y)$ 这个损失越小, 表示学得的函数 f 更贴近于真实映射 g

风险

损失函数的期望值 $R(f) = \sum_i L(f(x_i), g(x_i))p(x_i)$

经验风险 (Empirical Risk)

真实分布的近似值。真实风险是建立在对整个样本空间进行考虑的基础之上，但并不能获得整个样本空间，有的只是一个从要解决的任务样本空间中使用独立同分布的方法随机采样得到的子集 $(\mathbf{X}, \mathbf{Y})$ （也就是数据集）。

$\bar{R}(f) = \frac{1}{n} \sum_{i=1}^n L(f(x_i), y_i)$ 其中 (x_i, y_i) 是已有的数据集中的样本，**经验风险最小化原则**：选择能够最小化经验风险的函数 f

%%对于手写识别任务，在数据集上通过经验风险最小化策略调整神经网络的模型参数，使得神经网络拟合出一个函数 f_1 ，训练出的这个“黑箱”可用于手写识别；而对于车辆识别，利用经验风险最小化策略，可以训练出一个黑箱（神经网络）来做车辆识别%%

欠拟合和过拟合

欠拟合：当训练误差过高时，模型学到的函数并没有满足经验风险最小化，模型在训练集中的识别**精度很差**

过拟合：当训练误差低但是**测试误差高**，即训练误差和测试误差的差距过大时，称之为过拟合，此时模型学到了训练集上一些“多余的规律”，表现为在训练数据集上识别精度很高，在测试数据集（未被用于训练，或者说未被用于调整模型参数的数据集上）上识别精度不高

梯度下降

导数的反方向移动一小步来最小化目标函数的方法

梯度下降算法是一个一阶最优化算法，通常也称为最速下降法。要使用梯度下降法找到一个函数的局部极小值，必须向函数当前点对应梯度（或者是近似梯度）的反方向的一定距离内进行迭代搜索

要最小化经验风险 $\bar{R}(f)$ ，等同于最小化损失函数，在机器学习中，损失函数可以写成每个样本的损失的和：



$L(\theta) = \frac{1}{n} \sum_{i=1}^n L(x_i, y_i, \theta)$ 其中 θ 表示模型中的所有参数， L 对 θ 的导数记作 $L'(\theta)$ ，代表了函数 $L(\theta)$ 在 θ 处的斜率，可以把函数输入输出的关联性用斜率来描述，其中 α 为学习率

$$L(\theta + \alpha) \approx L(\theta) + \alpha L'(\theta) \quad (1)$$

利用上述公式，可以利用导数来逐渐使 L 变小，即只要让 α 的符号和导数的符号相反：

$$\text{sign}(\alpha) = -\text{sign}(L'(\theta)), \quad L(\theta + \alpha) = L(\theta) - |\alpha L'(\theta)| \quad (2)$$

学习率的大小设置对学习过程的影响



神经网络基础

感知机的定义和模型

感知机：最初的神经网络设计借鉴的是生物神经元的结构，使用一个数学模型来描述人类神经元的结构以及接受刺激、被激活然后传递刺激的过程

向向量 x_i 来表示输入的数值, 输入会乘以一个权重向量 w_i , 在

$$z = \sum_{i=1}^d w_i x_i + b$$


$$= \mathbf{w}^T \mathbf{x} + b,$$

感知机内部, 这些乘以权重的输入被求和, 并且加上了一个很小的偏置 b 。在感知机的输出端, h 被输入到一个阶跃

函数 f 中: $f(h) = \begin{cases} 1, h > 0 \\ 0, h \leq 0 \end{cases}$

激活函数 (Activation Function)

阶跃函数是一个**非线性变换**，它属于激活函数的一种，由于阶跃对函数的模拟比较粗糙，所以通常不会使用阶跃函数作为神经元的激活函数，常用的激活函数包括 **sigmoid函数**、**tanh函数**、**ReLU (Rectified Linear Unit)** 及其变体等



感知机与神经网络

单个感知机被证明无法学习到异或（XOR）关系
使用**多层感知机嵌套**，即现代的神经网络结构
神经网络优势：在拥有足够多的隐藏层神经元节点的情况下，三层神经网络能够拟合任意函数

前馈神经网络输出方式

One-hot编码

单点激活的编码方式，输出层的每一个神经元的输出对应一个类别，对应类别的位置激活为1，其他位置为0。类别数很少的情况下是一种非常有效的方式。

SoftMax分类

神经网络输出的是各个点的“得分”，这个数值被称为Logit。希望得到的不是得分而是输出层各个神经元被激活的概率，所以在神经网络的输出层再添加一个SoftMax函数，它的作用是将神经元的输出"得分"转换为容易理解的概率，所有神经元**概率的和为1**，输出概率越大表示预测为某个数字的概率也越大

前向传播和反向传播

方面	前向传播 (Forward Propagation)	反向传播 (Backward Propagation)
核心作用	计算预测，评估表现	计算梯度，归因错误
数据流向	输入层 → 输出层	输出层 → 输入层
目的	得到预测值和损失值	得到所有参数的梯度
比喻	学生考试答题	老师批改并指出如何改进
后续	产出的 损失值 是反向传播的输入	产出的 梯度 是参数更新的 依据

求得损失以后，得到了神经网络的输出结果以及输出结果与真实值之间的“距离”。这个过程称为一次**前向传播（Forward Propagation）**。

前向传播能够输出正确分类的前提是神经网络已经具有了合适的参数。为了确保网络有合适的参数，网络通过**反向传播（Back Propagation）** 算法让损失函数的信息通过网络向前流动，从而**计算梯度并更新权重**。一次反向传播仅仅更新一次参数，称为一个Epoch，通常需要迭代多个**Epoch**才会使得网络收敛到合适的模型。

前馈神经网络的训练过程

1. 前向计算每一层的状态和激活值，直到最后一层
2. 反向计算每一层的参数的偏导数
3. 更新参数

深度神经网络

正则化方法（Regularization）

减少测试误差和训练误差的差距，提高模型的泛化能力，增强模型的鲁棒性

数据集增强

以图像数据为例，通过算法对图像进行转变，引入噪声等方法来扩充数据，即**增加数据量**

提前终止 Early Stopping

使用一个验证集（Validation Dataset）来测试每一次迭代的参数在验证集上是否最优，如果在验证集上的错误率不再下降，就停止迭代

参数范数惩罚 / ℓ_1 和 ℓ_2 正则化

丢弃技术

通过改变训练时神经网络的结构来增强网络的泛化能力，**随机删除**网络中某层某些节点的输入/输出边权重
每做一次丢弃，相当于从原始网络中采样得到一个子网络，相当于训练了很多个**只有半数隐含层单元的神经网络**（即“半数网络”），大部分半数网络都可以给出正确分类结果，少数错误分类结果就不会对最终结果造成大的影响
训练结束时，这个神经网络可以看作**多个训练好的半数网络的集成模型**，到应用网络的阶段，就不再使用Dropout，网络的最终输出结果是所有半数网络的集成结果，其泛化能力自然就会更好

卷积神经网络的优势

稀疏交互

下一层的节点只与其卷积核作用到的节点相关

权重共享

参数共享，只需要学习一个参数集合，不需要对每一个像素都学习一个单独的参数集合，模型所需的存储空间大幅度降低

叠加多个卷积层，卷积网络虽然在直接连接上是稀疏的，但是在更深的层中单元可以间接连接到全部或者大部分的输入图像

等变表示

由于整个输入图片共享一组参数，模型对于图像中的某些特征平移具有等变性
这一性质在检测输入中的某些共有结构（比如边缘）时非常有用，尤其在卷积神经网络的前几层（靠近输入的层）

卷积和池化

使用相邻位置的总体统计特征来替换该位置的值,理念类似时序问题中的滑动窗口平均

- 最大池化
- 平均池化

YOLOv3网络结构-降采样

方式：使用卷积层代替池化层进行降采样

作用：解决池化层丢失细节信息的问题。


Darknet-53共进行5次降采样，每次降采样后特征图尺寸缩减2倍，共缩减32倍。

残差网络的作用

网络设计的层次越深，会出现冗余层导致模型过拟合（即对新数据的测试集预测结果差）,残差块的恒等映射可以“去掉”这些冗余层，解决网络退化问题，使加深的神经网络能够表达出好的特征

让每一层不再直接学习完整的输出，而是去学习相对于输入的“残差”（即差异或者需要改进的部分）。同时，通过“跳跃连接”，将输入直接加回到输出上，为信息和梯度提供了一条畅通无阻的路径。

多通道卷积



输出特征图的尺寸 ($H_{out} * W_{out} * C_{out}$)

- 对于高度 (H_{out}) 和宽度 (W_{out}): $O = \text{Floor}((I - K + 2P) / S) + 1$
 - I 是输入尺寸（高或宽）
 - K 是卷积核尺寸（高或宽）

- o **P** 是填充 (Padding)
- o **s** 是滑动步长 (Stride)
- o **Floor** 是向下取整

- 对于输出通道数 (**C_{out}**): 输出通道数等于使用的卷积核的数量

YOLO



以YOLO为代表的单阶段目标检测算法与以RCNN为代表的深度学习目标检测算法最大的区别

以RCNN系列为代表的深度学习目标检测算法采用**两阶段**的方法，首先生成候选区域，然后对这些候选区域进行分类和回归

YOLO单阶段目标检测算法中通过**单个神经网络模型**一次性完成目标检测和边界框回归


YOLOv3算法中共包含3中不同尺度的特征图来进行目标检测，当输入图像分辨率为 416×416 时，三种尺度特征图的大小分别为 13×13 , 26×26 , 52×52 。

特征图深度=一个cell与n个锚框匹配* (中心偏移量+cell内是否含有物体+预测边界框的准确性 (含有物体时) + 物体类别概率)




无人驾驶视觉感知

基于激光雷达的路缘石检测




点云预处理

按类划分选定区域内的点



1. 订阅 `velodyne_points` 消息获取原始点云并切割出处于感兴趣区域内的部分
2. 将处于感兴趣区域内的点云按其所属射线划分成若干个点集
3. 激光射线投射在不同高度的路缘石平台与路面上导致了弧线“错位”现象

划分左右子集




a) 按x轴划分点集

b) 按参考线划分点集

1. 按x轴划分点集：简单直观，车体发生偏转时，容易产生错误划分
2. 按参考线划分点集：得到的参考点几乎总是处于路面上，减少了左右点集划分错误的情况
 1. 通过高度信息筛选，获得最远点集中投射在路面上的点
 2. 对最远点集中投射在路面点的坐标进行求和取平均，获得参考点坐标
 3. 将参考点与雷达中心进行连线得到参考线对所有点集进行左右划分，得到左、右子点集


左右子点集排序



使用顺时针与逆时针的方式分别对右子点集与左子点集中的点进行排序

滑窗算法

1. 路缘石与路面存在一定高度差，可利用激光雷达投射在路缘石垂面上相邻两点高度之差较大这一几何特性获取包含路缘石点的有效窗口，并选定有效窗口中与邻点高度差最大一点为路缘石点



2. 使用滑动窗口方法对排序后的左右子点集进行筛查，提取路缘石点

聚类拟合

1. 对每个路缘石点进行两两连线，将得到的所有直线按斜率进行聚类
2. 对聚类结果中最大类内的直线取平均，即得到拟合的路缘石线

基于摄像机的车道线检测

1.保留ROI、去畸变

1. 实际平行的车道线在图像上呈现出近宽远窄的效果，尽量去除图像中车道线之外的部分，只保留感兴趣区域 (Region of Interest, ROI)
2. 透视变换

1. 在原始图像中标定四个顶点并记录其在图像中的位置坐标，给出这四个顶点在所期望获得的鸟瞰图中的位置坐标
2. 使用OpenCv库中的getPerspectiveTransform函数两种位置坐标，给出透视变换所需的转换矩阵
3. 使用OpenCv库中的wrapPerspective函数对原始图像处理得到鸟瞰图


2.形态学处理

中值滤波


将图像中的每一个像素点用附近邻域内所有像素点的中值来代替，从而去除图像中的一些噪声：
`image = cv2.medianBlur(image, 5)`

颜色空间转换

将鸟瞰图由RGB颜色空间转换为HSV颜色空间，以便于提取图像中的车道线像素点
`image_hsv = cv2.cvtColor(image, cv2.COLOR_BGR2HSV)`



RGB颜色空间



HSV颜色空间

车道线提取

形态学处理中的腐蚀和膨胀操作

1. 定义结构元素（核），用于与图像卷积，实现对图像的腐蚀膨胀操作

```
1 1 1 1 1
1 1 1 1 1
1 1 1 1 1
1 1 1 1 1
1 1 1 1 1
```

矩形结构元素


```
0 0 1 0 0
1 1 1 1 1
1 1 1 1 1
1 1 1 1 1
0 0 1 0 0
```

椭圆形结构元素

```
0 0 1 0 0
0 0 1 0 0
1 1 1 1 1
0 0 1 0 0
0 0 1 0 0
```


十字形结构元素

2. 对提取车道线颜色后得到的黑白二值图进行腐蚀操作，对其进一步减噪
 腐蚀就是求局部最小值的操作，核B与图像（或图像的一部分区域，我们称之为A）卷积，即计算核B覆盖区域的像素点最小值，并把这个最小值赋值给参考点指定的像素。这样就会使图像中的高亮区域逐渐减少



腐蚀操作示意图

3. 对腐蚀后的黑白二值图进行**膨胀**操作，以对腐蚀后得到的结果进行增强（膨胀和腐蚀是相反的一对操作，所以膨胀就是求**局部最大值**的操作）




膨胀操作示意图

3.车道线拟合

计算车道线下端起点

以图像的左上顶点为坐标原点，以图像高为x轴、宽为y轴建立的平面直角坐标系，将图像分为左右两部分，对这两部分沿**x轴**方向将像素值累加，分别找出两部分中最大的累加值，将其所在位置作为左右车道线的下端起点



滑动窗口

1. 以车道线的下端起点作为第一个窗口的中点，按预先设定的窗口大小确定第一个窗口，返回窗口内所有**非零像素点**的坐标值，将所有非零像素点坐标的平均值作为**第二个窗口的中点**生成第二个窗口以此类推
2. 利用滑动窗口能够排除二值图中车道线以外的**杂点**并返回图像中车道线对应的**所有非零像素点**的坐标，用于车道线的直线拟合

拟合车道线

利用numpy库中的多项式拟合函数polyfit对滑窗返回的有效车道线坐标值进行直线拟合，函数返回值是拟合的直线方程系数

4.坐标系转换

像素坐标系转换至车体坐标系

将拟合出的车道线投影到现实世界三维空间中，并显示在rviz界面上

两次坐标系变换：利用拟合好的直线方程系数对坐标系进行变换，先转换至世界坐标系，再转换至车体坐标系

迁移学习

迁移学习的必要性

矛盾	传统机器学习	迁移学习
大数据与少标注	增加人工标注，但是昂贵且耗时	数据的迁移标注
大数据与弱计算	只能依赖强大计算能力，但是受众少	模型迁移
普适化模型与个性化需求	通用模型无法满足个性化需求	模型自适应调整
特定应用	冷启动问题无法解决	数据迁移

比较项目	传统机器学习	迁移学习
数据分布	训练和测试数据服从相同的分布	训练和测试数据服从不同的分布
数据标注	需要足够的数据标注来训练模型	不需要足够的数据标注
模型	每个任务分别建模	模型可以在不同任务之间迁移

常见的迁移学习方法分类

基于实例的迁移 (instance based TL)

通过权重重用源域和目标域的样例进行迁移，从源数据里挑或“加权”那些和目标数据更像的样本来训练，让训练更贴近目标分布

基于特征的迁移 (feature based TL)

将源域和目标域的特征变换到相同空间

基于模型的迁移 (parameter based TL)

利用源域和目标域的参数共享模型

基于关系的迁移 (relation based TL)

利用源域中的逻辑网络关系进行迁移，迁移“样本或类别之间的关系/结构”，比如图、知识库、共现关系、因果或上下位关系，让这些结构帮你在目标域里学习

迁移学习应用场景

在开发深度学习模型时，并不一定需要从头开始训练模型。迁移学习可以方便将这些经典模型移植到新的应用场景中

如何移植取决于两个因素：新应用数据量大小、新应用和原始模型的相似度。


数据集数量	应用相似度	模型训练方法
较大	较高	微调模型
较大	较低	微调或者重新训练
较小	较高	对全连接分类层进行修改训练
较小	较低	重新设计、重新训练模型

强化学习

端到端无人驾驶

基本思路与模型

1. 采集数据：通过人为操作车辆（模拟器）行驶来采集控制数据
过程中，需要记录下当前车辆前方的道路场景图像，记录下人在驾驶车辆（正确操作）时的控制参数，例如方向盘的转角、刹车和油门等。
2. 网络训练：训练深层神经网络模型
输入参数：采集到的路况图像数据
输出数据：汽车的控制参数
3. 测试：基于路况图像和控制参数训练完神经网络模型之后，该模型就具有一定的能力对当前摄像头采集到的路况场景进行预测，进一步可以给出车辆的控制参数，这些参数被输入到汽车线控单元（或者作为模拟器输入参数），从而达到控制车辆自动行驶的目的。



马尔可夫性和马尔可夫过程

强化学习的本质是一个序列决策过程，通过不断地学习每个状态，最终得到一个最佳的序列(策略)，这与马尔可夫决策过程解决的问题相似。

- 马尔可夫性：指系统的下一个状态 S_{t+1} 仅与当前状态 S_t 有关，表示为

$$P[S_{t+1}|S_t] = P[S_{t+1}|s_1, s_2, \dots, s_t] \quad (3)$$

- 马尔可夫过程：它是一个二元组 (S, P) ，其中 S 为有限状态机， P 为状态转移概率矩阵，该矩阵为：

$$P = \begin{pmatrix} P_{11} & \dots & P_{1n} \\ \vdots & \ddots & \vdots \\ P_{n1} & \dots & P_{nn} \end{pmatrix} \quad (4)$$

在强化学习中，问题被描述为一个马尔可夫决策过程(Markov Decision Process, MDP)，由一个元组 $\langle S, A, P, R \rangle$ 表示：

- S 为有限状态空间集合， $s_t \in S$ 表示 t 时刻状态
- A 为有限动作空间集合， $a_t \in A$ 表示 t 时刻动作
- P 为状态转移概率， $P(s'|s, a)$ 表在状态 s 下执行动作 a 后，转移至下一状态的概率
- R 为奖惩函数，执行完动作转移至下一状态时，奖励记作 $R = r(s'|s, a)$

非确定性策略和确定性策略

通常情况下策略被定义为从状态到行为的一个映射，每个状态下指定一个动作概率，这个策略可以是非确定性的(只满足某种分布)，也可以是确定性的。

- 非确定性策略：对于相同的状态，其输出的状态并不唯一，而是满足一定的概率分布，从而导致即使处于相同的状态，也可能输出不同的动作

$$\pi(a|s) = P[A_t = a|S_t = s] \quad (5)$$

- 确定性策略：在相同的状态下，其输出的动作是确定的，实现时，只需要建立一个神经网络，输入状态，输出一个确定的动作就行

$$a = \mu(s) \quad (6)$$

及时奖励和累计期望奖励

- 及时奖励：实时反馈给智能体的奖励 r
- 累计期望奖励：指一个过程的总奖励期望，比如直升机从飞起到降落整个过程

$$G_t = R_1 + \gamma R_2 + \gamma^2 R_3 + \dots + \gamma^{k-1} R_k = \sum_{k=0} \gamma^k R_{t+k+1}, \quad \gamma \text{ 为折扣因子} \quad (7)$$

假如在策略 π 下，从 Start 出发，有不同的路径。每个路径的累计回报 G_t 不同，且在随机策略下 G_t 是随机变量，但它们的期望是一个确定值，因此需要用值函数进行估计。

状态-值函数和状态-行为值函数之间的关系

$$V_{\pi}(s) = \sum_{a \in A} \pi(a|s) q_{\pi}(s, a)$$

值函数是对未来奖励的一个预测。当智能体采用某个策略 π 时，累计回报服从一个分布，通常将状态 S 处的期望定义为状态-值函数

$$V_{\pi}(s) = E_{\pi}[R_1 + \gamma R_2 + \gamma^2 R_3 + \cdots + \gamma^{k-1} R_k | S_t = s] \quad (8)$$

其中 $\gamma \in [0, 1)$ 是折扣因子，用来估算未来对现在的影响。如果 $\gamma = 0$ ，即短视，只看当前的而不关注长期的回报。

状态-行为值函数衡量当前行为的好坏，在某一个状态下采取某行为会带来的期望回报

$$q_{\pi}(s, a) = E_{\pi} \left[\sum_{t=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s, A_t = a \right] \quad (9)$$

一般情况下，状态-值函数和状态-行为值函数之间的关系表示为：

$$V_{\pi}(s) = \sum_{a \in A} \pi(a|s) q_{\pi}(s, a) \quad (10)$$

贝尔曼方程

$$v_{\pi}(s_t) = E_{\pi}[R_{t+1} + \gamma v_{\pi}(s_{t+1})]$$


$$q_{\pi}(s_t, a_t) = E_{\pi}[R_{t+1} + \gamma v_{\pi}(s_{t+1}, a_{t+1})]$$

在强化学习中的作用


- 计算值函数的目的是为了从数据中学到最优策略，每个策略对应一个值函数，最优策略对应最优值函数
- 当且仅当 $\pi \geq \pi^*$ 且 $V_{\pi}(s) \geq V^*(s)$ 时，最优状态-值函数 $V^*(s)$ 为所有策略中值函数最大的

Q值函数

1. DQN和Q-Learning算法的区别是什么？



Qtable—离散




Q值函数—连续

- Q-learning: 状态空间是离散的，算法维护一个 **Q-table**，Q-table记录了不同状态下 $s(s \in S)$ ，采取不同动作 $a(a \in A)$ 的所获得的 Q 值。
- DQN：是基于深度学习的Q-learning算法，状态空间是连续的，不能用表格描述，使用神经网络生成函数 $Q(s, a, w)$ 近似动作价值函数。

2. DQN中的经验回放起到什么作用？

- **基本思想**：将智能体的交互经验存储在一个经验池中，并在智能体进行更新时从经验池中随机采样一小批经验来进行训练。
- **作用**：智能体可以更好地利用过去的经验，提高学习效率，降低了采样成本。此外通过随机采样，经验回放可以减少训练数据之间的相关性，提高算法收敛速度。

3. DQN中的目标网络和评估网络有何区别及联系，分别承担什么作用？



目标网络和评估网络 $Q(s, a, \theta)$ 结构一样，只是参数不同 $\theta' \neq \theta$ ，且参数更新频率也不同。在更新过程中，评估网络 $Q(s, a, \theta)$ 的权重 θ 会随着训练而不断更新，以逼近最优 Q 值函数。

在训练学习过程中，某段时间内目标 Q 值一直保持不变，这一定程度降低了当前 Q 值和目标 Q 值的相关性，提高了算法稳定性。

两个网络的作用不一样

- 评估网络用于估计Q值函数，收集经验，决定智能体的动作选择。
- 目标网络是提供一个稳定的目标Q值，以减少训练中的估计偏差。

策略梯度

通过最大似然和蒙特卡洛法计算梯度得到最终梯度公式：

$$\nabla_{\theta} J(\theta) = \frac{1}{N} \sum_{i=1}^T \left[\sum_{t=0}^T \nabla_{\theta} \log \pi_{\theta}(a_i, t | s_i, t) \left(\sum_{t=0}^T r(s_i, t, a_i, t) \right) \right]$$

当前第n回玩游戏时，t时刻机器所看到的画面情况下做出a行为的概率

第n回完游戏时总的奖励

思考：如果换成t时刻的奖励会发生什么后果？


会导致只注重当前做的动作的回报，而不会注重整个游戏的过程中的奖励。容易陷入局部最优，无法更新到最优解。

深度确定性策略梯度算法 DDPG

基本框架：演员-评论家（Actor-Critic）算法

策略网络和动作值函数的近似采用：深度神经网络

对于策略函数和价值函数均使用双重神经网络模型架构，请解释Critic目标网络和训练网络、Actor目标网络和训练网络分别的作用？



DDPG 共包含 4 个神经网络，用于对 Q 值函数和策略的近似表示。

- Critic
 - 目标网络：用于近似估计下一时刻的状态-动作的 Q 值函数
 - 训练网络：输出当前时刻状态-动作的 Q 值函数，用于对当前策略评价
- Actor
 - 目标网络：用于提供下一个状态的策略
 - 训练网络：提供当前状态的策略，结合Critic 训练网络的Q值函数可以得到Actor在参数更新时的策略梯度

Q-learning是为离散动作空间设计的，而DDPG是为连续动作空间设计的。当问题变得复杂时（比如高维度的状态和连续的动作），Q-learning的方法就暴露出了根本性的局限，而DDPG的架构恰好解决了这些痛点。寻找最优动作的过程从“在无限个动作中搜索最大Q值”变成了“直接由Actor网络给出一个最优动作”。这个结构从根本上解决了连续动作空间的问题。

特性	Q-Table	DQN (Deep Q-Network)	DDPG (Deep Deterministic Policy Gradient)
核心思想	价值学习 (Value-Based)	价值学习 (Value-Based)	演员-评论家 (Actor-Critic)
状态空间	离散且低维	连续或高维 (如图像)	连续或高维 (如图像)
动作空间	离散	离散	连续
模型/数据结构	二维数组 (表格)	深度神经网络	两个深度神经网络 (Actor & Critic)
输出	整个Q值表	所有离散动作的Q值向量	Actor: 确定性连续动作 Critic: 单一Q值
决策方式	查表 + <code>argmax</code>	神经网络前向传播 + <code>argmax</code>	Actor 网络直接输出动作
相同点	- 都属于强化学习算法 - 都需要计算Q值来指导决策	- 都是Value-Based - 都用 <code>argmax</code> 决策 - 都常与经验回放池结合	- 都使用神经网络 - 都使用经验回放池 - Critic部分也计算Q值
关键创新/解决的问题	强化学习的基础	解决了Q-Table的状态维度灾难	1. 解决了DQN的离散动作空间限制 2. 引入Actor-Critic处理连续动作
主要局限	状态和动作空间稍大就不可用	无法处理连续动作空间	训练不稳定，对超参数敏感

无人驾驶的规划

无人车路径规划和A*算法

深度优先搜索

沿着一条路径不断往下搜索直到不能继续，然后再折返，开始搜索下一条路径。
保存候补节点：栈，性质先进后出

广度优先搜索


根据离起点的距离，按照从近到远的顺序对各节点进行搜索，能够找到最短路径。
保存候补节点：队列，性质先进先出

Dijkstra算法

基本思想和实现步骤：由近到远把所有点的最短路径算出来
缺点：搜索最短路径时需要遍历整个离散空间，搜索的效率相对较低，计算开销也较大


A*算法

基本思想和实现步骤：以从起点到该点的距离加上该点到终点的估计距离之和作为该点的优先级。



混合A*算法

经典A*只考虑了x, y两个维度，相当于把车当成了一个质点。混合A*在此基础上引入了θ维度表示朝向，用x, y表示车辆后轴中心。



比较A*和混合A*算法

节点字段定义

- 经典A*包含的字段包括：F, G, H, 父节点。
- 混合A*新增的字段包括：
 - 对应的位姿[x, y, θ]
 - 节点是由何种v, φ扩展而来
 - 由父节点到本节点的轨迹

节点扩展方式

- 经典A*扩展节点的方式就是找相邻节点。
- 混合A*的扩展需要考虑车辆动力学。要求车辆在单位时间内，以恒定的速度和转角做匀速运动，轨迹末端落入的三维网格就是要扩展的子节点。

碰撞检测方式

- 经典A*算法中，判断是否碰撞只是检查对应网格是否被占据。
- 混合A*需要将整条轨迹均匀采样，检测各采样时刻车辆位姿是否与障碍物碰撞。

距离定义

丰富了距离G的含义

- 在经典A*中，G是从起点到当前节点的距离。但是距离单个因素不足以完整体现轨迹的合理性与轨迹的平滑程度。
- 混合A*从当前节点扩展到子节点的距离可以直接由 v^* 单位时间得到，此外，加入了对控制量 v ， ϕ 频繁切换的惩罚。从当前节点到终点的估算距离综合考虑了车辆动力学和碰撞检测距离。

丰富了距离H的含义

- 在经典A*中，用曼哈顿距离来估计H的值。
- 混合A*中，H有两种计算方式，最后取其中较大的一个。
H1：符合车辆动力学，不考虑碰撞检测的距离，使用Reeds-Shepp曲线计算。
%%Reeds-Shepp曲线：最短的路径把车停进去，汽车运动形成的黑色曲线就是Reeds-Shepp曲线。Reeds-Shepp曲线由几段半径固定的圆弧和一段直线段拼接组成，而且圆弧的半径就是汽车的最小转向半径。%%
H2：考虑碰撞检测，不考虑车辆动力学的距离，取曼哈顿距离和Dijkstra距离两者之间的较大值

无人车路径规划-局部路径规划-TEB算法

局部优化

TEB被表述为一个多目标优化问题，大多数目标都是局部的，只与一小部分参数相关，因为它们只依赖于几个连续的机器人状态。

注意：局部性-每个目标函数只与elastic band中的某几个连续状态有关，而非整条band。

约束目标函数

1. 跟随路径+避障

约束主要有两个目标：跟随已知的全局规划路径和避障。

两个目标函数均十分相似，算是一类问题。跟随路径施力将elastic bands拉向全局路径，而避障约束施力使得elastic bands远离障碍物。

2. 速度/加速度约束

橡皮筋只定义了姿态 (x, y, θ) 与两两状态直接的时间，直接用差分近似计算

3. 运动学限制

若干弧段组成平滑的轨迹，不希望车漂移起来。控制量只有车速（油门）与转角（方向盘），阿克曼结构有最小转弯半径，麦轮/差速/全向轮车为0。

4. 最快路径约束

目标函数使得机器人获得最快路径，路径上的各位姿点在时间上均匀分开，而非传统的空间上求最短路径。

优化算法

g2o-General Graph Optimization通用图优化法：点(node) & 边(edge)

TEB生成的局部轨迹由一系列带有时间信息的离散位姿(pose)组成，g2o算法优化的目标即这些离散的位姿，使最终由这些离散位姿组成的轨迹能达到时间最短、距离最短、远离障碍物等目标，同时限制速度与加速度使轨迹满足机器人的运动学。

全局路径—加入约束—g2o优化—速度指令

适合动态避障

无人车行为规划

有限状态机

算法基本原理

只对特定的外界输入产生数量有限的响应

分类

1. 确定型自动机：每个状态对每个可能输入只有精确的一个转移
2. 非确定型自动机：给定状态对给定可能输入可以没有或有多于一个转移

存在问题

当状态很多，有限状态机就有可能变得非常庞大，可维护性差、可扩展性差、复用性差

分层有限状态机

算法基本原理

新增了**超级状态（Super-state）**，将同一类型的一组状态合为一个集合。

斯坦福大学Junior：将顶层的驾驶行为分成了**13个超级状态**。在无人车正常行驶中，状态机几乎处在普通驾驶模式（即FORWARD_DRIVE和PARKING_Navigate这两个状态）。

优点

1. **分层结构**：将状态机分为不同的层次，每个层次可以包含多个子状态，子状态之间可以共享父状态的行为和事件，从而减少状态的数量和复杂度。
2. **分层继承**：子状态可以继承父状态的属性和方法，同时也可以覆盖和扩展父状态的功能，从而提高状态机的可复用性和灵活性。
3. **分层封装**：每个层次的状态机可以作为一个独立的模块，对外提供统一接口，提高可读性和可测试性。

无人车路径生成-三次样条插值算法

三次曲线(单一的三次多项式 $y = ax^3 + bx^2 + cx + d$ 来拟合所有给定的数据点)和三次样条插值生成路径的区别

三次样条插值拟合出来的曲线更加符合车辆运动学规律，汽车尽量走直线，只是在转变方向的地方形成一个符合汽车转弯特性的曲线路径。

性质

1. 三次样条曲线在衔接点处是连续、光滑的
2. 三次样条的一阶导数和二阶导数是连续可导的
3. 自由边界三次样条(Nature Cubic Spline)的边界二阶导数也是连续的。
在起点、终点边界点，二阶导数 == 0

4. 单个点并不会影响到整个插值曲线

基于Frenet优化轨迹的无人车动作规划方法

动作规划

目的是将上游行为决策（behavior）的宏观指令解释成一条带有时间信息的轨迹曲线（trajectory），最后给底层的反馈控制。

- 轨迹规划（Trajectory Planning）：二维平面上的优化轨迹问题
- 速度规划（Speed Planning）：选定轨迹后，用什么样的速度行驶这条轨迹


最优的动作序列

Jerk 即加速度的变化率，也即加加速度

过高的加加速度会引起乘坐者的不适，要解决的问题是研究如何优化Jerk

Frenet坐标系

Frenet坐标系中，使用道路的中心线作为参考线，使用参考线的切线向量和法线向量建立一个坐标系



a) 笛卡尔坐标系

b) Frenet坐标系

笛卡尔坐标系和Frenet坐标系比较

相对比笛卡尔坐标系的优势

相比于笛卡尔坐标系（图a），Frenet坐标系明显地简化了道路曲线拟合的问题。因为在公路环境下，总是能够简单找到道路的参考线（即道路中心线），那么基于参考线的车辆位置表示就可以简单地使用纵向距离和横向距离来描述，同样，两个方向的速度的计算也相对简单。

横向、纵向轨迹优化

横向轨迹

在较高速度的情况下，损失函数可设计为：

$$C_d = k_j J_t(d(t)) + k_t T + k_a d_1^2 \quad (11)$$

该损失函数包含三个惩罚项:

- $k_j J_t(d(t))$: 惩罚Jerk较大的备选轨迹
- $k_t T$: 制动应当迅速, 时间短

- $k_d d_1^2$: 目标状态不应偏离道路中心线太远
- k_j 、 k_t 和 k_d 是**惩罚项的权重值**，决定了损失函数更加偏向哪一方面的优化
- 好的，遵照你提供的格式，我们来为纵向轨迹设计一个在较高速度情况下的损失函数。

纵向轨迹

在较高速度的情况下，**损失函数**可设计为：

$$C_s = k_j J_t(\dot{s}(t)) + k_v (v_{target} - \dot{s}_1)^2 + k_a \ddot{s}_1^2 + k_T T \quad (12)$$

该损失函数包含**四个惩罚项**:

- $k_j J_t(\dot{s}(t))$: 惩罚Jerk较大的备选轨迹，保证纵向加减速的平滑性与乘坐舒适度。这里的 $J_t(\dot{s}(t)) = \int_{t_0}^{t_1} (\ddot{s}(\tau))^2 d\tau$
- $k_v (v_{target} - \dot{s}_1)^2$: 惩罚轨迹终点速度 $\dot{s}_1$ 与目标速度 v_{target} 之间的偏差，确保轨迹能达到期望的速度
- $k_a \ddot{s}_1^2$: 惩罚轨迹终点加速度 $\ddot{s}_1$ ，通常期望在轨迹结束时加速度接近0，以保证后续轨迹的平稳衔接
- $k_T T$: 惩罚轨迹总时长 T ，鼓励在安全、舒适前提下，以更短的时间完成规划任务，提高效率
- k_j 、 k_v 、 k_a 和 k_T 是**惩罚项的权重值**，决定了损失函数更加偏向哪一方面的优化

碰撞避免

在完成所有备选轨迹的损失计算后进行一次轨迹检查，检查内容包括:

1. 检查s方向上的速度是否超过设定的最大限速
2. 检查s方向的加速度是否超过设定的最大加速度
3. 检查轨迹的曲率是否超过最大曲率
4. 检查轨迹是否会引起碰撞（事故）

车辆模型和高级控制

自行车模型

自行车模型的假设

1. 忽略车辆在垂直方向的运动，假定车辆是一个二维平面上的运动物体
2. 假设车辆的结构就像自行车一样
 - 前两个轮胎拥有一致的角度和转速等，后面的两个轮胎也是如此，前后轮胎可以各用一个轮胎来描述
 - 前轮控制车辆的转角

不同的参考点

- 看**后轴**：公式简单，速度方向=车身方向
- 看**质心**：公式复杂，速度方向 $\neq$ 车身方向（多了一个 β 角）
质心的速度向量与车身朝向之间会有一个夹角，这个夹角被称为**质心侧偏角（Sideslip Angle, β ）**

运动学自行车模型

四个状态变量描述车辆状态（位置、偏航角、速度）

- x : 当前的 x 坐标
- y : 当前的 y 坐标
- ψ : 当前的偏航角 (用弧度来描述, 逆时针方向为正)
- v : 速度

两个控制输入 (a, δ_f)

- a 车辆的加速度, 踩油门意味着正的加速度, 踩刹车意味着负的加速度
- δ_f 方向盘的转角, 假定方向盘转角就是前轮当前的转角

根据运动学定理，定义了运动学自行车模型中各个状态量的更新公式

$$x_{t+1} = x_t + v_t \cos(\psi_t + \beta) \times dt \tag{13}$$

$$y_{t+1} = y_t + v_t \sin(\psi_t + \beta) \times dt \tag{14}$$

$$\psi_{t+1} = \psi_t + \frac{v_t}{l_r} \sin(\beta) \times dt \tag{15}$$

$$v_{t+1} = v_t + a \times dt \tag{16}$$

其中， dt 表示间隔时间， β 又如下的公式计算可得：

$$\beta = \tan^{-1} \left(\frac{l_r}{l_f + l_r} \tan(\delta_f) \right) \tag{17}$$

自行车模型假定后轮的转角控制输入 $\delta_r = 0$

l_f : 前轮到车辆重心的距离

l_r : 后轮到车辆重心的距离

动力学自行车模型

当车辆以相对高的速度行驶时，车轮的方向并不一定是车辆当前的速度方向。

考虑各种各样的力的作用（纵向力和侧向力）

- 纵向力 *Longitudinal force*：使车辆前后移动的力量
- 侧向力 *Lateral force*：促使车辆横向移动

侧向运动中轮胎是非常重要的力来源。

体现了由frenet坐标系下车身的纵向和侧向速度来推导笛卡尔坐标系下X和Y两个方向上的车辆行驶速度。

PID控制

比例、积分、微分项各项的作用

（设置过大或过小对系统的影响）

比例P

优点：调整系统的开环比例系数，提高系统的稳态精度，减低系统的惰性，加快响应速度

缺点：仅用P控制器，过大的开环比例系数不仅会使系统的超调量增大，而且会使系统稳定裕度变小，甚至不稳定

- 增大P系数会增大无人车向着参考线方向运动的倾向

积分I

优点：消除稳态误差

缺点：积分控制器的加入会影响系统的稳定性，使系统的稳定裕度减小

微分D

使系统的响应速度变快，超调减小，振荡减轻，对动态过程有“预测”作用。

- 增大D系数会增大无人车转角快速变化的“阻力”，从而使得转向更加平缓

临界比例法进行PID控制器参数的整定步骤

PID控制器的参数整定方式和步骤（先P后I最后D）

1. 首先预选择一个足够短的采样周期让系统工作
2. 仅加入比例控制环节，直到系统对输入的阶跃响应出现临界振荡，记下这时的比例放大系数和临界振荡周期
3. 在一定的控制度下通过公式计算得到PID控制器的参数

PID调试一般原则

1. 在输出不振荡时，增大比例增益
2. 在输出不振荡时，减小积分时间常数
3. 在输出不振荡时，增大微分时间常数

PID调试一般步骤

先P后I最后D

1. 确定比例增益P
2. 确定积分时间常数I
3. 确定微分时间常数D
4. 系统空载、带载联调，再对PID参数进行微调，直至满足要求

模型预测控制

模型预测控制三个因素

1. 预测模型

基于以上公式，在给定一个控制指令的情况下，这个预测模型能够根据运动学的规律计算出 dt 时间以后车辆的状态 (x, y, ψ, v) 。

由于自行车模型本身建立在一定的假设前提下的，所以计算出来的状态只是理论上车辆的可能状态。

2. 在线滚动优化

基于模型的控制信号以及相应的输出信号，构造损失函数，并且通过调整控制信号最优化损失函数

3. 反馈校正

当通过最优化方法得到一组控制输出以后，车辆执行控制指令并且继续以一定的频率反馈当前车辆的状态 z_t 。

这个状态会被同时输入到路径规划模块以及MPC模块。


路径规划模块会依据新的车辆状态，结合感知模块的信息以及地图信息重新作出规划，MPC模块则根据新的参考路径和车辆当前状态进行新一轮的预测控制。

相较于PID控制，它解决了哪方面的问题

%%PID是基于“过去和现在”的误差来调节，而MPC是基于“未来”来进行规划%%
一般应用于无人驾驶的**横向控制**（转向控制）

轨迹追踪

非完整动力学约束轨迹追踪。非完整（Nonholonomic）动力学约束就是假设车辆在追踪过程中没有滑移。基于几何追踪的方法——纯追踪



基本原理和分析过程

从自行车模型出发，纯追踪算法以车后轴为切点、车辆纵向车身为切线，通过控制前轮转向角 δ ，使车辆沿着一条经过目标路径点的圆弧行驶。 (g_x, g_y) 是下一个要追踪的路径点，它位于已经规划好的全局路径中，现在需要控制车辆使得车辆的后轴经过该路径点， l_d 表示车辆当前位置（即后轴位置）到目标路径点 (g_x, g_y) 的距离， α 表示目前车身姿态和目标路径点的夹角，根据正弦定理可以推导出：.....

转角控制表达式

$$\text{纯追踪算法控制量 } \delta(t) = \tan^{-1}\left(\frac{2L \sin(\alpha(t))}{l_d}\right)$$

P控制器 $\kappa = \frac{2}{l_d^2} e_l$

纯追踪控制器其实是横向上CTE的P控制器。

l_d : 距离目标路径点的前视距离, 一般将前视距离表示成**车辆纵向速度的线性函数**。

前视距离对追踪效果的影响

纯追踪器的调整是调整系数 k 。通常来说，会使用最大、最小前视距离来约束前视距离，越大的前视距离意味着轨迹的追踪越**平滑**，越小的前视距离会使得追踪更加**精确**，会带来控制的**震荡**。