

模式识别与统计学习

一、统计学习的基础概念与定义

可多模式对象

1. 统计学习/统计机器学习: 计算机基于数据构建概率统计模型并运用模型对数据进行预测和分析的一门学科

目的

总目标: 1. 学习什么样的模型 → 准确
2. 如何学习模型 → 分析 & 预测

2. 三要素: 方法 = 模型 + 策略 + 算法

模型

- ① 概率: 假设空间为条件概率集合 $F = \{P_\theta(Y|X), \theta \in R^n\}$
 参数空间
- ② 非概率: 假设空间为决策函数集合 $F = \{f|Y=f_\theta(X), \theta \in R^n\}$

①: 朴素贝叶斯, Logistic

②: SVM, KNN, Boosting, 决策树, 感知机
 $P(y)P(x|y)$ ← 判别不强

△ 模型

- 生成模型^①: 数据学习联合概率 $P(X, Y)$, 求得 $P(Y|X) = \frac{P(X, Y)}{P(X)}$
 已知者
- 判别模型^②: 数据直接学习决策函数 $f(x)/P(Y|X)$

①: 朴素贝叶斯, 核心在于可以还原出联合概率 (参数量大), θ^T 快收敛, 隐变量

②: KNN, 感知机, Logistic 回归, SVM, 最大熵, Boosting... → 直接 Y

△ 策略: 经验风险最小化 & 结构风险最小化
 防止拟合 + 正则化

A. 损失函数: 一次预测错误的程度
 代价 $L(Y, f(x))$
 期望 $E_p[L(Y, f(x))]$
 风险函数/期望损失

C. 经验风险: $R_{emp}(f) = \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i))$

$$R_{exp}(f) = \int_{X \times Y} L(Y, f(x)) p(x, y) dx dy$$

经验风险最小化
 最大似然估计
 近似 $N \rightarrow \infty =$ 难求
 模型: 条件概率分布

损失函数: 对数损失函数 $KOL(y, y')$



假设空间限制有限

模型复杂度度量

D. 估计风险: $R_{str}(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i)) + \lambda J(f)$ 这个近似合理
少样本时 max 似然估计不准

$\parallel$ 事件概率分布
对数损失函数
复杂度由先验表示

$= \text{MAP 贝叶斯最大后验估计}$
正则项 / 惩罚项
MLE + 正则 (参数的先验)
假设函数均匀

$P(\theta|D) \propto P(D|\theta)P(\theta)$
似然
Data
先验

常用的损失函数

1. 0-1 损失函数 $L(Y, f(x)) = \begin{cases} 1, & Y \neq f(x) \\ 0, & Y = f(x) \end{cases}$
2. 平方损失函数 $L(Y, f(x)) = (Y - f(x))^2 \Rightarrow$ 非负、可微
3. 绝对损失函数 $L(Y, f(x)) = |Y - f(x)| \Rightarrow$ 欧式距离, 1范数
4. 对数损失 / 对数似然函数 $L(Y, P(Y|X)) = -\log P(Y|X)$
 $(\hat{y}_i)^{y_i} (1 - \hat{y}_i)^{(1-y_i)}$

△ 算法: 最优化问题 < 解析
迭代

非概率模型: 决策函数参数空间内损失函数最优化
概率模型: 某种损失函数下最优化

判别模型: 条件概率参数空间中似然函数最大化
生成模型: 类后验概率最大化 (与判别模型, 隐变量 "max")

Logistic 回归: 似然函数 max = 交叉熵损失 min

$$-\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

0-1 分类的对数损失 min
0/1 $y_i=1$ 的概率


3. 基本分类: 监督学习、无监督学习、强化学习

① 监督学习: 从标注数据中学习预测模型, 学习输入到输出映射的统计规律

基本假设: 数据独立同分布; 分类 & 回归



训练集 $T = \{(x_1, y_1), \dots, (x_n, y_n)\}$



① 无监督学习：从无标注数据中学习预测模型，学习数据中的统计规律、潜在结构


core：压缩数据矩阵，找到潜在结构，假设损失最小的压缩得到最本质结构。

纵向结构 $\rightarrow$ 聚类 $\parallel$ X : 样本向量 Z : 样本类别

横向结构 $\rightarrow$ 降维 $\equiv$ 特征组合 X : 样本高维向量 Z : 样本低维向量

横+纵 $\rightarrow$ 概率模型估计 假设含隐式结构的概率模型 X : 观测数据

训练集 $U = \{x_1, x_2, \dots, x_n\}$



$x_1, \dots, x_n$ $z = \hat{g}(x)$ $z_{n+1} = \hat{g}(x_{n+1})$

人造 $\hat{p} = (z|x)$ $z_{n+1} = \arg \max \hat{p}(z|x_{n+1})$

降维 $\hat{p} = (x|z)$ $\hat{p}(x_{n+1}|z_{n+1})$ 学习时学到的参数

学习时学到的参数

由不同高斯分布的 H. G

预测时给定状态，输出预测分布

$$p(x_i, z_i | \theta) = p(z_i | \theta) p(x_i | z_i, \theta)$$

E步：计算变量后验

M步：最大化似然数（训练数据 log 似然的 B）

$$z \rightarrow p(z_i | x_i)$$

$$p_z [\log p(x_i, z_i | \theta) | x_i, \theta^{(t)}]$$

$$\hat{\theta}_{MLE} = \arg \max_{\theta} p(D | \theta)$$


$$\hat{\theta}_{MAP} = \arg \max_{\theta} p(\theta | D) = p(D | \theta) p(\theta)$$

似然 先验



4. 模型评估与选择

过拟合(高方差)



偏差

方差

解决方法

正则化与交叉验证


2'

$$\min \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i)) + \lambda J(f)$$

D. 结构风险

W

正则化

L1范数: $+\lambda \|W\|_1$. 多0解, 稀疏解L2范数: $+\frac{\lambda}{2} \|W\|^2$ 

偏差

ln lambda

方差

泛化能力 = B. 期望损失

$$R_{exp}(f) = E_P[L(Y, f(X))] = \int L(y, f(x)) P(x, y) dx dy$$

取决于训练误差 + 假设空间大小

欠拟合(高偏差)

Bias & Validation

KNN - K ↓ 复杂 ↑

SVM - C ↑ γ ↑

神经网络 - 层数 ↑ 神经元个数 ↑

Logistic - 特征数 ↑ λ ↓

GMM + EM - 簇数 K ↑

PCA - K ↑ (主成分个数)

SVD - r ↑ (保留奇异值个数)

决策树 - 叶节点数 ↑ 深度 ↑

选模型

数据充足

不足

交叉验证

训练集: 找θ

验证集: 选模型 (正则化)

测试集: 评估

训练集

测试集

切分给定数据, 重复使用, 在此基础上反复训练, 测试, 模型选择。

① 简单交叉验证

随机方, 不同条件 (如不同参数数)

下训练, 选测试误差 min 的模型

② S折交叉验证 ✓

S个互不交, 大小同子集

x S折 - - -

③ 留一交叉验证

S = N (数据缺时适用)



分类性能评估指标

① 混淆矩阵

	Predict class		TP	正预测正	FN	正预测负
Actual class	TP	FN	FP	负预测正	TN	负预测负
	FP	TN	准确率: $\frac{TP+TN}{TP+FN+FP+TN}$			

② 精确率: $P = \frac{TP}{TP+FP}$ 预测✓ 实际✓
Precision

召回率: $R = \frac{TP}{TP+FN}$ 实际✓ 预测✓
Recall

F₁值: $\frac{2}{F_1} = \frac{1}{P} + \frac{1}{R} \Rightarrow F_1 = \frac{2TP}{2TP+FP+FN}$
P&R调和均值

监督学习:

4个基础方法: 感知机, KNN, 朴素贝叶斯, 决策树

3个复杂方法: logistic回归, SVM, 提升方法

1个生成方法: 朴素贝叶斯

6个判别方法: 感知机, KNN, 决策树, logistic回归, SVM, 提升方法

3个概率模型: 朴素贝叶斯, 决策树, 高斯混合模型

5个参数化模型: 感知机, 朴素贝叶斯, logistic, k均值, 高斯混合模型

1个单独算法: EM, 介于有监督与无监督间, 用于概率模型参数估计

无监督学习:

4个基础方法: K-Means 聚类, 层次聚类, GMM, PCA 线性降维

1个单独算法: EM 软聚类



感知机

模型：二类分类、判别、参数、基础 $f(x) = \text{sign}(w \cdot x + b)$

策略：极小化误分点到超平面距离

$$-\frac{1}{\|w\|} \sum_{x_i \in M} y_i (w \cdot x_i + b)$$

几何间隔 样本点函数间隔

这里不考虑 $\frac{1}{\|w\|}$, SVM 要考虑!

损失函数 $L(w, b) = - \sum_{x_i \in M} y_i (w \cdot x_i + b)$ 非凸, 求不了解析解

算法：随机梯度下降 $\nabla_w L(w, b) = - \sum_{x_i \in M} y_i x_i$

$\nabla_b L(w, b) = - \sum_{x_i \in M} y_i$

logistic

梯度下降 故随机选一个误分类点

更新

$$w = w + \eta y_i x_i$$

$$b = b + \eta y_i$$

收敛收敛：线性可分 (不可分则震荡)

- 1) 存在 $\|\hat{w}_{opt}\| = 1$ 的超平面 $\hat{w}_{opt} \cdot x = w_{opt} \cdot x + b_{opt} = 0$ 完全分开
且存在 $\gamma > 0$, 对所有 $y_i (\hat{w}_{opt} \cdot x_i) \geq \gamma$
- 2) $R = \max \|x_i\|$, 误分类次数 $k \leq \left(\frac{R}{\gamma}\right)^2 \Rightarrow$ 有限次搜索

有多解, 取决于初值 & 迭代过程中误分类点选择顺序. 想唯一要加分类超平面的约束条件 $\rightarrow$ 线性支持向量机



K近邻

模型: 多类分类、回归、判别

→ 聚类

闵可夫斯基距离

1. 特征之间的度量是 $L_p(X_i, X_j) = \left(\sum_{k=1}^n |x_i^{(k)} - x_j^{(k)}|^p \right)^{1/p}$

2. 训练样本点的位置

 $p \rightarrow \infty$ 时为 $\max_k |x_i^{(k)} - x_j^{(k)}|$ $p=1$ 曼哈顿距离; $p=2$ 欧氏距离; $p=\infty$ 切比雪夫距离K值选择 $< \sqrt{N}$

→ 小: 近似误差 ↓ 估计误差 ↑ 噪声敏感 ...

※ Kd树 (解法: 找包含目标点的叶结点, 再层层回退)

计算: 例 3.1 - 距离计算

(朴素)贝叶斯法

① 模型: 多类分类, 基本假设: 数据独立同分布 (横向), NB 这里不同! 是

给定类别 Y 条件下, 所有特征 X_i 相互独立 $\Rightarrow$ 条件独立性假设② 策略: 学习构建特征与类别的联合概率分布 $\rightarrow$ 最大类后验概率参数: MLE: 用先验 $P(Y=c_k) = \frac{\sum_i I(y_i=c_k)}{N}$ 估计: MAP: $P_{\lambda}(X^{(i)} = a_{ji} | Y=c_k) = \frac{\sum_i I(x_i^{(i)} = a_{ji}, y_i=c_k) + \lambda}{\sum_i I(y_i=c_k) + S_j \lambda}$ 0-1 损失 $\min$ 期望风险 S_j : 第 j 个特征 $X^{(i)}$ 可取值个数, 即 $1/\text{总个数}$ $P(Y|X)$

计算: 例 4.1 & 4.2

MLE

MAP

① 算先验概率及类条件概率

② 据实例计算 $P(Y=c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y=c_k)$ ③ 确定实例 X 的类

MLE MAP

推导: Naive Bayes 学习 $P(X, Y)$ 具体地, 学习 $P(X=x | Y=c_k) = P(X^{(1)}=x^{(1)}, \dots, X^{(n)}=x^{(n)} | Y=c_k)$ 先验概率分布 $P(Y=c_k)$ 条件概率分布 $P(X=x | Y=c_k)$ → $K \prod_{j=1}^n S_j$ 参数级数

条件独立性假设

$$P(X=x|Y=c_k) = P(X^{(1)}=x^{(1)} \dots X^{(n)}=x^{(n)}|Y=c_k) = \prod_{j=1}^n P(X^{(j)}=x^{(j)}|Y=c_k)$$

学习 $P(X, Y)$ 后导出后验概率分布 $P(Y=c_k|X=x)$ 类MAP输出

$$P(Y=c_k|X=x) = \frac{P(X=x|Y=c_k)P(Y=c_k)}{\sum_k P(X=x|Y=c_k)P(Y=c_k)}$$

代入后
即

$$P(Y=c_k|X=x) = \frac{P(Y=c_k) \prod_j P(X^{(j)}=x^{(j)}|Y=c_k)}{\sum_k P(Y=c_k) \prod_j P(X^{(j)}=x^{(j)}|Y=c_k)}$$

朴素 Bayes 法
分类基本公式

朴素 Bayes: $y = f(x) = \underset{c_k}{\operatorname{argmax}} \frac{P(Y=c_k) \prod_j P(X^{(j)}=x^{(j)}|Y=c_k)}{\sum_k P(Y=c_k) \prod_j P(X^{(j)}=x^{(j)}|Y=c_k)}$

分类器

↓ 分母对所有 c_k 相同

$$\text{故 } y = f(x) = \underset{c_k}{\operatorname{argmax}} P(Y=c_k) \prod_j P(X^{(j)}=x^{(j)}|Y=c_k)$$



决策树

1. 模型: 多类分类, 回归, 判别; 训练误差为0, 易过拟合

2. 策略: 损失函数: 对数似然损失 $\Leftrightarrow$ 正则化极大似然估计反例 NP 难, 启发式方法 $\rightarrow$ 次优解: 生成 + 剪枝

3. 算法

① 熵: $H(X) = -\sum_{i=1}^n p_i \log p_i$ 信息量大小, 随机变量不确定性

$$0 \leq H(p) \leq \log n$$

② 条件熵: $H(Y|X) = \sum_{i=1}^n p_i H(Y|X=x_i)$ 已知 X, Y 的不确定性 $\rightarrow$ 条件概率分布对 X 的 E③ 信息增益 $\Leftrightarrow$ 类与特征的互信息 (熵 $H(Y)$ - 条件熵 $H(Y|X)$)

$$g(D, A) = H(D) - H(D|A)$$

④ 信息增益比 $g_R(D, A) = \frac{g(D, A)}{H_A(D)}$

$$H_A(D) = -\sum_{i=1}^n \frac{|D_{iA}|}{|D|} \log_2 \frac{|D_{iA}|}{|D|}, n \text{ 为特征 A 取值数}$$

 $\rightarrow$ 特征 A 有多细碎

$$\textcircled{3} \text{ 经验熵 } H(D) = -\sum_{k=1}^K \frac{|C_k|}{|D|} \log \frac{|C_k|}{|D|}$$

数据熵
多 MLE

$$\textcircled{4} \text{ 经验条件熵 } H(D|A) = \sum_{i=1}^n \frac{|D_{iA}|}{|D|} H(D_i)$$

$$= -\sum_{i=1}^n \frac{|D_{iA}|}{|D|} \sum_{k=1}^K \frac{|D_{ik}|}{|D_{iA}|} \log \frac{|D_{ik}|}{|D_{iA}|}$$

 $\downarrow$
特征每种取值占比 $\rightarrow$ 小组内熵

计算: 信息增益准则: 例 5.2

ID3: 例 5.3

CART: 例 5.4


C4.5: 习题 5.1



⑥ 基尼指数 $Gini(p) = \sum_{k=1}^K p_k(1-p_k) = 1 - \sum_{k=1}^K p_k^2 = 1 - \sum_{k=1}^K \left(\frac{|C_k|}{|D|}\right)^2$
 二分类 $Gini(p) = 2p(1-p)$ 集合D的不确定性

$$Gini(D, A) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2)$$

→ A=a分割后D的不确定性.



二分类中

→ 混乱节点奖励低, 越纯越奖励, 专治高潜力

混乱时K变化越剧烈越易受噪声影响

不用分类误差率: { ← 过拟合

→ 无法反映划分后数据分布



Logistic 回归

1. 模型: 概率*, 判别, 多类分类, 广义线性模型

输入可为连续/离散变量, 输入与输出非线性关系

直接对分类问题建模, 给出类别近似概率 $P(Y|X)$

任意阶可导凸函数

① Logistic 分布 $F(x) = P(X \leq x) = \frac{1}{1 + e^{-\frac{x-\mu}{\sigma}}}$

② 二项 logistic 回归 $P(Y=1|X) = \frac{\exp(w \cdot x + b)}{1 + \exp(w \cdot x + b)} = \sigma(\vec{w}^T \vec{x})$

扁平面 sigmoid 映射 概率

$P(Y=0|X) = \frac{1}{1 + \exp(w \cdot x + b)}$

$\vec{w} = \begin{bmatrix} \vec{w} \\ b \end{bmatrix}, \vec{x} = \begin{bmatrix} \vec{x} \\ 1 \end{bmatrix}$

连续函数 $\log \frac{P(Y=1|X)}{1 - P(Y=1|X)} = w \cdot x$ 即对数几率回归


logistic 函数 (对数几率)

2. 策略: (正则化) MLE: $\prod_{i=1}^N [\pi(x_i)]^{y_i} [1 - \pi(x_i)]^{1-y_i}$

对数似然 $L(w) = \sum_{i=1}^N [y_i \log \frac{\pi(x_i)}{1 - \pi(x_i)} + \log(1 - \pi(x_i))]$

$= \sum_{i=1}^N [y_i (w \cdot x_i) - \log(1 + \exp(w \cdot x_i))]$

logistic 损失 $L_{\log}(z) = \log(1 + \exp(-z)), z = y_i (w \cdot x_i)$



3. 算法: 梯度下降算法

输入: $\{(x_i, y_i)\}_{i=1}^n$, $x_i \in \mathbb{R}^n$, $y_i \in \{0, 1\}$

输出: 最优模型参数 $(w^{(1)}, w^{(2)}, \dots, w^{(n)})^T$; logistic 回归模型

对数似然: $L(w) = \sum_{i=1}^n [y_i(w \cdot x_i) - \log(1 + \exp(w \cdot x_i))]$

梯度下降: $\nabla L(w) = \sum_{i=1}^n [y_i x_i - \frac{x_i \exp(w \cdot x_i)}{1 + \exp(w \cdot x_i)}]$

1. 选取初值 $w^{(0)} = 0$, $k = 0$

2. $L(w^{(k)}) = \sum_{i=1}^n [y_i(w^{(k)} \cdot x_i) - \log(1 + \exp(w^{(k)} \cdot x_i))]$

3. 若 $L(w^{(k)}) - L(w^{(k+1)}) \leq \varepsilon$, 停止 $\Rightarrow w^{(k)}$

否则 $w^{(k+1)} = w^{(k)} + \lambda^{(k)} \nabla L(w^{(k)})$

4. 令 $k = k + 1$

Sigmoid $g(x) = \frac{1}{1+e^{-x}} \in [0, 1] \Rightarrow h_\theta(x) = g(\theta^T x) = \frac{1}{1+e^{-\theta^T x}}$

分类 $\begin{cases} P(y=1|x; \theta) = h_\theta(x) \\ P(y=0|x; \theta) = 1 - h_\theta(x) \end{cases} \Rightarrow P(y|x; \theta) = [h_\theta(x)]^{y_i} [1 - h_\theta(x)]^{1-y_i}$

似然函数: $L(\theta) = \prod_{i=1}^n P(y_i | x_i; \theta) = \prod_{i=1}^n [h_\theta(x)]^{y_i} [1 - h_\theta(x)]^{1-y_i}$

对数似然: $\ln L(\theta) = \sum_{i=1}^n \{y_i \log h_\theta(x) + (1-y_i) \log [1 - h_\theta(x)]\}$

$\times \left(= \sum_{i=1}^n \left\{ y_i \log \frac{h_\theta(x)}{1 - h_\theta(x)} + \log [1 - h_\theta(x)] \right\} \right)$

经验风险: $J(\theta) = -\frac{1}{n} \ln L(\theta)$

$\frac{\partial J(\theta)}{\partial \theta_j} = -\frac{1}{n} \sum_{i=1}^n \left(\frac{y_i}{h_\theta(x)} + \frac{y_i-1}{1-h_\theta(x)} \right) \frac{\partial h_\theta(x)}{\partial \theta_j}$



$$= -\frac{1}{n} \sum_{i=1}^m \left(\frac{y_i}{h_0(x)} + \frac{y_i-1}{1-h_0(x)} \right) x^{(i)} g'(\theta^T x)$$

由 Sigmoid 函数 $f(x) = f(x) [1 - f(x)]$

$$\text{故} = -\frac{1}{n} \sum_{i=1}^m \left(\frac{y_i}{h_0(x)} + \frac{y_i-1}{1-h_0(x)} \right) h_0(x) [1-h_0(x)] x^{(i)}$$

$$= -\frac{1}{n} \sum_{i=1}^m [y_i (1-h_0(x)) + (y_i-1) h_0(x)] x^{(i)}$$

$$= -\frac{1}{n} \sum_{i=1}^m [y_i - h_0(x)] x^{(i)} = \frac{1}{n} \sum_{i=1}^m [h_0(x) - y_i] x^{(i)}$$

$$\text{故更新 } \theta_j = \theta_j - \eta \frac{dJ(\theta)}{d\theta_j} = \theta_j - \frac{\eta}{n} \sum_{i=1}^m [h_0(x) - y_i] x^{(i)}$$



支持向量机

1. 模型：二类分类，分离超平面，核技巧，判别 $f(x) = \text{sign}(w \cdot x + b)$

2. 定义在特征空间上的间隔最大的线性分类器

↓ 核技巧

本质上的非线性分类器

策略

↓
解凸二次规划 (SMD 求解)

↕

线性可分支持向量机 (硬间隔)

正则化的合页损失函数 $\min$

概念：0. 函数间隔：样本点 $\hat{\gamma}_i = y_i (w \cdot x_i + b)$

III 训练数据集 $\hat{\gamma} = \min_{i=1 \sim n} \hat{\gamma}_i$

$$\gamma_i = \frac{\hat{\gamma}_i}{\|w\|}$$

0. 几何间隔：样本点 $\gamma_i = y_i \left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right)$

$$\gamma = \frac{\hat{\gamma}}{\|w\|}$$

III 训练数据集 $\gamma = \min_{i=1 \sim n} \gamma_i \quad (y_i = \pm 1)$

若 w, b 缩放， $\hat{\gamma}$ 变， γ 不变

$$\text{最大间隔分离超平面} \Rightarrow \max_{w, b} \gamma \Rightarrow \frac{\hat{\gamma}}{\|w\|} \Rightarrow \max_{w, b} \frac{1}{\|w\|} \Leftrightarrow \frac{\|w\|^2}{2}$$

$$\text{s.t. } y_i \left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right) \geq \gamma$$

$$\Downarrow$$

$$y_i (w \cdot x_i + b) \geq \hat{\gamma} \quad (\text{令 } =)$$

$$\left\{ \begin{array}{l} \min_{w, b} \frac{1}{2} \|w\|^2 \\ \text{s.t. } y_i (w \cdot x_i + b) - 1 \geq 0 \end{array} \right.$$

0. 支持向量：离分离超平面最近的样本点， $\alpha_j > 0$

$$y_i (w \cdot x_i + b) - 1 = 0$$

0. 间隔边界： $w \cdot x + b = \pm 1$ ，中间无训练点，分离边界



间隔: 长带宽度, 依赖于分离超平面的法向量 $w_i = \frac{2}{\|w\|}$

拉格朗日对偶性

$$\begin{array}{l} \text{原始问题} \\ \text{(构造可行解)} \end{array} \left\{ \begin{array}{l} \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.t.} \left\{ \begin{array}{l} C_i(x) \leq 0 \\ h_j(x) = 0 \end{array} \right. \end{array} \right.$$

$$\begin{array}{l} \text{构造拉格朗日函数} \end{array} \left\{ \begin{array}{l} L(x, \alpha, \beta) = f(x) + \sum_{i=1}^K \alpha_i C_i(x) + \sum_{j=1}^L \beta_j h_j(x) \\ \theta_p(x) = \max_{\alpha, \beta, \alpha_i \geq 0} L(x, \alpha, \beta) \end{array} \right.$$

极小极大问题 (无约束)

$\Leftrightarrow$ 原始问题 (有约束)

$$\min_x \theta_p(x) = \min_x \max_{\alpha, \beta, \alpha_i \geq 0} L(x, \alpha, \beta)$$

$\hookrightarrow$ 最优解都是 $p^* = \min_x \theta_p(x)$

对偶问题

强对偶性

$$\max_{\alpha, \beta, \alpha_i \geq 0} \theta_p(x, \alpha, \beta) = \max_{\alpha, \beta, \alpha_i \geq 0} \min_x L(x, \alpha, \beta) \quad \text{最优解 } d^* = \max_{\alpha, \beta, \alpha_i \geq 0} \theta_p(x, \alpha, \beta)$$

强对偶性: $f(x)$ $C_i(x)$ 凸函数, $h_j(x)$ 仿射函数, $C_i(x)$ 严格可行

$$d^* = p^* = L(x^*, \alpha^*, \beta^*) \quad \text{充要条件: KKT条件}$$

$$\left\{ \begin{array}{l} D^* L(x^*, \alpha^*, \beta^*) = 0 \quad \text{极值条件} \\ \alpha^* C_i(x^*) = 0 \quad \text{互补松弛条件} \\ C_i(x^*) \leq 0 \\ \alpha_i \geq 0 \\ h_j(x^*) = 0 \end{array} \right\} \quad \text{原始条件的约束}$$



原始问题 $\min \frac{1}{2} \|w\|^2$

s.t. $y_i(w \cdot x_i + b) - 1 \geq 0$

对偶: 1. 优化, 易解

2. α 样本数, w 特征维度

3. 引入核函数, 推广非线性

拉格朗日函数 $L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i (w \cdot x_i + b) + \sum_{i=1}^N \alpha_i$

对偶问题 $\min_{w, b} \max_{\alpha} L(w, b, \alpha) \Rightarrow \max_{\alpha} \min_{w, b} L(w, b, \alpha)$

拉格朗日乘子向量 $(\alpha_1, \alpha_2, \dots, \alpha_N)^T$

(1) 求 $\min_{w, b} L(w, b, \alpha)$

$\nabla_w L(w, b, \alpha) = w - \sum_{i=1}^N \alpha_i y_i x_i = 0$

$\nabla_b L(w, b, \alpha) = -\sum_{i=1}^N \alpha_i y_i = 0$

故 $L(w, b, \alpha) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$

(2) 求 $\max_{\alpha} \min_{w, b} L(w, b, \alpha)$

$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \Rightarrow \min \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i$

s.t. $\sum_{i=1}^N \alpha_i y_i = 0$

$\alpha_i \geq 0$

s.t. $\sum_{i=1}^N \alpha_i y_i = 0$

$\alpha_i \geq 0$

选正分量为 $\alpha_j: y_j(w \cdot x_j + b) - 1 = 0$

同重 y_j $b^* = y_i - \sum_{j=1}^N \alpha_j y_j (x_i \cdot x_j)$

$w^* = \sum_{j=1}^N \alpha_j y_j x_j$

分离超平面 $\sum_{j=1}^N \alpha_j^* y_j (x \cdot x_j) + b^* = 0$

分类决策函数

$f(x) = \text{sign}(\sum_{j=1}^N \alpha_j^* y_j (x \cdot x_j) + b^*)$

支持向量



提升方法 (AdaBoost + 提升树)

1. 模型: 二分类, 弱分类器的线性组合, 判别

o AdaBoost: 前向分步加法算法 $\rightarrow$ 基本分类器组成的加法模型

损失函数: 指数函数

$$f(x) = \sum_{m=1}^M \alpha_m G_m(x)$$

$$f(x) = \sum_{m=1}^M \beta_m b(x; \gamma_m)$$

$\downarrow$
 基函数 基函数 基函数
 函数 参数 参数

2. 策略:

$$L(y, f(x)) = \exp[-y f(x)]$$

拟比加法模型的

1. 初始化权重分布 $D_1 = (W_1, \dots, W_N)$ 2. 对 $m=1, 2, \dots, M$, 使 D_{m+1} 成概率分布① 用 D_m 学习弱基本分类器 $\pm 1: G_m(x)$ 决策树

$$\textcircled{2} \text{ 分类误差率 } e_m = \sum_{i=1}^N p_i [G_m(x_i) \neq y_i] = \sum_{i=1}^N W_{mi} I(i)$$

③ 算 G_m 系数

$$\alpha_m = \frac{1}{2} \log \frac{1 - e_m}{e_m}$$

$$\textcircled{4} \text{ 更新 } D_{m+1}, W_{m+1,i} = \frac{W_{mi}}{Z_m} \exp[-\alpha_m y_i G_m(x_i)]$$

$$\text{规范化因子 } Z_m = \sum_{i=1}^N W_{mi} \exp[-\alpha_m y_i G_m(x_i)]$$

3. 基本分类器线性组合 $f(x) = \sum_{m=1}^M \alpha_m G_m(x)$

$$4. \text{ 分类器 } G(x) = \text{sign} \left[\sum_{m=1}^M \alpha_m G_m(x) \right]$$

o Boosting Tree 加法模型 + 决策函数 + 前向分步算法 (平方误差)

优化损失函数 残差 / 负梯度 (GB 梯度提升)



线性支持向量机(软间隔SVM)

解法:

$$\textcircled{1} \text{ 原始问题 } \begin{cases} \min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \\ \text{s.t. } y_i(w \cdot x_i + b) \geq 1 - \xi_i \\ \xi_i \geq 0 \end{cases}$$

Δ 二次规划

w 唯一, b 不唯一, 是区间

$0 < \alpha_j^* < C$ 都有 b

$$L(w, b, \xi, \alpha, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i + \sum_{i=1}^N \alpha_i [1 - \xi_i - y_i(w \cdot x_i + b)] - \sum_{i=1}^N \mu_i \xi_i$$

$$\text{对偶问题 } \max_{\alpha, \mu} \min_{w, b, \xi} L(w, b, \xi, \alpha, \mu)$$

$$\textcircled{1} \text{ 求 } \min_{w, b, \xi} L(w, b, \xi, \alpha, \mu)$$

$$\begin{cases} \nabla_w L(w, b, \xi, \alpha, \mu) = w - \sum_{i=1}^N \alpha_i y_i x_i = 0 \\ \nabla_b L(w, b, \xi, \alpha, \mu) = -\sum_{i=1}^N \alpha_i y_i = 0 \\ \nabla_{\xi_i} L(w, b, \xi, \alpha, \mu) = C - \alpha_i - \mu_i = 0 \end{cases} + \begin{cases} \text{两个互补松弛条件 } \alpha_i^* \dots \rightarrow \\ \mu_i^* - \xi_i^* = 0 \end{cases}$$

$$\min_{w, b, \xi} L(w, b, \xi, \alpha, \mu) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

$$\textcircled{2} \text{ 求 } \max_{\alpha, \mu} \min_{w, b, \xi} L(w, b, \xi, \alpha, \mu) = \max_{\alpha, \mu} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

$$\text{s.t. } \sum_{i=1}^N \alpha_i y_i = 0 \quad \checkmark$$

$$C - \alpha_i - \mu_i = 0$$

$$\alpha_i \geq 0$$

$$\mu_i \geq 0$$

$$\Rightarrow 0 \leq \alpha_i \leq C \quad \checkmark$$

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i \quad b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j) \quad \mu_i^* = C - \alpha_i^*$$

$$\xi_i^* = \begin{cases} 0, & 0 < \alpha_i^* < C \\ 1 - y_i(w^* \cdot x_i + b^*), & \alpha_i^* = C \end{cases}$$

(互补松弛条件)

$$1 - y_i(w^* \cdot x_i + b^*), \alpha_i^* = C$$



分析惩罚参数 C : 平衡间隔最大化, 减少分类错误

$$\alpha_i^* > 0 \quad \left\{ \begin{array}{l} \alpha_i^* < C \quad \text{则 } \xi_i = 0 \quad \text{间隔边界} \\ \alpha_i^* = C \quad \left\{ \begin{array}{l} 0 < \xi_i < 1 \quad \text{分类正确, 间隔边界与拉平面间} \\ \xi_i = 1 \quad \text{支持向量在决策边界上} \\ \xi_i > 1 \quad \text{错误分类, 拉平面误分一侧} \end{array} \right. \end{array} \right.$$

• 合页损失函数

(软间隔 max) 线性支持向量机另一种解释

$$\textcircled{+} \Leftrightarrow \min_{w, b} \sum_{i=1}^n [1 - y_i(w \cdot x_i + b)]_+ + \lambda \|w\|^2 \rightarrow L_2 \text{范数正则化项}$$

$$\text{经验损失(风险)} \quad L[y(w \cdot x + b)] = [1 - y(w \cdot x + b)]_+ \quad (\text{只取正值})$$

// 可证该条件为凸区

取 $\lambda = \frac{1}{2C}$ 则全证

• 技巧: 用非线性变换将输入空间 $\rightarrow$ 特征空间 H

给定的核 $k(x, z)$ H 与映射函数 ϕ 取法可不同

$$k(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$$

• 正定核的必要条件

设 $k: X \times X \rightarrow \mathbb{R}$ 对称函数 $k(x, z)$ 正定核函数; Gram 半正定

$$K = \begin{bmatrix} k(x_1, x_1) & \dots & k(x_1, x_m) \\ \vdots & & \vdots \\ k(x_m, x_1) & \dots & k(x_m, x_m) \end{bmatrix}_{m \times m}$$



聚合聚类 $O(n^3m)$

层次聚类

分裂聚类

聚类

K-means - 中间非层次化 $O(mnk)$

1. 闵可夫斯基距离

2. 马哈拉诺比斯距离: 各特征间相关性 $\uparrow \rightarrow$

$$\text{样本 } X_i \text{ 与 } X_j \text{ 间 } d_{ij} = [(X_i - X_j)^T S^{-1} (X_i - X_j)]^{\frac{1}{2}}$$

为 1 时, 各变量独立且 $G=1 \Rightarrow$ 欧氏距离

$$3. \text{相关系数 } r_{ij} = \frac{\sum_{k=1}^m (X_{ki} - \bar{X}_i)(X_{kj} - \bar{X}_j)}{[\sum_{k=1}^m (X_{ki} - \bar{X}_i)^2 \sum_{k=1}^m (X_{kj} - \bar{X}_j)^2]^{\frac{1}{2}}}$$

$$4. \text{夹角余弦 } s_{ij} = \frac{\sum_{k=1}^m X_{ki} X_{kj}}{[\sum_{k=1}^m X_{ki}^2 \sum_{k=1}^m X_{kj}^2]^{\frac{1}{2}}}$$

$$5. \text{类的直径 } D_G = \max d_{ij}$$

$$\text{类的中心 } \bar{X}_G = \frac{\sum X_i}{n_G}$$

$$\text{类的样本散布矩阵 } A_G = \sum (X_i - \bar{X}_G)(X_i - \bar{X}_G)^T$$

$$\text{类的样本协方差矩阵 } S_G = \frac{1}{m-1} A_G = \frac{1}{m-1} \sum (X_i - \bar{X}_G)(X_i - \bar{X}_G)^T$$

$$6. \text{类间最短距离/单连接 } D_{pq} = \min d_{ij} \rightarrow \text{链}$$

$$\text{类间最长距离/完全连接 } D_{pq} = \max d_{ij} \rightarrow \text{球、紧凑、鲁棒}$$

$$\text{类间中心距离 } D_{pq} = d_{\bar{X}_p \bar{X}_q}$$

$$\text{类间平均距离 } D_{pq} = \frac{\sum \sum d_{ij}}{n_p n_q}$$

$$7. \text{K-means 损失函数/能量 } W(c) = \sum_{i=1}^k \sum_{x \in c_i} \|x_i - x\|^2$$

$\hookrightarrow$ 启发式

计算: 例 14.1 聚合聚类 例 14.2 K-means



SVD $A_{m \times n} = U_{m \times m} \Sigma_{m \times n} V_{n \times n}^T$ (不唯一). 完全SVD

正交: $UU^T = I$; $VV^T = I$; $\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_p)$ $\sigma_1, \sigma_2, \dots, \sigma_p \geq 0$
 $p = \min\{m, n\}$

1) 紧凑SVD: $\text{rank}(A) = r$, $r \leq \min\{m, n\}$. $A = U_r \Sigma_r V_r^T$

2) 截断SVD: $0 < k < r$, $A \approx U_k \Sigma_k V_k^T$

• SVD分解基本定理: 对A构造出SVD各子矩阵, 先设 $m \geq n$

任取A, $A^T A$ 实对称. 特征分解 $V \Lambda V^T$ (正交基, 由特征向量构成)

确定 Σ $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$, $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r > \lambda_{r+1} = \dots = \lambda_n = 0$, $\sigma_i = \sqrt{\lambda_i}$

确定V $\Sigma_r = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$, $V_1 = (v_1, v_2, \dots, v_r)$ $V_2 = (v_{r+1}, \dots, v_n)$

$$A^T A = V \Lambda V^T \text{ 故 } V^T A^T A V = \Lambda = \begin{pmatrix} \Sigma_r^2 & 0 \\ 0 & 0 \end{pmatrix}$$

$$\text{即 } \begin{pmatrix} V_1^T \\ V_2^T \end{pmatrix} A^T A \begin{pmatrix} V_1 \\ V_2 \end{pmatrix} = \begin{bmatrix} V_1^T A^T A V_1 & V_1^T A^T A V_2 \\ V_2^T A^T A V_1 & V_2^T A^T A V_2 \end{bmatrix} = \begin{pmatrix} \Sigma_r^2 & 0 \\ 0 & 0 \end{pmatrix}$$

$$V_1^T A^T A V_1 = \Sigma_r^2 \quad V_2^T A^T A V_1 = 0$$

确定U 令 $U_{m \times r} = A V_1 \Sigma_r^{-1}$

$$U^T U = \Sigma_r^{-1} V_1^T A^T A V_1 \Sigma_r^{-1} = \Sigma_r^{-1} \Sigma_r^2 \Sigma_r^{-1} = I$$

故一定存在 $U_{m \times m} = [U_1 \ U_2]$ 使 $U^T U = U U^T = I$

$$\text{证明 } A = U \Sigma V^T = (U_1 \ U_2) \Sigma \begin{pmatrix} V_1^T \\ V_2^T \end{pmatrix} = U_1 \Sigma_r V_1^T = A V_1 V_1^T = A$$

$x \in \mathbb{R}^n$ 旋转/反射, V^T 缩放, Σ 旋转/反射, U $Ax \in \mathbb{R}^m$

$$\text{性质 1. } A^T A = (U \Sigma V^T)^T (U \Sigma V^T) = V \Sigma^T U^T U \Sigma V^T = V (\Sigma^T \Sigma) V^T$$

$$A A^T = U \Sigma V^T (U \Sigma V^T)^T = U \Sigma V^T V \Sigma^T U^T = U (\Sigma \Sigma^T) U^T$$

V列向量: $A^T A$ 特征向量

U列向量: $A A^T$ 特征向量

奇异值: $A A^T$ 与 $A^T A$ 的 λ



2. $AU_j = \sigma_j U_j, j=1 \sim n$ 右奇异向量与奇异值, 左奇异向量
 $A^T U_j = \sigma_j V_j, j=1 \sim n$ 左奇异向量与奇异值, 右奇异向量
 $= 0, j=n+1 \sim m$

3. $\sigma_1, \sigma_2, \dots, \sigma_n$ 唯一, UV 不唯一

4. $r(A) = r(\Sigma) = \sigma_i \neq 0$ 的个数 (包含重复的)

5. r 个右奇异向量 $V_1, \dots, V_r$ 构成 $R(A^T)$ 标准正交基

输入空间 A 得 $A^T U_j = \sigma_j V_j$ $R(A^T) = \text{col}(A^T) \subset \mathbb{R}^n$
 $\hookrightarrow \mathbb{R}^m \rightarrow \mathbb{R}^n$ 线性变换 且 $V_1, \dots, V_r$ 是 A^T 的标准正交基

② $n-r$ 个右奇异向量 $V_{r+1}, \dots, V_n$ 构成 $N(A)$ 标准正交基

$AV_i = 0, U_i = 0, i=r+1 \sim n$ 输入空间被 A 消除

③ r 个左奇异向量 $U_1, U_2, \dots, U_r$ 构成 $R(A)$ 标准正交基

输出空间 A 可达 $R(A) = \text{col}(A)$ $U_1, \dots, U_r$ 是 A 的标准正交基

④ $m-r$ 个左奇异向量 $U_{r+1}, \dots, U_m$ 构成 $N(A^T)$ 的标准正交基

输出空间 A 无法达到

SVD: 输入 $X \begin{cases} R(A^T) \xrightarrow{V_1 \sim r} \Sigma \xrightarrow{U_1} \text{输出 } AX \end{cases}$
 $\begin{cases} N(A) \xrightarrow{V_{r+1} \sim n} 0 \end{cases}$ $\rightarrow$ 输出 $AX \begin{cases} R(A) \\ N(A^T) \text{ 垂直} \end{cases}$

几何视角: 把复杂的线性变换分解成 2 对 互补 的子空间
 正交

书上例证: ① 确定 V 和 Σ

$A^T A$ 实对称 $\rightarrow$ 特征分解: $V^T (A^T A) V = \Lambda$

$\|Ax\|^2 = x^T A^T A x = \lambda x^T x = \lambda \|x\|^2$

证 $\lambda \geq 0$:

故 $\lambda = \frac{\|Ax\|^2}{\|x\|^2} \geq 0$

假设 V 列排列使 λ 降序排列 $\lambda_1 \geq \dots \geq \lambda_n \geq 0$

$\sigma_j = \sqrt{\lambda_j} \Rightarrow \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r > 0, \lambda_{r+1} = \dots = \lambda_n = 0$

$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0, \sigma_{r+1} = \dots = \sigma_n = 0$



确定 V : $V = [V_1 \ V_2]$ $\Sigma = \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \\ & & & 0 \end{pmatrix}$

$\downarrow$ $\downarrow$
 $V_1 \dots V_r$ $V_{r+1} \dots V_n$
 正交特征向量 0 特征向量

确定 Σ : $\begin{bmatrix} \Sigma & 0 \\ 0 & 0 \end{bmatrix}_{m \times n}$

故知

$$A^T A V_j = 0, j = r+1 \sim n$$

性质 5.2 V_2 列向量 $\Rightarrow N(A^T A) = N(A)$

$\Rightarrow N(A)$ 正交基

$\downarrow$

$$A V_2 = 0$$

V 正交, 故 $I = V V^T = V_1 V_1^T + V_2 V_2^T$

$$A = A I = A V_1 V_1^T + A V_2 V_2^T = A V_1 V_1^T$$

② 确定 U

令 $U_j = \frac{A V_j}{\sigma_j}, j = 1 \sim r$ $U_1 = [u_1 \dots u_r]$

则 $A V_1 = U_1 \Sigma_1$

证 U 正交: $u_i^T u_j = \left(\frac{A V_i}{\sigma_i} \right)^T \left(\frac{A V_j}{\sigma_j} \right) = \frac{1}{\sigma_i \sigma_j} V_i^T A^T A V_j$

$$= \frac{1}{\sigma_i \sigma_j} V_i^T \lambda_j V_j = \frac{\sigma_j}{\sigma_i} V_i^T V_j$$

$$= \delta_{ij} \Rightarrow \text{标准正交基}$$

$\downarrow$ 故知

性质 5.3 $u_1 \dots u_r \Rightarrow R(A) = \text{col}(A)$

$$R(A)^\perp = N(A^T)$$

$\Rightarrow$ 正交基 $u_{r+1}, \dots, u_m \Rightarrow U_2 = [u_{r+1} \dots u_m]$

$$U = [U_1 \ U_2]$$



$$\textcircled{3} U \Sigma V^T = [U_1 \ U_2] \begin{bmatrix} \Sigma & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} V_1^T \\ V_2^T \end{bmatrix}$$

$$= U_1 \Sigma V_1^T = A V_1 V_1^T = A \quad \checkmark$$

计算: Step 1. 求 $A^T A$ 特征值与特征向量 $\Rightarrow V = \begin{bmatrix} \text{特征向量} \\ \text{特征值} \end{bmatrix}$

例 15.5

$$\Sigma = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_r & & \\ & & & 0 & \end{bmatrix}$$

Step 2. 求正交矩阵 $U \Rightarrow R(A)$ 的标准正交基, 前 r

$$U = \begin{bmatrix} | & & | \\ \vdots & & \vdots \\ | & + & | \\ \vdots & & \vdots \\ | & & | \end{bmatrix} \left(\begin{array}{l} r \\ r+1 \\ \vdots \\ m \end{array} \right) \quad \begin{array}{l} U_1 = \frac{A V_1}{\sigma_1} \\ \vdots \\ U_r = \frac{A V_r}{\sigma_r} \end{array} = \begin{bmatrix} \vdots \\ \vdots \\ \vdots \\ \vdots \end{bmatrix}_{m \times 1}$$

Step 3. 求正交矩阵 $U \Rightarrow N(A^T)$ 标准正交基, 后 $m-r$

解 $A^T x = 0$ 出正交基 $U_{r+1} \sim U_m$

• 外积展开式 $A = (U \Sigma V^T) \quad U \Sigma = [\sigma_1 U_1 \sim \sigma_n U_n]$

$$= \sigma_1 U_1 V_1^T + \sigma_2 U_2 V_2^T + \dots + \sigma_n U_n V_n^T \quad V^T = \begin{bmatrix} V_1^T \\ V_2^T \\ \vdots \\ V_n^T \end{bmatrix}$$

$$\begin{bmatrix} U_{11} \\ U_{21} \\ \vdots \\ U_{m1} \end{bmatrix} [V_1 \ V_2 \ \dots \ V_n] = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n & & \\ & & & 0 & \end{bmatrix}_{m \times n}$$

U_k 与 V_k^T 外积

• 弗罗贝尼乌斯范数 $\|A\|_F = \left(\sum_{i=1}^m \sum_{j=1}^n (a_{ij})^2 \right)^{\frac{1}{2}}$

$$\|A\|_F = \|U \Sigma V^T\|_F = \|\Sigma\|_F = (\sigma_1^2 + \sigma_2^2 + \dots + \sigma_n^2)^{\frac{1}{2}} = \sqrt{\text{tr}(A^T A)}$$



矩阵最佳近似存在

定理1: $\|A - X\|_F = \min_{S \in M} \|A - S\|_F$, M 为 $R^{m \times n}$ 中 $r \leq k$ 的矩阵集

$\downarrow$
 X 为 A 在 M 中按欧氏意义下最佳近似

定理2: $\|A - X\|_F = \min_{S \in M} \|A - S\|_F = (\sigma_{k+1}^2 + \sigma_{k+2}^2 + \dots + \sigma_n^2)^{\frac{1}{2}}$

若 $A' = U \Sigma' V^T$, $\Sigma' = \begin{pmatrix} \Sigma_k & 0 \\ 0 & 0 \end{pmatrix}$ 则 $\|A - A'\|_F = \min \|A - S\|_F$

计算: 例 15.6, 习题 15.5

PCA (最大方差/投影距离最小方向) 低维正交空间

$\hookrightarrow$ 方差和: 信息保存

证明:

X 为 m 维随机变量, Σ 为 X 的协方差矩阵, Σ 特征值 $\lambda_1, \dots, \lambda_m$

第 k 主成分: $y_k = \alpha_k^T X = \alpha_{1k} X_1 + \dots + \alpha_{mk} X_m$ $\alpha_1, \dots, \alpha_m$

$$\text{Var}(y_k) = \alpha_k^T \Sigma \alpha_k = \lambda_k$$

$$\} \text{Cov}(y) = \Lambda = \text{diag}(\lambda_1, \dots, \lambda_m) \}$$

样本协方差矩阵: $S_{ij} = \frac{1}{n-1} \sum_{k=1}^n (X_{ik} - \bar{X}_i)(X_{jk} - \bar{X}_j)^T$

样本相关矩阵: $R = [r_{ij}]_{m \times m} = \frac{XX^T}{n-1} \checkmark$

$$r_{ij} = \frac{S_{ij}}{\sqrt{S_{ii} S_{jj}}}$$

样本方差 $\text{Var}(y_i) = \alpha_i^T S \alpha_i$

样本协方差 $\text{Cov}(y_i, y_k) = \alpha_i^T S \alpha_k$

因子载荷 $f(x_i, y_j) = \sqrt{\lambda_j} \alpha_{ij} \checkmark$

贡献率 $V_i = \sum_{j=1}^K \lambda_j \alpha_{ij}^2 \checkmark$



Step 1. 规范化 $X_{ij} = \frac{X_{ij} - \bar{X}_i}{\sqrt{S_{ii}}}$

$$S_{ii} = \frac{1}{n-1} \sum_{j=1}^n (X_{ij} - \bar{X}_i)^2$$

Step 2. 样本相关矩阵 $R = \frac{1}{n-1} X X^T$

↓

求特征值、特征向量

$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_m$

1. 按贡献率求 k

2. 前 k 个特征值对应的单位特征向量

$\alpha_i = (\alpha_{i1}, \alpha_{i2}, \dots, \alpha_{im})^T$

《单位化!》

x_1, x_2 变量

y_1, y_2 主成分

Step 3. 求 k 个样本主成分 $y_i = \alpha_i^T X$ $y_1 = \dots$
 $y_2 = \dots$

Step 4. 求 k 个主成分 y_i 与变量 x_j 的相关系数 (因子荷重)

$$r(x_j, y_i) = \sqrt{\lambda_j} \alpha_{ij}$$

	x_1	x_2
y_1	...	...
y_2	...	...

以及 k 个主成分对变量 x_j 的贡献率

$$V_i = \sum_{j=1}^k \lambda_j \alpha_{ij}^2$$

第一个主成分对 x_1, x_2 的贡献率为 (,)

二个 ...

计算: 例 16.1 习题 16.1



证明: 求第一主成分 $\max_{\alpha_1} \alpha_1^T \Sigma \alpha_1 (= \text{var}(\alpha_1^T X))$
 s.t. $\alpha_1^T \alpha_1 = 1$

故拉格朗日函数为 $L(\alpha_1) = \alpha_1^T \Sigma \alpha_1 - \lambda_1 (\alpha_1^T \alpha_1 - 1)$

$$\nabla L(\alpha_1) = 2\Sigma \alpha_1 - 2\lambda_1 \alpha_1 = 0$$

$$\text{则 } \Sigma \alpha_1 = \lambda_1 \alpha_1$$

故 α_1 为 Σ 的特征向量, λ_1 为 Σ 的特征值

$$\text{Var}(y_1) = \text{var}(\alpha_1^T X) = \alpha_1^T \Sigma \alpha_1 = \alpha_1^T \lambda_1 \alpha_1 = \lambda_1 \alpha_1^T \alpha_1 = \lambda_1$$

故 $\text{Var}(y_1)$ 最大时, λ_1 为 Σ 最大的特征值, α_1 为对应向量。

求第二主成分 $\max_{\alpha_2} \alpha_2^T \Sigma \alpha_2 (= \text{var}(\alpha_2^T X))$
 s.t. $\alpha_2^T \alpha_2 = 1$

$$\alpha_1^T \Sigma \alpha_2 = 0, \alpha_2^T \Sigma \alpha_1 = 0$$

主成分间协方差矩阵

$$\text{Cov}(Y_1, Y_2) = \text{Cov}(\alpha_1^T X, \alpha_2^T X)$$

$$= \alpha_1^T \Sigma \alpha_2$$

$$\text{证: 则 } \alpha_1^T \Sigma \alpha_2 = \alpha_2^T \Sigma \alpha_1 = \alpha_2^T \lambda_1 \alpha_1 = \lambda_1 \alpha_2^T \alpha_1 = \lambda_1 \alpha_1^T \alpha_2 = 0$$

$$\text{故 } \alpha_2^T \alpha_1 = 0, \alpha_1^T \alpha_2 = 0$$

$$L(\alpha_1, \alpha_2) = \alpha_2^T \Sigma \alpha_2 - \lambda_2 (\alpha_2^T \alpha_2 - 1) - \Phi \alpha_2^T \alpha_1$$

$$\nabla_{\alpha_2} L(\alpha_1, \alpha_2) = 2\Sigma \alpha_2 - 2\lambda_2 \alpha_2 - \Phi \alpha_1 = 0$$

$$\text{左乘 } \alpha_1^T \text{ 后: } 2\alpha_1^T \Sigma \alpha_2 - 2\lambda_2 \alpha_1^T \alpha_2 - \Phi \alpha_1^T \alpha_1 = 0$$

$$\text{则 } 0 - 0 - \Phi = 0, \text{ 故 } \Phi = 0$$

$$\text{故 } 2\Sigma \alpha_2 = 2\lambda_2 \alpha_2$$

故 λ_2 为 Σ 特征值, α_2 为对应向量

以上证明中, λ_k 为 Σ 第 k 个特征值, α_k 为对应特征向量

$$\text{即 } \Sigma \alpha_k = \lambda_k \alpha_k, \text{ 矩阵为 } \Sigma A = A \Lambda$$

$$A \text{ 为 } n \times n \text{ 矩阵 } A^T A = A A^T = I, \text{ 故 } A^T \Sigma A = \Lambda, \Sigma = A \Lambda A^T$$



EM算法, 概率模型参数估计

三硬币模型: $P(y|\theta) = \sum_z P(y, z|\theta)$

$$= \sum_z P(z|\theta) P(y|z, \theta)$$

$$= \pi p^y (1-p)^{1-y} + (1-\pi) q^y (1-q)^{1-y}$$

观测数据似然 $P(Y|\theta) = \sum_z P(z|\theta) P(Y|z, \theta)$

$$= \prod_{i=1}^n [\pi p^{y_i} (1-p)^{1-y_i} + (1-\pi) q^{y_i} (1-q)^{1-y_i}]$$

$$\text{MLE: } \hat{\theta} = \arg \max_{\theta} \log P(Y|\theta)$$

无解析解, 迭代求解

$$\theta^{(0)} = (\pi^{(0)}, p^{(0)}, q^{(0)}) \text{ 先选初值}$$

计1次: E步: $\mu_j^{(i+1)} = \frac{\pi^{(i)} (p^{(i)})^{y_j} (1-p^{(i)})^{1-y_j}}{\pi^{(i)} (p^{(i)})^{y_j} (1-p^{(i)})^{1-y_j} + (1-\pi^{(i)}) [q^{(i)}]^{y_j} (1-q^{(i)})^{1-y_j}}$

数据 y_j 来自硬币A的概率

期望
后验分布

M步: 计算参数新估计值

$$\frac{\partial \log}{\partial \pi} = \pi^{(i+1)} = \frac{1}{n} \sum_{j=1}^n \mu_j^{(i+1)}$$

$$\frac{\partial \log}{\partial p} = p^{(i+1)} = \frac{\sum_{j=1}^n \mu_j^{(i+1)} y_j}{\sum_{j=1}^n \mu_j^{(i+1)}}$$

$$\frac{\partial \log}{\partial q} = q^{(i+1)} = \frac{\sum_{j=1}^n [1 - \mu_j^{(i+1)}] y_j}{\sum_{j=1}^n [1 - \mu_j^{(i+1)}]}$$

不同初值可得不同参数估计值



EM 算法

输入: $Y, Z, P(Y, Z|\theta), P(Z|Y, \theta)$

联合分布

条件分布

输出: θ (1) 选初值 $\theta^{(1)}$ 开始迭代(2) E步: $\theta^{(i)}$ 后进行第 1 步

$$Q(\theta, \theta^{(i)}) = E_Z[\log P(Y, Z|\theta) | Y, \theta^{(i)}]$$

对完整数据对数似然的期望

$$= \sum_Z \log P(Y, Z|\theta) P(Z|Y, \theta^{(i)})$$

给定观测数据 Y 和当前参数 $\theta^{(i)}$ 下
隐变量 Z 的条件概率分布

$$(3) M步: \theta^{(i+1)} = \arg \max_{\theta} Q(\theta, \theta^{(i)})$$

目标: 极大化观测/不完整数据 Y 关于 θ 的对数似然

$$L(\theta) = \log P(Y|\theta) = \log \sum_Z P(Y, Z|\theta)$$

$$= \log \left(\sum_Z P(Y|Z, \theta) P(Z|\theta) \right) \rightarrow \text{求对数, 不好求}$$

↓ 迭代

$$L(\theta) - L(\theta^{(i)}) = \log \left[\sum_Z P(Y|Z, \theta) P(Z|\theta) \right] - \log P(Y|\theta^{(i)})$$

利用 Jensen 不等式 $\log(\sum_j \lambda_j y_j) \geq \sum_j \lambda_j \log y_j, \lambda_j \geq 0, \sum \lambda_j = 1$

$$= \log \left[\sum_Z P(Z|Y, \theta^{(i)}) \frac{P(Y|Z, \theta) P(Z|\theta)}{P(Z|Y, \theta^{(i)})} \right] - \log P(Y|\theta^{(i)})$$

$$\geq \sum_Z P(Z|Y, \theta^{(i)}) \log \frac{P(Y|Z, \theta) P(Z|\theta)}{P(Z|Y, \theta^{(i)}) P(Y|\theta^{(i)})}$$

E步:

$$\text{定义 } B(\theta, \theta^{(i)}) = \sum_Z P(Z|Y, \theta^{(i)}) \log \frac{P(Y|Z, \theta) P(Z|\theta)}{P(Z|Y, \theta^{(i)}) P(Y|\theta^{(i)})} + L(\theta^{(i)})$$

ELBO 下界

KOKUYU



$$ELBO: L(\theta) \geq B(\theta, \theta^{(n)}) \quad \text{且有 } L(\theta^{(n)}) = B(\theta^{(n)}, \theta^{(n)})$$

$$\theta^{(n+1)} = \arg \max_{\theta} B(\theta, \theta^{(n)})$$

$$M_3: \theta^{(n+1)} = \arg \max_{\theta} \left(L(\theta^{(n)}) + \sum_{\mathbf{z}} P(\mathbf{z} | Y, \theta^{(n)}) \log \frac{P(Y | \mathbf{z}, \theta) P(\mathbf{z} | \theta)}{P(\mathbf{z} | Y, \theta^{(n)}) P(Y | \theta^{(n)})} \right)$$

最大化

$$= \arg \max_{\theta} \left(\sum_{\mathbf{z}} P(\mathbf{z} | Y, \theta^{(n)}) \log \frac{P(Y | \mathbf{z}, \theta) P(\mathbf{z} | \theta)}{P(\mathbf{z} | Y, \theta^{(n)}) P(Y | \theta^{(n)})} \right)$$

$$= \arg \max_{\theta} \left(\sum_{\mathbf{z}} P(\mathbf{z} | Y, \theta^{(n)}) \log P(Y | \mathbf{z}, \theta) P(\mathbf{z} | \theta) \right)$$

$$= \arg \max_{\theta} \left(\sum_{\mathbf{z}} P(\mathbf{z} | Y, \theta^{(n)}) \log P(Y, \mathbf{z} | \theta) \right)$$

$$= \arg \max_{\theta} E_{\mathbf{z}} [\log P(Y, \mathbf{z} | \theta) | Y, \theta^{(n)}]$$

$$= \arg \max_{\theta} Q(\theta, \theta^{(n)})$$

KL 散度 ≥ 0

$$B(\theta, \theta^{(n)}) = Q(\theta, \theta^{(n)}) + H(P(\mathbf{z} | Y, \theta^{(n)}))$$

$$\text{EM 算法的收敛性} = P(Y | \theta^{(n+1)}) \geq P(Y | \theta^{(n)})$$

$$\text{证明: } P(Y | \theta) = \frac{P(Y, \mathbf{z} | \theta)}{P(\mathbf{z} | \theta)}$$

$$\text{取对: } \log P(Y | \theta) = \log P(Y, \mathbf{z} | \theta) - \log P(\mathbf{z} | \theta)$$

$$\text{则 } Q(\theta, \theta^{(n)}) = \sum_{\mathbf{z}} \log P(Y, \mathbf{z} | \theta) P(\mathbf{z} | Y, \theta^{(n)})$$

$$\text{且 } H(\theta, \theta^{(n)}) = \sum_{\mathbf{z}} \log P(\mathbf{z} | Y, \theta) P(\mathbf{z} | Y, \theta^{(n)})$$

$$\text{则 } \log P(Y | \theta) = Q(\theta, \theta^{(n)}) - H(\theta, \theta^{(n)})$$



$$\log P(Y|\theta^{(i+1)}) - \log P(Y|\theta^{(i)}) \overset{0, \text{好} \neq 0}{=} [Q(\theta^{(i+1)}, \theta^{(i)}) - Q(\theta^{(i)}, \theta^{(i)})] - [H(\theta^{(i+1)}, \theta^{(i)}) - H(\theta^{(i)}, \theta^{(i)})]$$

$$H(\theta^{(i+1)}, \theta^{(i)}) - H(\theta^{(i)}, \theta^{(i)}) = \sum_{\mathbf{z}} \log \frac{P(\mathbf{z}|Y, \theta^{(i+1)})}{P(\mathbf{z}|Y, \theta^{(i)})} P(\mathbf{z}|Y, \theta^{(i)})$$

由 Jensen 不等式: $\log \sum \lambda_j y_j \geq \sum \lambda_j \log y_j, \lambda_j \geq 0 \text{ 且 } \sum \lambda_j = 1$

$$\leq \log \left(\frac{\sum P(\mathbf{z}|Y, \theta^{(i+1)})}{\sum P(\mathbf{z}|Y, \theta^{(i)})} P(\mathbf{z}|Y, \theta^{(i)}) \right) = \log \left[\sum P(\mathbf{z}|Y, \theta^{(i+1)}) \right] = 0$$

故 $\log P(Y|\theta^{(i+1)}) - \log P(Y|\theta^{(i)}) \geq 0$. 证正.

$L(\theta^{(i)})$ 对数似然函数序列. $\theta^{(i)}$ 参数估计序列.

1. $L(\theta) = \log P(Y|\theta)$ 单调增且 $P(Y|\theta)$ 有界 $\Rightarrow$ 收敛.
 2. $Q(\theta, \theta')$ 与 $L(\theta)$ 满足一定条件. $\theta^{(i)} \rightarrow$ 收敛值 θ^*
- θ^* 是 $L(\theta)$ 的驻点, $\downarrow$
 $L(\theta)$ 的驻点.

GMM. 软聚类. 概率, 参数. MLE $\rightarrow$ EM 算法, 生成模型

一个高斯对应一个簇. 共 K 个

每个样本先选一簇. 再从该簇高斯分布中采样

参数 $\left\{ \begin{array}{l} \pi_k, \text{第 } k \text{ 个被选中的概率, } \sum \pi_k = 1 \\ \mu_k, \text{每个 GMM 中心} \\ \Sigma_k, \text{形状} \end{array} \right.$

