

模式识别与统计学习

模式识别与统计学习

概论

统计学习三要素 方法 = 模型 + 策略 + 算法

统计学习方法基本分类

模型评估 (Evaluation) 与选择 (Selection)

正则化

交叉验证 (Cross-validation)

泛化能力 (Generalization ability)

KNN

距离度量

K值的选择

分类决策规则：多数表决规则

算法

线性感知机

贝叶斯方法

模型：训练数据集学习联合概率分布 $P(X, Y)$

策略：将实例分到后验概率最大的类中, 等价于期望风险最小化

信息熵

熵 (*entropy*)

条件熵 $H(Y | X)$

信息增益 *Information gain*

信息增益比

决策树

ID3 (分类) 算法

C4.5 (分类) 算法

剪枝

预剪枝 (*prepruning*)

后剪枝 (*post – pruning*)

代价-复杂度剪枝 (*CART*)

CART算法 (*Classification and Regression Trees*)

分类树: 基尼指数 *Gini Index*

回归树: 平方误差最小化

CART剪枝

随机森林 (Random forests)

提升方法

AdaBoost 算法

前向分步算法

提升树 Boosting tree

梯度提升 gradient boosting, GB

支持向量机

线性可分支持向量机 (硬间隔SVM)

函数间隔和几何间隔

支持向量

线性可分SVM学习算法：最大间隔法

KKT条件

原始问题

对偶算法

线性支持向量机 (软间隔SVM)

原始问题

对偶问题

支持向量

合页损失函数 hinge loss function

核技巧与非线性支持向量机 (kernel-SVM)

核技巧

正定核的充要条件

常用核函数

多项式核函数 (polynomial kernel function)

高斯核函数 (Gaussian kernel function)

字符串核函数 (string kernel function)

EM算法

三硬币模型

策略

Q函数

算法

似然和Q函数的关系 $L(\theta)$ 和 $B(\theta, \theta^{(i)})$

EM算法在高斯混合模型学习中的应用

聚类

概念

闵可夫斯基距离 Minkowski distance

马哈拉诺比斯距离 Mahalanobis distance

相关系数 correlation coefficient

夹角余弦

层次聚类

聚合聚类 agglomerative/自下而上聚类 bottom-up

分裂聚类 divisive/自上而下聚类 top-down

k 均值聚类

策略

算法

支持向量机

线性可分支持向量机 (硬间隔SVM)

函数间隔和几何间隔

支持向量

线性可分支VM学习算法：最大间隔法

KKT条件

原始问题

对偶算法

线性支持向量机 (软间隔SVM)

原始问题

对偶问题

支持向量

合页损失函数 hinge loss function

核技巧与非线性支持向量机 (kernel-SVM)

核技巧

正定核的充要条件

常用核函数

多项式核函数 (polynomial kernel function)

高斯核函数 (Gaussian kernel function)

字符串核函数 (string kernel function)

聚类

概念

闵可夫斯基距离 Minkowski distance

马哈拉诺比斯距离 Mahalanobis distance

相关系数 correlation coefficient

夹角余弦

层次聚类

聚合聚类 agglomerative/自下而上聚类 bottom-up

分裂聚类 divisive/自上而下聚类 top-down

k 均值聚类

策略
算法

奇异值分解

奇异值分解基本定理

紧奇异值分解 compact singular value decomposition

截断奇异值分解 truncated singular value decomposition

矩阵的最优近似

概论

统计学习 (statistical learning) 是关于计算机基于数据构建概率统计模型并运用模型对数据进行预测与分析的一门学科。统计学习也称为统计机器学习 (statistical machine learning)。

统计学	Statistical Learning	机器学习	Machine Learning
Estimation	参数估计	Learning	学习/训练
Classifier	分类器	Hypothesis	假设/模型
Data point	数据点	Example/Instance	样本/实例
Regression	回归(连续)	Supervised learning	监督学习
Classification	分类(离散)	Supervised learning	监督学习
Covariate	自/协/特征变量	Feature	特征
Response	因/响应变量/目标	Label	标签

Machine Learning: A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P , if its performance at tasks in T , as measured by P , improves with experience E .



统计学习三要素 方法 = 模型 + 策略 + 算法

1. 模型：学习模式的集合

非概率模型

假设空间：决策函数的集合

概率模型

假设空间：条件概率的集合

生成模型 Generative model

生成方法直接从数据学习联合概率分布

收敛速度快、隐变量可用

如：朴素[[贝叶斯方法]]、隐马尔科夫模型

判别模型 Discriminative model

判别方法由数据直接学习决策函数 $f(X)$ 或条件概率分布 $P(Y|X)$ 作为预测的模型

准确率高、学习过程简单

如：[[模式识别与统计学习/k-Nearest Neighbours]]、[[线性感知机]]、[[模式识别与统计学习/决策树|决策树]]、[[模式识别与统计学习/Logistic回归模型|Logistic回归模型]]、最大熵模型、[[模式识别与统计学习/支持向量机|支持向量机]]、[[模式识别与统计学习/提升方法|提升方法]]、条件随机场

2. 策略：优化模型的准则

损失函数：一次预测的好坏

0-1损失函数 0-1 loss function

平方损失函数 quadratic loss function

绝对损失函数 absolute loss function

对数损失函数 logarithmic loss function 或对数似然损失函数 loglikelihood loss function

$$L(Y, P(Y|X)) = -\log P(Y|X)$$

风险函数：平均意义下模型预测的好坏，损失函数的期望

$$R_{\text{exp}}(f) = E_P[L(Y, f(X))] = \int L(y, f(x))P(x, y)dxdy$$

经验风险： $\frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i))$

结构风险最小化 structure risk minimization

为防止过拟合提出的策略，等价于正则化 regularization，即加入[[#正则化]]项 regularizer,或惩罚项

penalty term

$$R_{\min}(f) = \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i)) + \lambda J(f)$$

3. 算法：求解得到最优模型

统计学习方法基本分类

1. 监督学习

概念

- 实例 Instance: x

- 特征向量 feature vector: $x = (x^{(1)}, x^{(2)}, \dots, x^{(i)}, \dots, x^{(n)})^T$

- $x^{(i)}$ 与 x_i 不同, 后者表示多个输入变量中的第 i 个

- 输入(特征)空间 feature space

- 样本 sample

- 样本容量: N

- 训练集: $T = [(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)]$

- 输入变量和输出变量

- 假设空间Hypothesis space

监督学习目的是学习一个由输入到输出的映射, 称为模型 *Model*

这样的模型的集合就是假设空间

概率模型: $P(Y|X)$

决策函数(非概率模型): $Y = f(X)$

应用

学习和预测两个阶段

分类问题: 预测类别 (Category/Class)

二分类评价指标: TP-true positive; FN-false negative; FP-false positive; TN-true negative

$$\text{精确率 } P = \frac{TP}{TP+FP}$$

$$\text{召回率 } R = \frac{TP}{TP+FN}$$

$$F1 \text{ 值 } \frac{2}{F_1} = \frac{1}{P} + \frac{1}{R}, F_1 = \frac{2TP}{2TP+FP+FN}$$

回归问题: 预测数值, 表示从输入变量到输出变量之间映射的函数, 回归问题的学习等价于函数拟合学习和标注两个过程

标注问题: 标注 tagging, 结构预测 structure prediction

输入: 观测序列 $x_i = (x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(m)})^T, i = 1, 2, \dots, N$

输出: 标记/状态序列 $y_i = (y_i^{(1)}, y_i^{(2)}, \dots, y_i^{(m)})^T$

模型: 条件概率分布 $P(Y^{(1)}, Y^{(2)}, \dots, Y^{(m)} | X^{(1)}, X^{(2)}, \dots, X^{(m)})$

联合概率分布

假设输入与输出的随机变量 X 和 Y 遵循联合概率分布 $P(X, Y)$

对于学习系统来说, 联合概率分布未知

训练数据和测试数据被看作是依联合概率分布 $P(X, Y)$ 独立同分布 (iid) 产生

2. 无监督学习

使用无标注数据 $U = \{x_1, x_2, \dots, x_N\}$ 学习或训练, 由特征向量组成

假设训练数据集由 N 个样本组成, 每个样本是一个 M 维向量, 训练数据可以由一个矩阵表示, 每一行对应一个特征,

$$\text{每一列对应一个样本 } X = \begin{pmatrix} X_{11} & X_{12} & \cdots & X_{1N} \\ X_{21} & X_{22} & \cdots & X_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ X_{M1} & X_{M2} & \cdots & X_{MN} \end{pmatrix}$$

对给定数据 (矩阵数据) 进行某种“压缩”, 从而找到数据的潜在结构, 假定损失最小的压缩得到的结果就是最本质的结构

三要素

模型: 函数 $z = g_\theta(x)$, 条件概率分布 $P_\theta(z|x)/P_\theta(x|z)$

策略: 目标函数的优化

算法: 迭代算法, 通过迭代达到对目标函数的最优化

应用

聚类 clustering

将样本集合中相似的样本 (实例) 分配到相同的类

样本: 欧氏空间中的向量

类别: 从数据中自动发现, 类别个数给定

分类

硬聚类 hard clustering 一个样本只能属于一个类 $z_i = g_\theta(x_i), i = 1, 2, \dots, N$

软聚类 soft clustering 一个样本可以属于多个类 $P_\theta(z_i|x_i), i = 1, 2, \dots, N$

降维 dimensionality reduction: 降维要保证样本中的信息损失最小, 二维新特征由原始特征定义

3. 强化学习: 通过与环境交互、从反馈中学习策略, 马尔可夫决策过程是状态、奖励、动作序列上的随机过程, 由五元组 $\langle S, A, P, r, \gamma \rangle$ 组成

1. S 是有限状态 state 的集合
2. A 是有限动作 action 的集合
3. P 是状态转移概率 transition, probability 函数
4. r 是奖励函数 reward function
5. γ 是衰减系数 discount factor $\gamma \in [0, 1]$

4. 半监督学习: 利用大量未标注数据的信息, 辅助少量标注数据, 进行监督学习, 成本低

5. 主动学习: 机器主动给出实例, 教师进行标注, 利用标注数据学习预测模型

6. 其他分类

按算法

在线学习 online learning: 数据按顺序一条一条到来

批量学习 batch learning: 一次性拿到全部训练集

按技巧

核方法 kernel method

将线性模型学习方法扩展到非线性模型的学习, 直接定义核函数, 即映射之后在特征空间的内积

贝叶斯学习 Bayesian learning

模型评估 (Evaluation) 与选择 (Selection)

正则化


一般形式: $\min_{f \in \mathcal{F}} \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i)) + \lambda J(f)$

L1 正则化: $L(w) = \frac{1}{2} \sum_{i=1}^N (f(x_i, w) - y_i)^2 + \lambda \|w\|_1$

易获得“稀疏”解: 模型系数拥有更多的0分量/更少的非0分量

L2 正则化: $L(w) = \frac{1}{2} \sum_{i=1}^N (f(x_i, w) - y_i)^2 + \frac{1}{2} \|w\|^2$

偏差 (bias) - 方差 (variance) 权衡



交叉验证 (Cross-validation)

概念

训练集 `training set` R_{emp} 用于训练模型

验证集 `validation set` R_v 用于模型选择

测试集 `test set` R_{test} 用于最终对学习方法的评估

分类

简单交叉验证

S折交叉验证

留一交叉验证 ($S = N$, N 为样本容量)

泛化能力 (Generalization ability)

泛化误差 `generalization error` $R_{exp}(f) = E_P[L(Y, f(X))] = \int L(y, f(x))P(x, y)dxdy$

样本容量增加, 泛化误差趋于0

假设空间容量越大, 泛化误差越大 (脑洞大)

二分类问题


当假设空间是有限个函数的集合: $F = \{f_1, f_2, \dots, f_d\}$, 对任意一个函数 f , 至少以概率 $1 - \delta$

$$R(f) \leq R(f) + \varepsilon(d, N, \delta)$$

$$\varepsilon(d, N, \delta) = \sqrt{\frac{1}{2N} (\log d + \log \frac{1}{\delta})}$$

KNN

距离度量



- L_p 距离: $L_p(x_i, x_j) = \left(\sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|^p \right)^{\frac{1}{p}}$
- 欧氏距离 $p = 2$: $L_2(x_i, x_j) = \left(\sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|^2 \right)^{\frac{1}{2}}$
- 曼哈顿距离 $p = 1$: $L_1(x_i, x_j) = \sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|$
- 切比雪夫距离 $p \rightarrow \infty$: $L_\infty(x_i, x_j) = \max_l |x_i^{(l)} - x_j^{(l)}|$
- 马氏距离 *Mahalanobis Distance*: $MD(x, y) = \sqrt{(x - y)^\top \Sigma^{-1} (x - y)}$, $\Sigma_{ij} = cov(x_i, x_j)$ 考虑到各种特性之间的联系, 可以消除样本间的相关性, 广泛用于分类和聚类分析

K值的选择

小:

近似误差 (approximation error) 减小, 估计误差 (estimation error) 增大

噪声敏感

整体模型复杂, 易过拟合

大

“学习”的估计误差减少, 近似误差增大

模型简单

交叉验证

模型准确率随k值的变化非单调

K 一般低于训练集样本容量的平方根

经验上, k值一般不超过20

分类决策规则：多数表决规则

多数表决规则

0-1损失函数下的经验风险最小化

测试样本类别的最大后验估计

决策边界分段线性 *piece - wiselinear*

泛化误差上界：最近邻分类器的泛化误差率不超过贝叶斯最优分类器错误率的两倍, k越大越好

算法

线性搜索：时间复杂度 $O(dN)$, d 为特征空间维度, N 为训练样本数

kd 树：数据预结构化，每个结点对应于一个 k 维超矩形区域

应用

特征向量维度不高 (< 20)

高维度的问题, 球树 *ball tree* 效率更高

复杂度

时间复杂度: $O(\log N)$, 最坏情况时间复杂度 $O(N)$

训练实例维度 $\gg$ 空间维度

构造：对深度为 j 的结点, 选择 $x^{(l)}$ 为切分的坐标轴, $l = j(\bmod k) + 1$

步骤

寻找当前最近点：从根节点出发找出包含目标点的子节点

回溯与迭代：以目标点和当前最近点的距离，沿树根部回溯与迭代

线性感知机

R^n 空间中的超平面方程: $w \cdot x + b = 0$

超平面法向量: w , 设 x_1, x_2 为超平面上任意两点, $w \cdot (x_1 - x_2) = 0$

点到超平面几何距离: $d = \frac{|w \cdot x + b|}{\|w\|}$

线性二分类模型

模型参数

权值向量 w

偏置 b

内积 $w \cdot x$

学习策略

损失函数: $L(w, b) = - \sum_{x_i \in M} y_i (w \cdot x_i + b)$, M 为误分类点的数目

误分类点到超平面的总距离: $\sum_{x_i \in M} \frac{-y_i (w \cdot x_i + b)}{\|w\|}$

学习算法: 随机梯度下降法 **Stochastic gradient descent, SGD**

原始形式: $f(x) = \text{sign}(w \cdot x + b)$

损失函数 L 的梯度

$$\nabla_w L(w, b) = - \sum_{x_i \in M} y_i x_i$$

$$\nabla_b L(w, b) = - \sum_{x_i \in M} y_i$$

随机选取一个误分类点 x_i 更新, 迭代, 直至训练集中没有误分类点

$$w \leftarrow w + \eta y_i x_i$$

$$b \leftarrow b + \eta y_i$$

e.g. 最终得到分离超平面 $x^{(1)} + x^{(2)} - 3 = 0$, 感知机模型 $f(x) = \text{sign}(x^{(1)} + x^{(2)} - 3)$

对偶形式: $f(x) = \text{sign}\left(\sum_j \alpha_j y_j x_j \cdot x + b\right)$, $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_n)^\top$

将 w 和 b 表示为实例 x_i 和标记 y_i 的线性组合的形式, 通过求解其系数, 而求得 w 和 b

$$\bullet y_i \left(\sum_j \alpha_j y_j x_j \cdot x_i + b \right) \leq 0$$

$$\alpha_i \leftarrow \alpha_i + \eta$$

$$b \leftarrow b + \eta y_i$$

Gram 矩阵: $G = [x_i \cdot x_j]_{N \times M}$

通过SGD对误分类点更新 n 次系数 w 和 b :

$$\begin{array}{ccc} w \leftarrow w + \eta y_i x_i & \xrightarrow[\text{最后学习到的 } w, b]{(\alpha_i = n_i \eta)} & w = w_0 + \sum_{i=1}^N \alpha_i y_i x_i \\ b \leftarrow b + \eta y_i & & b = b_0 + \sum_{i=1}^N \alpha_i y_i \end{array}$$

收敛性定理：经过有限次迭代可以得到一个将训练数据集完全正确划分的分离超平面及感知机模型

贝叶斯方法

独立同分布 *independent and identically distributed, i.i.d.*, $X_1, \dots, X_n \sim P$

协方差 *Covariance*: $\text{Cov}(X, Y) = \mathbb{E}[(X - \mu_x)(Y - \mu_y)] = \mathbb{E}[XY] - \mu_x \mu_y$

相关性 *Correlation*: $\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_x \sigma_y}$, $-1 \leq \rho(X, Y) \leq 1$

全方差公式: $\text{Var}(Y) = \mathbb{E}[\text{Var}(Y | X)] + \text{Var}(\mathbb{E}[Y | X])$

贝叶斯定理, 对参数 θ 进行估计:

$$P(\theta | \text{Data}) = \frac{P(\text{Data} | \theta) \cdot P(\theta)}{P(\text{Data})} \quad (1)$$

- $P(\theta | \text{Data})$: 后验概率。在观测到数据后, 参数 θ 的概率分布。
- $P(\text{Data} | \theta)$: 似然。在参数 θ 已知的情况下, 观测到当前数据的概率。
- $P(\theta)$: 先验概率。在观测数据之前, 我们对参数 θ 的信念或假设。
- $P(\text{Data})$: 边缘似然, 在这里是归一化常数。

模型: 训练数据集学习联合概率分布 $P(X, Y)$

先验概率分布: $P(Y = c_k)$, $k = 1, 2, \dots, K$

类条件概率分布: $P(X = x | Y = c_k) = P(X^{(1)} = x^{(1)}, \dots, X^{(n)} = x^{(n)} | Y = c_k)$

朴素贝叶斯分类器: $y = \arg \max_{c_k} P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c_k)$

策略: 将实例分到后验概率最大的类中, 等价于期望风险最小化

$h_{\text{nb}}(\mathbf{x}) = \arg \max_{c \in \mathcal{Y}} P(c) \prod_{i=1}^d P(x_i | c)$

参数估计 — 概率模型训练 (学习):

频率派 *M. L. E.*: 极大似然估计

先验概率 $P(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k)}{N}$, $k = 1, 2, \dots, K$

贝叶斯派 *M. A. P.*: 解决训练样本不充分时分类偏差

先验概率的贝叶斯估计: $P_\lambda(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k) + \lambda}{N + K\lambda}$

类条件概率的贝叶斯估计: $P_\lambda(X^{(j)} = a_{jl} | Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k) + \lambda}{\sum_{i=1}^N I(y_i = c_k) + S_j \lambda}$

$\lambda = 1$ 为拉普拉斯平滑; $\lambda = 0$ 为极大似然估计 (*MLE*)

S_j 是第 j 个特征 $X^{(j)}$ 的可取值个数, 即 l 的可取值个数

信息熵

熵 (*entropy*)

信息量大小的度量, 即表示随机变量不确定性的度量。

事件 a_i 的信息量 $I(a_i) = \log_2 \frac{1}{p(a_i)}$

n 个互不相容的事件 $a_1, a_2, a_3, \dots, a_n$, 平均的信息量(熵)

$I(a_1, a_2, \dots, a_n) = \sum_{i=1}^n I(a_i) = \sum_{i=1}^n p(a_i) \log_2 \frac{1}{p(a_i)}$

熵能达到的最大值: $0 \leq H(p) \leq \log n$

单位

以2为底: 比特 (*bit*)

以e为底(自然对数): 纳特 (*nat*)

条件熵 $H(Y | X)$

在已知随机变量 X 的条件下随机变量 Y 的不确定性,定义为给定 X 条件下 Y 的条件概率分布的熵对 X 的数学期望:

$$H(Y|X) = \sum_{i=1}^n p_i H(Y|X = x_i)$$

经验熵 (empirical entropy) 和 **经验条件熵 (empirical conditional entropy)**: 熵和条件熵中的概率由数据估计 (特别是极大似然估计) 得到

互信息 (mutual information): 熵 $H(Y)$ 与条件熵 $H(Y|X)$ 之差, 决策树学习中的信息增益等价于训练数据集中类与特征的互信息

信息增益 *Information gain*

特征A对训练数据集D的信息增益, $g(D, A)$, 定义为集合D的经验熵 $H(D)$ 与特征A给定条件下D的经验条件熵 $H(D|A)$ 之差, 表示得知特征A的信息而使得不确定性减少的程度. $g(D, A) = H(D) - H(D|A)$ 已知: 训练数据集 D 和特征 A

- 数据集 D 的经验熵 $H(D) = - \sum_{k=1}^K \frac{|C_k|}{|D|} \log_2 \frac{|C_k|}{|D|}$
- 特征A对数据集D的经验条件熵 $H(D|A) = \sum_{i=1}^n \frac{|D_i|}{|D|} H(D_i) = - \sum_{i=1}^n \frac{|D_i|}{|D|} \sum_{k=1}^K \frac{|D_{ik}|}{|D_i|} \log_2 \frac{|D_{ik}|}{|D_i|}$
- 信息增益 $g(D, A) = H(D) - H(D|A)$

信息增益比

以信息增益作为划分训练数据集的特征, 存在**偏向于选择取值较多的特征**的问题, 故校正, n 是特征 A 取值的个数

$$g_R(D, A) = \frac{g(D, A)}{H_A(D)}, H_A(D) = - \sum_{i=1}^n \frac{|D_i|}{|D|} \log_2 \frac{|D_i|}{|D|}$$

决策树

可以做到训练误差为0, 容易出现过拟合

模型: 首先对训练数据进行处理, 利用**归纳算法**生成可读的规则和决策树

If-then 规则: 互斥且完备

条件概率分布: 将特征空间划分为互不相交的单元 (*cell*) 或区域 (*region*), 并在每个单元定义一个类的概率分布, 决策树的一条路径对应于划分中的一个单元

CLS (Concept Learning System) 算法: 自顶向下、递归、贪心的数据划分过程, 通过反复选择“最佳”特征来分裂数据集, 直到每个子集都“纯净”。

学习: 从训练数据集中归纳出一组分类规则, 与训练数据集不相矛盾的决策树, 假设空间有无穷多个概率模型

策略: **最小化损失函数**

从所有可能决策树中选择最优决策树是NP完全问题, 通常采用**启发式方法**, 生成**次优解 (Sub-optimal)**

特征选择: **递归选择最优特征**

生成: 对应特征空间划分, 直到所有训练子集被基本正确分类

剪枝: 避免**过拟合**, 具有更好泛化能力

ID3 (分类) 算法

使用**信息增益**选择测试属性

以[[模式识别与统计学习/信息熵|信息熵]]为度量, 用于决策树结点的属性选择, 每次优先选取信息量最多的属性, 亦即使熵值变为最小的属性, 以构造一颗熵值下降最快的决策树, 到叶子节点处的熵值为0 (不存在矛盾样本情况下)

ID	天气 (Outlook)	外出 (Play)
D1	晴 (Sunny)	否 (No)
D2	晴 (Sunny)	否 (No)
D3	阴 (Overcast)	是 (Yes)
D4	雨 (Rain)	是 (Yes)
D5	雨 (Rain)	否 (No)

计算数据集D的经验熵 $H(D)$

- 数据集D总数 $|D| = 5$ 。
- 类别 C_k 有2个：是 (C_1), 否 (C_2)。
- $|C_1|$ (是) = 2, $|C_2|$ (否) = 3。

$$H(D) = - \sum_{k=1}^2 \frac{|C_k|}{|D|} \log_2 \frac{|C_k|}{|D|}$$

$$H(D) = -(\frac{2}{5} \log_2 \frac{2}{5} + \frac{3}{5} \log_2 \frac{3}{5})$$

$$H(D) \approx 0.971$$

1. ID3 算法 (信息增益)

目标：计算 $g(D, A) = H(D) - H(D|A)$ ，选择增益最大的特征。

A. 对于特征 A = 天气 (Outlook)

- 特征“天气”有3个取值： D_1 =晴, D_2 =阴, D_3 =雨。
- $|D_1| = 2$ (2个否), $|D_2| = 1$ (1个是), $|D_3| = 2$ (1个是, 1个否)。

1. 计算各分支的熵 $H(D_i)$:

$$H(D_1, \text{晴}) = -(\frac{0}{2} \log_2 \frac{0}{2} + \frac{2}{2} \log_2 \frac{2}{2}) = 0$$

$$H(D_2, \text{阴}) = -(\frac{1}{1} \log_2 \frac{1}{1} + \frac{0}{1} \log_2 \frac{0}{1}) = 0$$

$$H(D_3, \text{雨}) = -(\frac{1}{2} \log_2 \frac{1}{2} + \frac{1}{2} \log_2 \frac{1}{2}) = 1$$

2. 计算条件熵 $H(D|A)$:

$$H(D|\text{天气}) = \sum_{i=1}^3 \frac{|D_i|}{|D|} H(D_i) = \frac{2}{5} H(D_1) + \frac{1}{5} H(D_2) + \frac{2}{5} H(D_3) = \frac{2}{5}(0) + \frac{1}{5}(0) + \frac{2}{5}(1) = 0.4$$

3. 计算信息增益 $g(D, A)$:

$$g(D, \text{天气}) = H(D) - H(D|\text{天气}) = 0.971 - 0.4 = 0.571$$

B. 对于特征 A = 编号 (ID)

- 特征“编号”有5个取值，1个取值对应1条记录，每个分支都是纯的。
- $|D_1| = 1$ (1否), $|D_2| = 1$ (1否), $|D_3| = 1$ (1是), ...

1. 计算各分支的熵 $H(D_i)$:

$$\circ H(D_1) = 0, H(D_2) = 0, H(D_3) = 0, H(D_4) = 0, H(D_5) = 0$$

2. 计算条件熵 $H(D|A)$:

$$\circ H(D|\text{编号}) = \sum_{i=1}^5 \frac{|D_i|}{|D|} H(D_i) = \frac{1}{5}(0) \times 5 = 0$$

3. 计算信息增益 $g(D, A)$:

$$\circ g(D, \text{编号}) = H(D) - H(D|\text{编号}) = 0.971 - 0 = 0.971$$

ID3 决策

比较信息增益： $g(D, \text{编号}) = 0.971 > g(D, \text{天气}) = 0.571$ 。

ID3算法选择“编号 (ID)”作为最优特征。过拟合，毫无泛化能力。

2. C4.5 算法 (信息增益比)

目标：计算 $g_R(D, A) = \frac{g(D, A)}{H_A(D)}$ ，选择增益比最大的特征。

我们已经从ID3的计算中得到了信息增益 $g(D, A)$ ，现在只需计算分母——特征A的熵 $H_A(D)$ (也称分裂信息 Split Information)。

A. 对于特征 A = 天气 (Outlook)

$$g(D, \text{天气}) = 0.571 \text{ (已知)}$$

$$H_{\text{天气}}(D) = -\sum_{i=1}^3 \frac{|D_i|}{|D|} \log_2 \frac{|D_i|}{|D|} = -(\frac{2}{5} \log_2 \frac{2}{5} + \frac{1}{5} \log_2 \frac{1}{5} + \frac{2}{5} \log_2 \frac{2}{5}) \approx 1.522$$

$$\text{信息增益比: } g_R(D, \text{天气}) = \frac{0.571}{1.522} \approx 0.375$$

B. 对于特征 A = 编号 (ID)

$$g(D, \text{编号}) = 0.971 \text{ (已知)}$$

$$H_{\text{编号}}(D) = -\sum_{i=1}^5 \frac{|D_i|}{|D|} \log_2 \frac{|D_i|}{|D|} = -(\frac{1}{5} \log_2 \frac{1}{5}) \times 5 = -\log_2(0.2) \approx 2.322$$

$$\text{信息增益比: } g_R(D, \text{编号}) = \frac{0.971}{2.322} \approx 0.418$$

C4.5 (分类) 算法

将ID3算法中“选择信息增益最大的特征”改为“选择信息增益比最大的特征”，即得**C4.5 (分类) 算法**

剪枝

预剪枝 (prepruning)

自上而下: 在决策树生成过程中, 对每个结点在划分前先进行估计

若当前结点的划分不能带来决策树泛化性能提升, 则停止划分, 并标记当前结点为叶结点, 限定决策树的深度/设定一个阈值 (回顾: ID3)

后剪枝 (post - pruning)

从训练集先生成一棵完整的决策树, 自底而上地考察非叶结点, 若将该结点对应的子树替换为叶结点能带来决策树泛化性能提升, 则将该子树替换为叶结点。

代价-复杂度剪枝 (CART)

通过极小化决策树整体的损失函数或代价函数来实现

- 设树 T 的叶结点个数为 $|T|$, t 是树 T 的叶结点, 该叶结点有 N_t 个样本点, 其中 k 类的样本点有 N_{tk} 个, $k = 1, 2, \dots, K$
- 损失函数如下, 其中 $\alpha \geq 0$ 为参数, $H_t(T)$ 为叶结点 t 上的经验熵

$$C_\alpha(T) = C(T) + \alpha|T|$$

$$C(T) = \sum_{t=1}^{|T|} N_t H_t(T) = -\sum_{t=1}^{|T|} \sum_{k=1}^K N_{tk} \log \frac{N_{tk}}{N_t} \quad (2)$$

$$H_t(T) = -\sum_k \frac{N_{tk}}{N_t} \log \frac{N_{tk}}{N_t}$$

CART算法 (Classification and Regression Trees)

分类树: 基尼指数 *Gini Index*

Gini(D) 反映了从数据集 D 中随机抽取到两个类别标记不一致的样本的概率, 用这个选择最优特征, 同时决定该特征的最优二值切分点

$$Gini(D) = 1 - \sum_k \left(\frac{|C_k|}{|D|} \right)^2$$

在特征 \$A\$ 条件下集合 \$D\$ 的基尼指数为

$$Gini(D, A) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2) \quad (3)$$

输入: 训练数据集 \$D\$, 停止计算条件

输出: CART决策树

从根节点开始, 递归对每个结点操作, 构建二叉决策树:

1. 设结点数据集为 \$D\$, 对每个特征 \$A\$, 对其每个值 \$a\$, 根据样本点对 \$A = a\$ 的测试为“是”或“否”, 将 \$D\$ 分为 \$D_1, D_2\$, 计算 \$A = a\$ 的基尼指数
2. 在所有的特征 \$A\$ 以及所有可能的切分点 \$a\$ 中, 选择基尼指数最小的特征和切分点, 将数据集分配到两个子结点中
3. 对两个子结点递归调用1, 2步骤, 直至满足停止条件
4. 生成CART树

回归树: 平方误差最小化

在训练数据集所在的输入空间中, 递归地将每个区域划分为两个子区域并决定每个子区域上的输出值, 构建二叉决策树:

(1) 选择最优切分变量 \$j\$ 与切分点 \$s\$, 求解达到最小值的对 \$(j, s)\$

$$\min_{j,s} \left[\min_{c_1} \sum_{x_i \in R_1(j,s)} (y_i - c_1)^2 + \min_{c_2} \sum_{x_i \in R_2(j,s)} (y_i - c_2)^2 \right] \quad (4)$$

(2) 用选定的对 \$(j, s)\$ 划分区域并决定相应的输出值:

$$R_1(j, s) = \{x | x^{(j)} \leq s\}, R_2(j, s) = \{x | x^{(j)} > s\} \quad (5)$$

$$\hat{c}_m = \frac{1}{N_m} \sum_{x_i \in R_m(j,s)} y_i, \quad x \in R_m, \quad m = 1, 2 \quad (6)$$

(3) 继续对两个子区域调用步骤(1), (2) 直至满足停止条件 (4) 将输入空间划分为 \$M\$ 个区域 \$R_1, R_2, \dots, R_M\$, 生成决策树:

$$f(x) = \sum_{m=1}^M \hat{c}_m I(x \in R_m) \quad (7)$$

CART剪枝

1. 从生成算法产生的决策树 \$T_0\$ 底端开始不断剪枝, 直到 \$T_0\$ 的根结点, 形成子树序列 \$\{T_0, T_1, \dots, T_n\}\$

计算子树的损失函数: \$C_\alpha(T) = C(T) + \alpha|T|\$

对固定的 \$\alpha\$ 一定存在损失函数最小的子树, 表示为 \$T_\alpha\$

◦ \$\alpha\$ 变大时, 最优子树 \$T_\alpha\$ 偏小

◦ \$\alpha = 0\$ 时, 整体树 \$T\$ 最优; \$\alpha\$ 趋近无穷大, 单结点最优

将 \$\alpha\$ 从小增大, \$0 = \alpha_0 < \alpha_1 < \dots < \alpha_n < +\infty\$, 对应最优子树序列 \$\{T_0, T_1, \dots, T_n\}\$

\$T_t\$ 与 \$t\$ 有相同损失函数值, 但 \$t\$ 结点更少, 所以剪枝 \$T_t\$: \$\alpha = \frac{C(t)-C(T_t)}{|T_t|-1}\$

对 \$T_0\$ 中每个内部结点 \$t\$, 计算: \$g(t) = \frac{C(t)-C(T_t)}{|T_t|-1}\$

在 \$T_0\$ 中剪去 \$g(t)\$ 最小的 \$T_t\$, 将得到的子树作为 \$T_1\$, 同时将最小的 \$g(t)\$ 设为 \$\alpha_1, T_1\$ 为区间 \$[\alpha_1, \alpha_2)\$ 的最优子树

如此剪枝下去, 直到根节点, 不断增加 \$\alpha\$ 的值, 产生新的区间

2. 通过交叉验证法在独立的验证数据集上对子树序列进行测试, 从中选择最优子树

利用独立的验证数据集, 测试子树序列中各子树的平方误差/基尼指数的值, 值最小的决策树就是最优决策树

输入: CART算法生成的决策树 \$T_0\$

输出: 最优决策树 T_α

(1) 设 $k = 0, T = T_0$

(2) 设 $\alpha = +\infty$

(3) 自下而上地对各内部结点 t 计算 $C_{T_t}, |T_t|$ 及 $g(t) = \frac{C(t) - C(T_t)}{|T_t| - 1}$, $\alpha = \min(\alpha, g(t))$ (4) 对 $g(t) = \alpha$ 的内部结点进行剪枝, 并对叶结点以多数表决法确定类, 得到树 T

(5) $k = k + 1, \alpha_k = \alpha, T_k = T$

(6) 如果 T_k 不是由根结点及两个叶结点构成的数, 回到步骤(2); 否则, 令 $T_k = T_n$

(7) 采用交叉验证法在子树序列 $T_0, T_1, \dots, T_n$ 中选取最优子树 T_α

随机森林 (Random forests)

集成学习 (Ensemble learning), 或基于委员会的学习 (committee-based learning) 通过构建并结合多个学习器来完成学习任务

1. 并行化方法: 个体学习器不存在强依赖关系、可同时生成, 主要关注降低方差, 需要基学习器较强 (倾向过拟合), 如无剪枝决策树、神经网络

- Bagging (bootstrap aggregation): 样本扰动-Bootstrap抽样有放回随机抽样
- 随机森林 (RF): 属性扰动-去相关的bagged trees

在自助法生成的训练样本上构建多个决策树, 构建这些决策树时, 对树中每一个分叉: 从全部的 p 个属性中随机选择 m 个候选的用于预测的属性、每次分叉都重新选择新的 m 个用于预测的属性、经验选择 $m \approx p^{1/2}$

2. 序列化方法: 个体学习器存在强依赖关系, 必须串行生成
Boosting, 如AdaBoost

提升方法

AdaBoost 算法

假设给定一个二类分类的训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$

其中, 每个样本点由实例与标记组成。实例 $x_i \in \mathcal{X} \subseteq \mathbb{R}^n$, 标记 $y_i \in \mathcal{Y} = \{-1, +1\}$, $\mathcal{X}$ 是实例空间, $\mathcal{Y}$ 是标记集合。

AdaBoost 利用以下算法, 从训练数据中学习一系列弱分类器或基本分类器, 并将这些弱分类器线性组合成为一个强分类器。

输入: 训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, 其中 $x_i \in \mathcal{X} \subseteq \mathbb{R}^n$, $y_i \in \mathcal{Y} = \{-1, +1\}$; 弱学习算法

输出: 最终分类器 $G(x)$

1. 初始化训练数据的权值分布

$$D_1 = (w_{11}, \dots, w_{1i}, \dots, w_{1N}), \quad w_{1i} = \frac{1}{N}, \quad i = 1, 2, \dots, N \quad (8)$$

2. 对 $m = 1, 2, \dots, M$, 使 D_{m+1} 成为一个概率分布

1. 使用具有权值分布 D_m 的训练数据集学习, 得到基本分类器

$$G_m(x): \mathcal{X} \rightarrow \{-1, +1\} \quad (9)$$

2. 计算 $G_m(x)$ 在训练数据集上的分类误差率

$$e_m = \sum_{i=1}^N P(G_m(x_i) \neq y_i) = \sum_{i=1}^N w_{mi} I(G_m(x_i) \neq y_i) \quad (10)$$

3. 计算 $G_m(x)$ 的系数,这里的对数是自然对数

$$\alpha_m = \frac{1}{2} \log \frac{1 - e_m}{e_m} \quad (11)$$

4. 更新训练数据集的权值分布

$$D_{m+1} = (w_{m+1,1}, \dots, w_{m+1,i}, \dots, w_{m+1,N}) \quad (12)$$

$$w_{m+1,i} = \frac{w_{mi}}{Z_m} \exp(-\alpha_m y_i G_m(x_i)), i = 1, 2, \dots, N \quad (13)$$

Z_m 是规范化因子

$$Z_m = \sum_{i=1}^N w_{mi} \exp(-\alpha_m y_i G_m(x_i)) \quad (14)$$

3. 构建基本分类器的线性组合

$$f(x) = \sum_{m=1}^M \alpha_m G_m(x) \quad (15)$$

4. 得到最终分类器

$$\begin{aligned} G(x) &= \text{sign}(f(x)) \\ &= \text{sign}\left(\sum_{m=1}^M \alpha_m G_m(x)\right) \end{aligned} \quad (16)$$

前向分步算法

输入: 训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, 损失函数 $L(y, f(x))$, 基函数集 $\{b(x; \gamma)\}$

输出: 加法模型 $f(x)$

1. 初始化 $f_0(x) = 0$

2. 对 $m = 1, 2, \dots, M$

1. 极小化损失函数 $L(y, f(x))$, 得到参数 $\beta_m, \gamma_m (\beta_m, \gamma_m) = \underset{\beta, \gamma}{\operatorname{argmin}} \sum_{i=1}^N L(y_i, f_{m-1}(x_i) + \beta b(x_i; \gamma))$

2. 更新 $f_m(x) = f_{m-1}(x) + \beta_m b(x; \gamma_m)$

3. 得到加法模型 $f(x) = f_M(x) = \sum_{m=1}^M \beta_m b(x; \gamma_m)$

- AdaBoost 算法是前向分步加法算法的特例
- 模型是由基本分类器组成的加法模型
- 损失函数是指数函数

不依赖预设下界 γ 的设计, 使得AdaBoost比早期的提升方法更为鲁棒和灵活。它不要求弱分类器“足够好”, 而只需“略好于随机”, 就能通过迭代和加权将这些微小的优势累积成一个强大的最终分类器, 从而成功地将多个弱学习器组合成一个强学习器

提升树 Boosting tree

以决策树为基函数的提升方法: 加法模型 + 决策树基函数 + 前向分步算法

模型	AdaBoost	Boosting Tree
通用框架	前向分步加法模型	前向分步加法模型
基函数 $b(x; \gamma)$	弱分类器 (通常是决策树桩)	决策树 (可以是树桩或稍深一点的树)
损失函数	指数损失函数 (对误分类样本加权)	任意可微分损失函数 (常见: 平方误差, 交叉熵)
学习目标	关注被前一轮分错的样本 (调整样本权重)	拟合当前模型的残差 (或负梯度, 目标不再是y)
处理问题	主要用于分类问题	分类、回归均可
参数选择方式	基于弱分类器错误率加权	通常通过优化损失函数负梯度 (残差) 来训练下一棵树

梯度提升 gradient boosting, GB

Freidman提出梯度提升算法, 利用最速下降法思想,用损失函数的负梯度在当前模型的值作为回归问题提升树算法中的残差的近似值

支持向量机

- 基本模型: 定义在特征空间上的间隔最大线性分类器
 - 间隔最大使它有别于感知机
 - 支持向量机还包括核技巧, 这使它成为实质上的非线性分类器
- 学习策略: 间隔最大化, 可形式化为一个求解凸二次规划 (*convex quadratic programming*)的问题, 也等价于正则化的合页损失函数的最小化问题
- 学习算法: 求解凸二次规划的最优化算法
- 输入空间: 欧氏空间或离散集合
- 特征空间: 欧氏空间或希尔伯特空间
- 支持向量机的学习在特征空间进行
 - 线性可分支持向量机、线性支持向量机:
 - 输入空间中的输入向量**直接映射**为特征空间中的特征向量
 - 非线性支持向量机:
 - 利用一个从输入空间到特征空间的**非线性映射**, 将输入向量映射为特征向量

线性可分支持向量机 (硬间隔SVM)

- linear support vector machine in linearly separable case*, 硬间隔最大化 *hard margin maximization* 模型
 - 分离超平面 $w^* \cdot x + b^* = 0$
 - 决策函数 $f(x) = \text{sign}(w^* \cdot x + b^*)$
- 策略: 软间隔最大化
- 算法: 凸二次规划

函数间隔和几何间隔

样本点的函数间隔: $\hat{\gamma}_i = y_i(w \cdot x_i + b)$

训练数据集的函数间隔: $\hat{\gamma} = \min_{i=1, \dots, N} \hat{\gamma}_i$

样本点的几何间隔: $\gamma_i = y_i \left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right)$

训练数据集的几何间隔 (最小间隔): $\gamma = \min_{i=1, \dots, N} \gamma_i$

- 即有 $\gamma_i = \frac{\hat{\gamma}_i}{\|w\|}, \gamma = \frac{\hat{\gamma}}{\|w\|}$
最大间隔分类超平面

$$\max_{w, b} \gamma, \text{ s.t. } y_i \left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right) \geq \gamma, i = 1, 2, \dots, N \quad (17)$$

根据几何间隔和函数间隔的关系

$$\max_{w, b} \frac{\hat{\gamma}}{\|w\|}, \text{ s.t. } y_i(w \cdot x_i + b) \geq \hat{\gamma}, i = 1, 2, \dots, N \quad (18)$$

- 取 $\hat{\gamma} = 1$
- 最大化 $\frac{1}{\|w\|}$ 和最小化 $\frac{1}{2} \|w\|^2$ 等价

支持向量

在线性可分情况下, 训练数据集的样本点中与分离超平面距离最近的样本点的实例称为支持向量 *support vector*

支持向量是使约束条件等号成立的点, 即 $y_i(w \cdot x_i + b) - 1 = 0$

- 正例: $H_1: w \cdot x + b = 1$
- 负例: $H_2: w \cdot x + b = -1$

线性可分SVM学习算法: 最大间隔法

线性可分支持向量机学习的最优化问题

KKT条件

原始问题和对偶问题的解相同的充分必要条件

$$\begin{cases} \nabla_x L(x^*, \alpha^*, \beta^*) = 0 \\ \alpha_i^* c_i(x^*) = 0, & i = 1, 2, \dots, k \\ c_i(x^*) \leq 0, & i = 1, 2, \dots, k \\ \alpha_i^* \geq 0, & i = 1, 2, \dots, k \\ h_j(x^*) = 0, & j = 1, 2, \dots, l \end{cases} \quad (19)$$

原始问题

$$x_i \in X = R^n \quad y_i \in Y = \{-1, +1\}, \quad i = 1, 2, \dots, N \quad (20)$$

输入: 线性可分训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$

输出: 最大间隔分离超平面和分类决策函数

1. 构造并求解约束最优化问题, 即一个凸二次规划 *convex quadratic programming* 问题

$$\min_{w, b} \frac{1}{2} \|w\|^2 \quad (21)$$

$$\text{s.t. } y_i(w \cdot x_i + b) - 1 \geq 0, \quad i = 1, 2, \dots, N \quad (22)$$

2. 得到分离超平面 $w^* \cdot x + b^* = 0$

3. 分类决策函数 $f(x) = \text{sign}(w^*x + b^*)$

对偶算法

在约束最优化问题中, 常常利用拉格朗日对偶性 *Lagrange duality* 将原始问题转换为对偶问题

- 对偶问题仍是凸优化问题, 且往往容易解 (α的维度为样本数, w的维数为特征维度)
- 从对偶问题可引入核函数, 推广到非线性分类问题
首先构建拉格朗日函数 (*Lagrange function*)。为此, 对每一个不等式约束引进拉格朗日乘子 (*Lagrange multiplier*) $\alpha_i \geq 0, i = 1, 2, \dots, N$, 定义拉格朗日函数:

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i (w \cdot x_i + b) + \sum_{i=1}^N \alpha_i \quad (23)$$

其中, $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_N)^T$ 为拉格朗日乘子向量。

根据拉格朗日对偶性, 原始问题的对偶问题是极大极小问题:

$$\max_{\alpha} \min_{w, b} L(w, b, \alpha) \quad (24)$$

1. 求 $\min_{w, b} L(w, b, \alpha)$

将拉格朗日函数 $L(w, b, \alpha)$ 分别对 w , b 求偏导数并令其等于0。

$$\nabla_w L(w, b, \alpha) = w - \sum_{i=1}^N \alpha_i y_i x_i = 0; \quad \nabla_b L(w, b, \alpha) = - \sum_{i=1}^N \alpha_i y_i = 0 \quad (25)$$

$$\text{得 } w = \sum_{i=1}^N \alpha_i y_i x_i, \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$\begin{aligned} L(w, b, \alpha) &= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i y_i \left(\left(\sum_{j=1}^N \alpha_j y_j x_j \right) \cdot x_i + b \right) + \sum_{i=1}^N \alpha_i \\ &= -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \end{aligned} \quad (26)$$

即

$$\min_{w, b} L(w, b, \alpha) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \quad (27)$$

2. 求 $\min_{w, b} L(w, b, \alpha)$ 对 α 的极大, 即是对偶问题

$$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \quad (28)$$

$$\text{s. t. } \sum_{i=1}^N \alpha_i y_i = 0, \quad \alpha_i \geq 0, i = 1, 2, \dots, N \quad (29)$$

将式目标函数由求极大转换成求极小, 得到与之等价的对偶最优化问题:

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \quad (30)$$

$$\text{s. t. } \sum_{i=1}^N \alpha_i y_i = 0, \quad \alpha_i \geq 0, i = 1, 2, \dots, N \quad (31)$$

输入：线性可分训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ ，其中， $x_i \in \mathcal{X} = \mathbf{R}^n$ ， $y_i \in \mathcal{Y} = \{-1, +1\}, i = 1, 2, \dots, N$ ；
输出：分离超平面和分类决策函数

1. 构造并求解约束最优化问题求得最优解 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)^T$
- $$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \text{s.t.} \sum_{i=1}^N \alpha_i y_i = 0, \quad \alpha_i \geq 0, i = 1, 2, \dots, N \tag{32}$$
2. 计算 $w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$ ，并选择支持向量： α^* 的一个正分量 $\alpha_j^* > 0$ ，计算
- $$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j) \tag{33}$$
- *假设 $\alpha^* = 0$ ，可知 $w^* = 0$ ，但这不是原始优化问题的解，产生矛盾
- 互补松弛条件：对 $\alpha_j^* > 0$ 的 j 有 $y_i(w^* \cdot x_i + b^*) = 1$
3. 求得分离超平面 $w^* \cdot x + b^* = 0$ ，分离超平面完全由支持向量 ($\alpha_j^* > 0$ ，在间隔边界) 决定
4. 分类决策函数 $f(x) = \text{sign}(w^* \cdot x + b^*)$

线性支持向量机 (软间隔SVM)

linear supportvector machine，训练数据近似线性可分时，通过软间隔最大化 *soft margin maximization* 训练数据中有一些特异点 (outlier) 不能满足函数间隔大于等于1的约束条件，对每个样本点 (x_i, y_i) ，引进一个松弛变量 $\xi_i \geq 0$ ，令函数间隔 + 松弛变量 ≥ 1
约束条件变为：

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i \tag{34}$$

目标函数变为：

$$\frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i, C(> 0) \text{为惩罚参数.} \tag{35}$$

惩罚参数 **C** 平衡模型的两个核心目标：“间隔最大化”和“减少分类错误”

特性 / C 值	C 很小	C 很大
关注点	间隔最大化	减少训练错误
间隔大小	大	小
偏差	高	低
方差	低	高
模型复杂度	低	高
风险	欠拟合	过拟合
对偶问题中 α_i 的范围	$0 \leq \alpha_i \leq C$	$0 \leq \alpha_i \leq C$

原始问题

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \quad (36)$$

$$\text{s.t. } y_i(w \cdot x_i + b) \geq 1 - \xi_i, i = 1, 2, \dots, N, \quad \xi_i \geq 0, i = 1, 2, \dots, N \quad (37)$$

- 凸二次规划
- w 的解唯一, b 不唯一 (而是一个区间范围)
- 设该问题的解是 w^*, b^* , 可得到分离超平面和决策函数

对偶问题

线性支持向量机原始问题的拉格朗日函数:

$$L(w, b, \xi, \alpha, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i + \sum_{i=1}^N \alpha_i [1 - \xi_i - y_i(w \cdot x_i + b)] - \sum_{i=1}^N \mu_i \xi_i \quad (38)$$

其中: $\alpha_i \geq 0, \mu_i \geq 0$ 为不等式约束的拉格朗日乘子

对偶问题是拉格朗日函数的极大极小问题

$$\max_{\alpha, \mu} \min_{w, b, \xi} L(w, b, \xi, \alpha, \mu) \quad (39)$$

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, N \end{aligned} \quad (40)$$

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i, \quad b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j) \quad (41)$$

$$\xi_i^* = \begin{cases} 0, & 0 < \alpha_i^* < C \\ 1 - y_i(w^* \cdot x_i + b^*), & \alpha_i^* = C \end{cases} \quad (42)$$

$$\mu_i^* = C - \alpha_i^* \quad (43)$$

输入: 训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, 其中, $x_i \in \mathcal{X} = \mathbf{R}^n$, $y_i \in \mathcal{Y} = \{-1, +1\}, i = 1, 2, \dots, N$;

输出: 分离超平面和分类决策函数

1. 选择惩罚参数 $C > 0$, 构造并求解凸二次规划问题, 求得最优解 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)^T$

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, i = 1, 2, \dots, N \end{aligned} \quad (44)$$

2. 计算 $w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$, 选择 α^* 的一个分量 α_j^* 适合条件 $0 < \alpha_j^* < C$, 计算

$$b^* = y_j - \sum_{i=1}^N y_i \alpha_i^* (x_i \cdot x_j) \quad (45)$$

3. 求得分离超平面: $w^* \cdot x + b^* = 0$, 分类决策函数: $f(x) = \text{sign}(w^* \cdot x + b^*)$

支持向量

软间隔SVM的KKT互补松弛条件

$$1. \alpha_i^* (y_i (w^* \cdot x_i + b^*) - 1 + \xi_i^*) = 0$$

$$2. \mu_i^* \xi_i^* = 0$$


$\alpha_i^* > 0$: 软间隔支持向量

若 $\alpha_i^* < C$, 则 $\xi_i = 0$

若 $\alpha_i^* = C$, $0 < \xi_i < 1$, 则分类正确

若 $\alpha_i^* = C$, $\xi_i = 1$

若 $\alpha_i^* = C$, $\xi_i > 1$



3. 在间隔边界上: $0 < \alpha^* < C$, $\xi = 0$

4. 在间隔内, 但分类正确: $\alpha^* = C$, $0 < \xi < 1$

5. 在中心线上: $\alpha^* = C$, $\xi = 1$


6. 被错误分类: $\alpha^* = C$, $\xi > 1$

只要一个点的 α^* 被 C “卡住”了 (即 $\alpha^* = C$), 就意味着这个点是一个“问题点”或“离群点”。模型为了迁就它, 已经付出了最大的“代价”。而这个点具体是分类正确、在边界上还是被错分, 则取决于它的松弛变量 ξ 的大小。可以把 C 想象成一个总的“惩罚预算”或者“压力上限”。对于每个数据点 x_i , 这个预算被分配给两个地方:

- α_i : 用来将分类边界推离该点的“力量”。 α_i 越大, 说明该点对边界的位置影响越大。
- μ_i : 用来惩罚松弛变量 ξ_i 的“力量”。它的作用是尽可能地让 ξ_i 保持为0, 即让数据点遵守规则。在最优解处, 这两股“力量”必须达到一个平衡, 这个平衡关系就是:
 $\alpha_i^* + \mu_i^* = C \alpha_i^* + \mu_i^* = C \alpha_i^* + \mu_i^* = C$ (等式来自拉格朗日函数对 ξ_i 求导并令其为0)。

合页损失函数 hinge loss function

0-1损失的上界,最优贝叶斯分类器



1. 我们的终极理想是达到 最优贝叶斯分类器(对于一个新的样本 x , 计算它属于每个类别 c 的后验概率 $P(c|x)$, 然后将它分到后验概率最大的那个类别中) 的性能。
2. 这意味着: 我们需要最小化 0-1 损失, 但0-1 损失在计算上无法直接优化。
3. 务实的解决方案是: 我们找到一个数学性质良好 (凸函数) 的替代品, 即 Hinge Loss, 它构成了 0-1 损失的一个紧上界。
4. 最终的算法 (如SVM): 通过最小化 (Hinge Loss + 正则化项), 我们实际上是在最小化0-1损失的一个更严格的上界。这样做既能在计算上保证可行性, 又能从理论上保证我们的方向是正确的——压低上界的同时, 也在间接地压低我们真正关心的0-1损失, 从而让我们在实践中尽可能地逼近理论上最优的贝叶斯分类器。

%%

线性支持向量机学习还有另外一种解释, 就是最小化以下目标函数,最小化正则化的合页损失:


$$\sum_{i=1}^N [1 - y_i (w \cdot x_i + b)]_+ + \lambda \|w\|^2 \quad (46)$$

合页损失函数: 目标函数的第1项是经验损失或经验风险

$$L(y(w \cdot x + b)) = [1 - y(w \cdot x + b)]_+ \quad (47)$$

下标“+”表示以下取正值的函数

$$[z]_+ = \begin{cases} z, & z > 0 \\ 0, & z \leq 0 \end{cases} \quad (48)$$



核技巧与非线性支持向量机 (kernel-SVM)

non-linear support vector machine, 当训练数据线性不可分时, 使用核技巧 *kernel trick* + 软间隔最大化
当输入空间为欧氏空间或离散集合、特征空间为希尔伯特空间时, 核函数 (*kernel function*) 将 (一对) 输入向量从输入空间映射到特征空间中相应的一对特征向量的内积

核技巧

- 通过核函数学习非线性支持向量机, 等价于隐式地在高维的特征空间中学习线性支持向量机
- 对于给定的核 $K(x, z)$, 特征空间 H 和映射函数 ϕ 的取法可以不同
- 通常直接计算 $K(x, z)$ 比较容易, 而 $\phi(x)$ 和 $\phi(z)$ 计算并不容易

正定核的充要条件

设 $K: \mathcal{X} \times \mathcal{X} \rightarrow \mathbf{R}$ 是对称函数, 则 $K(x, z)$ 为正定核函数的充要条件是对任意 $x_i \in \mathcal{X}, i = 1, 2, \dots, m$, $K(x, z)$ 对应的 *Gram* 矩阵是半正定矩阵

$$K = \begin{bmatrix} K(x_1, x_1) & \cdots & K(x_1, x_m) \\ \vdots & \ddots & \vdots \\ K(x_m, x_1) & \cdots & K(x_m, x_m) \end{bmatrix}_{m \times m} \quad (49)$$

核方法 (*kernel method*) 是比支持向量机更为一般的机器学习方法

径向基函数 (*Radial Basis Function, RBF*)

高斯过程 (*Gaussian Processes*)

常用核函数

多项式核函数 (polynomial kernel function)

$$K(x, z) = (x \cdot z + 1)^p$$

对应的支持向量机是一个 p 次多项式分类器, 分类决策函数:

$$f(x) = \text{sign} \left(\sum_{i=1}^{N_s} a_i^* y_i (x_i \cdot x + 1)^p + b^* \right) \quad (50)$$

高斯核函数 (Gaussian kernel function)

$$K(x, z) = \exp \left(-\frac{\|x - z\|^2}{2\sigma^2} \right) \quad (51)$$

对应的支持向量机是高斯径向基函数 (radial basis function) 分类器, 分类决策函数:

$$f(x) = \text{sign} \left(\sum_{i=1}^{N_s} a_i^* y_i \exp \left(-\frac{\|x - x_i\|^2}{2\sigma^2} \right) + b^* \right) \quad (52)$$

字符串核函数 (string kernel function)

核函数不仅可以定义在欧氏空间上, 还可以定义在离散数据的集合上。比如, 字符串核是定义在字符串集合上的核函数。字符串核函数在文本分类、信息检索、生物信息学等方面都有应用。

EM算法

三硬币模型

假设有3枚硬币, 分别记作A, B, C。这些硬币正面出现的概率分别是 π , p 和 q 。进行如下掷硬币试验: 先掷硬币A, 根据其结果选出硬币B或硬币C, 正面选硬币B, 反面选硬币C; 然后掷选出的硬币, 掷硬币的结果, 出现正面记作1, 出现反面记作0; 独立地重复 n 次试验

$$i = \pi p^y (1 - p)^{1-y} + (1 - \pi) q^y (1 - q)^{1-y} \quad (53)$$

- 随机变量 y 是观测变量, 表示一次试验观测的结果是 1 或 0
- 随机变量 z 是隐变量, 表示未观测到的掷硬币 A 的结果
- $\theta = (\pi, p, q)$ 是模型参数, 这一模型是以上数据的生成模型

策略

将观测数据表示为 $Y = (Y_1, Y_2, \dots, Y_n)^T$, 未观测数据表示为 $Z = (Z_1, Z_2, \dots, Z_n)^T$ 则观测数据的似然函数为

$$P(Y|\theta) = \sum_Z P(Z|\theta) P(Y|Z, \theta) \quad (54)$$

考虑求模型参数 $\theta = (\pi, p, q)$ 的极大似然估计, 即

$$\hat{\theta} = \underset{\theta}{\operatorname{argmax}} \log P(Y|\theta) \quad (55)$$

这个问题没有解析解, 只有通过迭代的方法求解。EM算法就是可以用于求解这个问题的一种迭代算法

Q函数

完全数据的对数似然函数 $\log P(Y, Z|\Theta)$ 关于在给定观测数据 Y 和当前函数 $\Theta^{(i)}$ 下对未观测数据 Z 的条件概率分布 $P(Z|Y, \Theta^{(i)})$ 的期望

$$Q(\theta, \theta^{(i)}) = E_z[\log P(Y, Z|\theta)|Y, \theta^{(i)}]$$

算法

EM算法首先选取参数的初值，记作 $\theta^{(0)} = (\pi^{(0)}, p^{(0)}, q^{(0)})$ ，然后通过下面的步骤迭代计算参数的估计值，直至收敛为止。

第*i*次迭代参数的估计值为 $\theta^{(i)} = (\pi^{(i)}, p^{(i)}, q^{(i)})$ 。

EM算法的第 *i* + 1 次迭代如下。

1. E步：计算在模型参数 $\pi^{(i)}, p^{(i)}, q^{(i)}$ 下观测数据 y_j 来自掷硬币 B 的概率

$$\mu_j^{(i+1)} = \frac{\pi^{(i)} (p^{(i)})^{y_j} (1 - p^{(i)})^{1-y_j}}{\pi^{(i)} (p^{(i)})^{y_j} (1 - p^{(i)})^{1-y_j} + (1 - \pi^{(i)}) (q^{(i)})^{y_j} (1 - q^{(i)})^{1-y_j}} \tag{56}$$

2. M步：计算模型参数的新估计值

$$\pi^{(i+1)} = \frac{1}{n} \sum_{j=1}^n \mu_j^{(i+1)} \tag{57}$$

$$p^{(i+1)} = \frac{\sum_{j=1}^n \mu_j^{(i+1)} y_j}{\sum_{j=1}^n \mu_j^{(i+1)}} \tag{58}$$


$$q^{(i+1)} = \frac{\sum_{j=1}^n (1 - \mu_j^{(i+1)}) y_j}{\sum_{j=1}^n (1 - \mu_j^{(i+1)})} \tag{59}$$

似然和Q函数的关系 $L(\theta)$ 和 $B(\theta, \theta^{(i)})$

1. $L(\theta)$ 是我们最终想要最大化的目标函数。它代表了在给定模型参数 θ 的情况下，观测数据 X 出现的可能性。在图中，它是那条粗黑线。它的形状复杂，可能有多个峰值，直接优化困难。
2. $B(\theta, \theta^{(i)})$ 是我们用E步骤构造出来的、在M步骤中要最大化的函数。它的具体形式是完整数据对数似然对隐变量后验分布的期望（Q函数），再加上一个常数项（隐变量后验分布的熵的负值）。在图中，它是那条细灰线。它扮演的角色是 $L(\theta)$ 的一个可处理的下界。
3. 核心关系：

下界性： 对于所有可能的参数 θ ，都有 $L(\theta) \geq B(\theta, \theta^{(i)})$ 。这保证了细灰线永远不会跑到粗黑线上面去。

接触点： 在当前迭代的参数 $\theta^{(i)}$ 处，它们是相等的： $L(\theta^{(i)}) = B(\theta^{(i)}, \theta^{(i)})$ 。这使得EM算法能够逐步提高 $L(\theta)$ 。



- 得到了一个新的参数 $\theta^{(i+1)}$ ，它的对数似然值更高。
 - 下一次迭代，我们会把这个 $\theta^{(i+1)}$ 作为E步骤的输入，构造出一条新的细灰线 $B(\theta, \theta^{(i+1)})$ 。这条新的细灰线会在 $\theta^{(i+1)}$ 处与粗黑线 $L(\theta)$ 相切。
 - M步骤再优化这条新的细灰线，找到下一个 $\theta^{(i+2)}$ 。
 - 这个过程不断重复，每一次迭代都保证 $L(\theta)$ 的值单调递增，直到算法收敛到一个局部最大值点（即 $L(\theta)$ 不再增加或增加微乎其微）。
- 这张图形象地展示了EM算法的“翘翘板”原理：

- **E步骤**：锚定当前参数 $\theta^{(i)}$ ，构造一条“比真实似然更容易优化”的下界曲线 $B(\theta, \theta^{(i)})$ ，这条曲线在 $\theta^{(i)}$ 处与真实似然曲线 $L(\theta)$ 相切。
 - **M步骤**：找到这条下界曲线 $B(\theta, \theta^{(i)})$ 的最高点，得到新的参数 $\theta^{(i+1)}$ 。由于下界曲线的特性，这个新的参数点所对应的真实似然值 $L(\theta^{(i+1)})$ 必然会高于或等于上一次的 $L(\theta^{(i)})$ 。
- 通过不断地“找下界 -> 优化下界 -> 产生更高真实似然 -> 找新下界”的过程，EM算法最终能逐步逼近 $L(\theta)$ 的局部最大值

EM算法在高斯混合模型学习中的应用

聚类

概念

闵可夫斯基距离 Minkowski distance

在聚类中，可以将样本集合看作是向量空间中点的集合，以该空间的距离表示样本之间的相似度。常用的距离有闵可夫斯基距离，特别是欧氏距离。闵可夫斯基距离越大相似度越小，距离越小相似度越大。

给定样本集合 X ， X 是 m 维实数向量空间 $\mathbf{R}^m$ 中点的集合，其中

$x_i, x_j \in X, x_i = (x_{1i}, x_{2i}, \dots, x_{mi})^T, x_j = (x_{1j}, x_{2j}, \dots, x_{mj})^T$ ，样本 x_i 与样本 x_j 的闵可夫斯基距离定义为

$$d_{ij} = \left(\sum_{k=1}^m |x_{ki} - x_{kj}|^p \right)^{\frac{1}{p}} \quad (60)$$

这里 $p \geq 1$ 。当 $p = 2$ 时称为欧氏距离（Euclidean distance），即

$$d_{ij} = \left(\sum_{k=1}^m |x_{ki} - x_{kj}|^2 \right)^{\frac{1}{2}} \quad (61)$$

当 $p = 1$ 时称为曼哈顿距离（Manhattan distance），即

$$d_{ij} = \sum_{k=1}^m |x_{ki} - x_{kj}| \quad (62)$$

当 $p = \infty$ 时称为切比雪夫距离（Chebyshev distance），取各个坐标数值差的绝对值的最大值，即

$$d_{ij} = \max_k |x_{ki} - x_{kj}| \quad (63)$$

马哈拉诺比斯距离 Mahalanobis distance

马哈拉诺比斯距离，简称马氏距离，也是另一种常用的相似度，考虑各个分量（特征）之间的相关性并与各个分量的尺度无关。马哈拉诺比斯距离越大相似度越小，距离越小相似度越大。

给定一个样本集合 X ， $X = [x_{ij}]_{m \times n}$ ，其协方差矩阵记作 S 。样本 x_i 与样本 x_j 之间的马哈拉诺比斯距离 d_{ij} 定义为

$$d_{ij} = \left[(x_i - x_j)^T S^{-1} (x_i - x_j) \right]^{\frac{1}{2}} \tag{64}$$

$$x_i = (x_{1i}, x_{2i}, \dots, x_{mi})^T, x_j = (x_{1j}, x_{2j}, \dots, x_{mj})^T \tag{65}$$

当 S 为单位矩阵时，即样本数据的各个分量互相独立且各个分量的方差为1时，马氏距离就是欧氏距离，所以马氏距离是欧氏距离的推广。

相关系数 correlation coefficient

样本之间的相似度也可以用**相关系数**来表示。相关系数的绝对值越接近于1，表示样本越相似；越接近于0，表示样本越不相似。

$$r_{ij} = \frac{\sum_{k=1}^m (x_{ki} - \bar{x}_i)(x_{kj} - \bar{x}_j)}{\left[\sum_{k=1}^m (x_{ki} - \bar{x}_i)^2 \sum_{k=1}^m (x_{kj} - \bar{x}_j)^2 \right]^{\frac{1}{2}}} \tag{66}$$

夹角余弦

样本之间的相似度也可以用夹角余弦（cosine）来表示。夹角余弦越接近于1，表示样本越相似；越接近于0，表示样本越不相似

$$s_{ij} = \frac{\sum_{k=1}^m x_{ki} x_{kj}}{\left[\sum_{k=1}^m x_{ki}^2 \sum_{k=1}^m x_{kj}^2 \right]^{\frac{1}{2}}} \tag{67}$$

层次聚类

- 假设类别之间存在层次结构，将样本聚到层次化的类中
- 硬聚类，每个样本只属于一个类

聚合聚类 agglomerative/自下而上聚类 bottom-up

- 开始将每个样本各自分到一个类
- 之后将相距最近的两类合并，建立一个新的类
- 重复此操作直到满足停止条件

分裂聚类divisive/自上而下聚类 top-down

- 开始将所有样本分到一个类
- 之后将已有类中相距最远的样本分到两个新的类
- 重复此操作直到满足停止条件

k 均值聚类

策略

样本之间的距离 $d(x_i, x_j)$ 采用欧氏距离平方 (squared Euclidean distance)

$$d(x_i, x_j) = \sum_{k=1}^m (x_{ki} - x_{kj})^2 = \|x_i - x_j\|^2$$

损失函数定义为样本与其所属类的中心之间的距离的总和

$$W(C) = \sum_{l=1}^k \sum_{C(i)=l} \|x_i - \bar{x}_l\|^2$$

$\bar{x}_l = (\bar{x}_{1l}, \bar{x}_{2l}, \dots, \bar{x}_{ml})^T$ 是第 l 个类的均值或中心, 函数 $W(C)$ 也称为能量, 表示相同类中的样本相似的程度

算法

输入: n 个样本的集合 X

输出: 样本集合的聚类 C 。

1. 初始化。令 $t = 0$, 随机选择 k 个样本点作为初始聚类中心 $m^{(0)} = (m_1^{(0)}, \dots, m_l^{(0)}, \dots, m_k^{(0)})$
2. 对样本进行聚类。对固定的类中心 $m^{(t)} = (m_1^{(t)}, \dots, m_l^{(t)}, \dots, m_k^{(t)})$, 其中 $m_l^{(t)}$ 为类 G_l 的中心, 计算每个样本到类中心的距离, 将每个样本指派到与其最近的中心的类中, 构成聚类结果 $C^{(t)}$
3. 计算新的类中心。对聚类结果 $C^{(t)}$, 计算当前各个类中的样本的均值, 作为新的类中心 $m^{(t+1)} = (m_1^{(t+1)}, \dots, m_l^{(t+1)}, \dots, m_k^{(t+1)})$
4. 如果迭代收敛或符合停止条件, 输出 $C = C^{(t)}$ 。否则, 令 $t = t + 1$ 返回2。
k 均值聚类算法的复杂度是 $O(mnk)$, 其中 m 是样本维数, n 是样本个数, k 是类别个数。

支持向量机

基本模型: 定义在特征空间上的间隔最大线性分类器

间隔最大使它有别于感知机

支持向量机还包括核技巧, 这使它成为实质上的非线性分类器

学习策略: 间隔最大化, 可形式化为一个求解凸二次规划 (*convex quadratic programming*) 的问题, 也等价于正则化的合页损失函数的最小化问题

学习算法: 求解凸二次规划的最优化算法

输入空间: 欧氏空间或离散集合

特征空间: 欧氏空间或希尔伯特空间

支持向量机的学习在特征空间进行

线性可分支持向量机、线性支持向量机:

输入空间中的输入向量**直接映射**为特征空间中的特征向量

非线性支持向量机:

利用一个从输入空间到特征空间的**非线性映射**, 将输入向量映射为特征向量

线性可分支持向量机 (硬间隔SVM)

linear support vector machine in linearly separable case, 硬间隔最大化 *hard margin maximization* 模型

分离超平面 $w^* \cdot x + b^* = 0$

决策函数 $f(x) = \text{sign}(w^* \cdot x + b^*)$

策略: 软间隔最大化

算法: 凸二次规划

函数间隔和几何间隔

样本点的函数间隔: $\hat{\gamma}_i = y_i(w \cdot x_i + b)$

训练数据集的函数间隔: $\hat{\gamma} = \min_{i=1, \dots, N} \hat{\gamma}_i$

样本点的几何间隔: $\gamma_i = y_i \left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right)$

训练数据集的几何间隔 (最小间隔): $\gamma = \min_{i=1, \dots, N} \gamma_i$

- 即有 $\gamma_i = \frac{\hat{\gamma}_i}{\|w\|}, \gamma = \frac{\hat{\gamma}}{\|w\|}$
最大间隔分类超平面

$$\max_{w,b} \gamma, \text{ s.t. } y_i \left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right) \geq \gamma, i = 1, 2, \dots, N \quad (68)$$

根据几何间隔和函数间隔的关系

$$\max_{w,b} \frac{\hat{\gamma}}{\|w\|}, \text{ s.t. } y_i(w \cdot x_i + b) \geq \hat{\gamma}, i = 1, 2, \dots, N \quad (69)$$

- 取 $\hat{\gamma} = 1$
- 最大化 $\frac{1}{\|w\|}$ 和最小化 $\frac{1}{2} \|w\|^2$ 等价

支持向量

在线性可分情况下，训练数据集的样本点中与分离超平面距离最近的样本点的实例称为支持向量 *support vector*。支持向量是使约束条件式等号成立的点，即 $y_i(w \cdot x_i + b) - 1 = 0$

- 正例: $H_1: w \cdot x + b = 1$
- 负例: $H_2: w \cdot x + b = -1$

线性可分SVM学习算法：最大间隔法

线性可分支持向量机学习的最优化问题

KKT条件

原始问题和对偶问题的解相同的充分必要条件

$$\begin{cases} \nabla_x L(x^*, \alpha^*, \beta^*) = 0 \\ \alpha_i^* c_i(x^*) = 0, & i = 1, 2, \dots, k \\ c_i(x^*) \leq 0, & i = 1, 2, \dots, k \\ \alpha_i^* \geq 0, & i = 1, 2, \dots, k \\ h_j(x^*) = 0, & j = 1, 2, \dots, l \end{cases} \quad (70)$$

原始问题

$$x_i \in X = R^n \quad y_i \in Y = \{-1, +1\}, \quad i = 1, 2, \dots, N \quad (71)$$

输入: 线性可分训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$

输出: 最大间隔分离超平面和分类决策函数

1. 构造并求解约束最优化问题，即一个凸二次规划 *convex quadratic programming* 问题

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad (72)$$

$$\text{s.t. } y_i(w \cdot x_i + b) - 1 \geq 0, \quad i = 1, 2, \dots, N \quad (73)$$

2. 得到分离超平面 $w^* \cdot x + b^* = 0$
3. 分类决策函数 $f(x) = \text{sign}(w^* \cdot x + b^*)$

对偶算法

在约束最优化问题中，常常利用拉格朗日对偶性 *Lagrange duality* 将原始问题转换为对偶问题

- 对偶问题仍是凸优化问题, 且往往容易解 (α 的维度为样本数, w 的维数为特征维度)
- 从对偶问题可引入核函数, 推广到非线性分类问题
首先构建拉格朗日函数 (*Lagrange function*)。为此, 对每一个不等式约束引进拉格朗日乘子 (*Lagrange multiplier*) $\alpha_i \geq 0, i = 1, 2, \dots, N$, 定义拉格朗日函数:

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i (w \cdot x_i + b) + \sum_{i=1}^N \alpha_i \quad (74)$$

其中, $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_N)^T$ 为拉格朗日乘子向量。

根据拉格朗日对偶性, 原始问题的对偶问题是极大极小问题:

$$\max_{\alpha} \min_{w, b} L(w, b, \alpha) \quad (75)$$

1. 求 $\min_{w, b} L(w, b, \alpha)$

将拉格朗日函数 $L(w, b, \alpha)$ 分别对 w , b 求偏导数并令其等于0。

$$\nabla_w L(w, b, \alpha) = w - \sum_{i=1}^N \alpha_i y_i x_i = 0; \quad \nabla_b L(w, b, \alpha) = - \sum_{i=1}^N \alpha_i y_i = 0 \quad (76)$$

$$\text{得 } w = \sum_{i=1}^N \alpha_i y_i x_i, \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$\begin{aligned} L(w, b, \alpha) &= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i y_i \left(\left(\sum_{j=1}^N \alpha_j y_j x_j \right) \cdot x_i + b \right) + \sum_{i=1}^N \alpha_i \\ &= -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \end{aligned} \quad (77)$$

即

$$\min_{w, b} L(w, b, \alpha) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \quad (78)$$

2. 求 $\min_{w, b} L(w, b, \alpha)$ 对 α 的极大, 即是对偶问题

$$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \quad (79)$$

$$\text{s. t. } \sum_{i=1}^N \alpha_i y_i = 0, \quad \alpha_i \geq 0, i = 1, 2, \dots, N \quad (80)$$

将式目标函数由求极大转换成求极小, 得到与之等价的对偶最优化问题:

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \quad (81)$$

$$\text{s. t. } \sum_{i=1}^N \alpha_i y_i = 0, \quad \alpha_i \geq 0, i = 1, 2, \dots, N \quad (82)$$

输入: 线性可分训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, 其中, $x_i \in \mathcal{X} = \mathbf{R}^n$, $y_i \in \mathcal{Y} = \{-1, +1\}, i = 1, 2, \dots, N$;

输出: 分离超平面和分类决策函数

1. 构造并求解约束最优化问题求得最优解 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)^T$

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \quad \text{s.t.} \quad \sum_{i=1}^N \alpha_i y_i = 0, \quad \alpha_i \geq 0, i = 1, 2, \dots, N \quad (83)$$

2. 计算 $w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$, 并选择支持向量: α^* 的一个正分量 $\alpha_j^* > 0$, 计算

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j) \quad (84)$$

假设 $\alpha^ = 0$, 可知 $w^* = 0$, 但这不是原始优化问题的解, 产生矛盾

互补松弛条件: 对 $\alpha_j^* > 0$ 的 j 有 $y_i(w^* \cdot x_i + b^*) = 1$

3. 求得分离超平面 $w^* \cdot x + b^* = 0$, 分离超平面完全由支持向量 ($\alpha_j^* > 0$, 在间隔边界) 决定

4. 分类决策函数 $f(x) = \text{sign}(w^* \cdot x + b^*)$

线性支持向量机 (软间隔SVM)

linear supportvector machine, 训练数据近似线性可分时, 通过软间隔最大化 *soft margin maximization*

训练数据中有一些特异点 (*outlier*) 不能满足函数间隔大于等于1的约束条件, 对每个样本点 (x_i, y_i) , 引进一个松弛变量 $\xi_i \geq 0$, 令函数间隔 + 松弛变量 ≥ 1

约束条件变为: $y_i(w \cdot x_i + b) \geq 1 - \xi_i$ 目标函数变为:

$$\frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i, C(> 0) \text{ 为惩罚参数.} \quad (85)$$

惩罚参数 **C** 平衡模型的两个核心目标: “间隔最大化” 和 “减少分类错误”

特性 / C 值	C 很小	C 很大
关注点	间隔最大化	减少训练错误
间隔大小	大	小
偏差	高	低
方差	低	高
模型复杂度	低	高
风险	欠拟合	过拟合
对偶问题中 α_i 的范围	$0 \leq \alpha_i \leq C$	$0 \leq \alpha_i \leq C$

原始问题

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \quad (86)$$

$$\text{s.t.} \quad y_i(w \cdot x_i + b) \geq 1 - \xi_i, i = 1, 2, \dots, N, \quad \xi_i \geq 0, i = 1, 2, \dots, N \quad (87)$$

- 凸二次规划
- w 的解唯一, b 不唯一 (而是一个区间范围)
- 设该问题的解是 w^*, b^* , 可得到分离超平面和决策函数

对偶问题

线性支持向量机原始问题的拉格朗日函数:

$$L(w, b, \xi, \alpha, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i + \sum_{i=1}^N \alpha_i [1 - \xi_i - y_i(w \cdot x_i + b)] - \sum_{i=1}^N \mu_i \xi_i \quad (88)$$

其中: $\alpha_i \geq 0, \mu_i \geq 0$ 为不等式约束的拉格朗日乘子

对偶问题是拉格朗日函数的极大极小问题

$$\max_{\alpha, \mu} \min_{w, b, \xi} L(w, b, \xi, \alpha, \mu) \quad (89)$$

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ \text{s. t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, N \end{aligned} \quad (90)$$

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i, \quad b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j) \quad (91)$$

$$\xi_i^* = \begin{cases} 0, & 0 < \alpha_i^* < C \\ 1 - y_i(w^* \cdot x_i + b^*), & \alpha_i^* = C \end{cases} \quad (92)$$

$$\mu_i^* = C - \alpha_i^* \quad (93)$$

输入: 训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, 其中,

$x_i \in \mathcal{X} = \mathbf{R}^n$, $y_i \in \mathcal{Y} = \{-1, +1\}, i = 1, 2, \dots, N$;

输出: 分离超平面和分类决策函数

1. 选择惩罚参数 $C > 0$, 构造并求解凸二次规划问题, 求得最优解 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)^T$

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ \text{s. t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, i = 1, 2, \dots, N \end{aligned} \quad (94)$$

2. 计算 $w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$, 选择 α^* 的一个分量 α_j^* 适合条件 $0 < \alpha_j^* < C$, 计算

$$b^* = y_j - \sum_{i=1}^N y_i \alpha_i^* (x_i \cdot x_j) \quad (95)$$

3. 求得分离超平面: $w^* \cdot x + b^* = 0$, 分类决策函数: $f(x) = \text{sign}(w^* \cdot x + b^*)$

支持向量

软间隔SVM的KKT互补松弛条件

1. $\alpha_i^* (y_i (w^* \cdot x_i + b^*) - 1 + \xi_i^*) = 0$

2. $\mu_i^* \xi_i^* = 0$


$\alpha_i^* > 0$: 软间隔支持向量

若 $\alpha_i^* < C$, 则 $\xi_i = 0$

若 $\alpha_i^* = C$, $0 < \xi_i < 1$, 则分类正确

若 $\alpha_i^* = C$, $\xi_i = 1$

若 $\alpha_i^* = C$, $\xi_i > 1$



3. 在间隔边界上: $0 < \alpha^* < C$, $\xi = 0$

4. 在间隔内, 但分类正确: $\alpha^* = C$, $0 < \xi < 1$

5. 在中心线上: $\alpha^* = C$, $\xi = 1$

6. 被错误分类: $\alpha^* = C$, $\xi > 1$

只要一个点的 α^* 被 C “卡住”了 (即 $\alpha^* = C$), 就意味着这个点是一个“问题点”或“离群点”。模型为了迁就它, 已经付出了最大的“代价”。而这个点具体是分类正确、在边界上还是被错分, 则取决于它的松弛变量 ξ 的大小。可以把 C 想象成一个总的“惩罚预算”或者“压力上限”。对于每个数据点 x_i , 这个预算被分配给两个地方:


- α_i : 用来将分类边界推离该点的“力量”。 α_i 越大, 说明该点对边界的位置影响越大。
- μ_i : 用来惩罚松弛变量 ξ_i 的“力量”。它的作用是尽可能地让 ξ_i 保持为0, 即让数据点遵守规则。

在最优解处, 这两股“力量”必须达到一个平衡, 这个平衡关系就是:

$\alpha_i^* + \mu_i^* = C\alpha_i^* + \mu_i^* = C\alpha_i^* + \mu_i^* = C$ (等式来自拉格朗日函数对 ξ_i 求导并令其为0)。

合页损失函数 hinge loss function

0-1损失的上界, 最优贝叶斯分类器



1. 我们的终极理想是达到 最优贝叶斯分类器 (对于一个新的样本 x , 计算它属于每个类别 c 的后验概率 $P(c|x)$, 然后将它分到后验概率最大的那个类别中) 的性能。
2. 这意味着: 我们需要最小化 0-1 损失, 但 0-1 损失在计算上无法直接优化。
3. 务实的解决方案是: 我们找到一个数学性质良好 (凸函数) 的替代品, 即 Hinge Loss, 它构成了 0-1 损失的一个紧

上界。

4. 最终的算法（如SVM）：通过最小化 (Hinge Loss + 正则化项)，我们实际上是在最小化0-1损失的一个更严格的上界。这样做既能在计算上保证可行性，又能从理论上保证我们的方向是正确的——压低上界的同时，也在间接地压低我们真正关心的0-1损失，从而让我们在实践中尽可能地逼近理论上最优的贝叶斯分类器。

%%

线性支持向量机学习还有另外一种解释，就是最小化以下目标函数,最小化正则化的合页损失：


$$\sum_{i=1}^N [1 - y_i (w \cdot x_i + b)]_+ + \lambda \|w\|^2 \quad (96)$$

合页损失函数: 目标函数的第1项是经验损失或经验风险

$$L(y(w \cdot x + b)) = [1 - y(w \cdot x + b)]_+ \quad (97)$$

下标“+”表示以下取正值的函数

$$[z]_+ = \begin{cases} z, & z > 0 \\ 0, & z \leq 0 \end{cases} \quad (98)$$



核技巧与非线性支持向量机 (kernel-SVM)

non-linear support vector machine, 当训练数据线性不可分时, 使用核技巧 *kernel trick* + 软间隔最大化
当输入空间为欧氏空间或离散集合、特征空间为希尔伯特空间时, 核函数 (*kernel function*) 将 (一对) 输入向量从输入空间映射到特征空间中相应的一对特征向量的内积

核技巧

- 通过核函数学习非线性支持向量机, 等价于隐式地高维的特征空间中学习线性支持向量机
- 对于给定的核 $K(x, z)$, 特征空间 H 和映射函数 ϕ 的取法可以不同
- 通常直接计算 $K(x, z)$ 比较容易, 而 $\phi(x)$ 和 $\phi(z)$ 计算并不容易

正定核的充要条件

设 $K: \mathcal{X} \times \mathcal{X} \rightarrow \mathbf{R}$ 是对称函数, 则 $K(x, z)$ 为正定核函数的充要条件是对任意 $x_i \in \mathcal{X}, i = 1, 2, \dots, m$, $K(x, z)$ 对应的Gram矩阵是半正定矩阵

$$K = \begin{bmatrix} K(x_1, x_1) & \cdots & K(x_1, x_m) \\ \vdots & \ddots & \vdots \\ K(x_m, x_1) & \cdots & K(x_m, x_m) \end{bmatrix}_{m \times m} \quad (99)$$

核方法 (*kernel method*) 是比支持向量机更为一般的机器学习方法

径向基函数(*Radial Basis Function, RBF*)

高斯过程 (*Gaussian Processes*)

常用核函数

多项式核函数 (polynomial kernel function)

$$K(x, z) = (x \cdot z + 1)^p$$

对应的支持向量机是一个 p 次多项式分类器, 分类决策函数:

$$f(x) = \text{sign} \left(\sum_{i=1}^{N_s} a_i^* y_i (x_i \cdot x + 1)^p + b^* \right) \quad (100)$$

高斯核函数 (Gaussian kernel function)

$$K(x, z) = \exp \left(-\frac{\|x - z\|^2}{2\sigma^2} \right) \quad (101)$$

对应的支持向量机是高斯径向基函数 (radial basis function) 分类器, 分类决策函数:

$$f(x) = \text{sign} \left(\sum_{i=1}^{N_s} a_i^* y_i \exp \left(-\frac{\|x - x_i\|^2}{2\sigma^2} \right) + b^* \right) \quad (102)$$

字符串核函数 (string kernel function)

核函数不仅可以定义在欧氏空间上, 还可以定义在离散数据的集合上。比如, 字符串核是定义在字符串集合上的核函数。字符串核函数在文本分类、信息检索、生物信息学等方面都有应用。

聚类

概念

闵可夫斯基距离 Minkowski distance

在聚类中, 可以将样本集合看作是向量空间中点的集合, 以该空间的距离表示样本之间的相似度。常用的距离有闵可夫斯基距离, 特别是欧氏距离。闵可夫斯基距离越大相似度越小, 距离越小相似度越大。

给定样本集合 X , X 是 m 维实数向量空间 $\mathbf{R}^m$ 中点的集合, 其中

$x_i, x_j \in X, x_i = (x_{1i}, x_{2i}, \dots, x_{mi})^T, x_j = (x_{1j}, x_{2j}, \dots, x_{mj})^T$, 样本 x_i 与样本 x_j 的闵可夫斯基距离定义为

$$d_{ij} = \left(\sum_{k=1}^m |x_{ki} - x_{kj}|^p \right)^{\frac{1}{p}} \quad (103)$$

这里 $p \geq 1$ 。当 $p = 2$ 时称为欧氏距离 (Euclidean distance), 即

$$d_{ij} = \left(\sum_{k=1}^m |x_{ki} - x_{kj}|^2 \right)^{\frac{1}{2}} \quad (104)$$

当 $p = 1$ 时称为曼哈顿距离 (Manhattan distance) , 即

$$d_{ij} = \sum_{k=1}^m |x_{ki} - x_{kj}| \quad (105)$$

当 $p = \infty$ 时称为切比雪夫距离 (Chebyshev distance) , 取各个坐标数值差的绝对值的最大值, 即

$$d_{ij} = \max_k |x_{ki} - x_{kj}| \quad (106)$$

马哈拉诺比斯距离 Mahalanobis distance

马哈拉诺比斯距离, 简称马氏距离, 也是另一种常用的相似度, 考虑各个分量 (特征) 之间的相关性并与各个分量的尺度无关。马哈拉诺比斯距离越大相似度越小, 距离越小相似度越大。

给定一个样本集合 X , $X = [x_{ij}]_{m \times n}$, 其协方差矩阵记作 S 。样本 x_i 与样本 x_j 之间的马哈拉诺比斯距离 d_{ij} 定义为

$$d_{ij} = \left[(x_i - x_j)^T S^{-1} (x_i - x_j) \right]^{\frac{1}{2}} \quad (107)$$

$$x_i = (x_{1i}, x_{2i}, \dots, x_{mi})^T, x_j = (x_{1j}, x_{2j}, \dots, x_{mj})^T \quad (108)$$

当 S 为单位矩阵时, 即样本数据的各个分量互相独立且各个分量的方差为1时, 马氏距离就是欧氏距离, 所以马氏距离是欧氏距离的推广。

相关系数 correlation coefficient

样本之间的相似度也可以用相关系数来表示。相关系数的绝对值越接近于1, 表示样本越相似; 越接近于0, 表示样本越不相似。

$$r_{ij} = \frac{\sum_{k=1}^m (x_{ki} - \bar{x}_i)(x_{kj} - \bar{x}_j)}{\left[\sum_{k=1}^m (x_{ki} - \bar{x}_i)^2 \sum_{k=1}^m (x_{kj} - \bar{x}_j)^2 \right]^{\frac{1}{2}}} \quad (109)$$

夹角余弦

样本之间的相似度也可以用夹角余弦 (cosine) 来表示。夹角余弦越接近于1, 表示样本越相似; 越接近于0, 表示样本越不相似

$$s_{ij} = \frac{\sum_{k=1}^m x_{ki} x_{kj}}{\left[\sum_{k=1}^m x_{ki}^2 \sum_{k=1}^m x_{kj}^2 \right]^{\frac{1}{2}}} \quad (110)$$

层次聚类

- 假设类别之间存在层次结构, 将样本聚到层次化的类中
- 硬聚类, 每个样本只属于一个类

聚合聚类 agglomerative/自下而上聚类 bottom-up

- 开始将每个样本各自分到一个类
- 之后将相距最近的两类合并, 建立一个新的类
- 重复此操作直到满足停止条件

分裂聚类divisive/自上而下聚类 top-down

- 开始将所有样本分到一个类
- 之后将已有类中相距最远的样本分到两个新的类
- 重复此操作直到满足停止条件

k 均值聚类

策略

样本之间的距离 $d(x_i, x_j)$ 采用欧氏距离平方 (squared Euclidean distance)

$$d(x_i, x_j) = \sum_{k=1}^m (x_{ki} - x_{kj})^2 = \|x_i - x_j\|^2$$

损失函数定义为样本与其所属类的中心之间的距离的总和

$$W(C) = \sum_{l=1}^k \sum_{C(i)=l} \|x_i - \bar{x}_l\|^2$$

$\bar{x}_l = (\bar{x}_{1l}, \bar{x}_{2l}, \dots, \bar{x}_{ml})^T$ 是第 l 个类的均值或中心, 函数 $W(C)$ 也称为能量, 表示相同类中的样本相似的程度

算法

输入: n 个样本的集合 X

输出: 样本集合的聚类 C 。

1. 初始化。令 $t = 0$, 随机选择 k 个样本点作为初始聚类中心 $m^{(0)} = (m_1^{(0)}, \dots, m_l^{(0)}, \dots, m_k^{(0)})$
 2. 对样本进行聚类。对固定的类中心 $m^{(t)} = (m_1^{(t)}, \dots, m_l^{(t)}, \dots, m_k^{(t)})$, 其中 $m_l^{(t)}$ 为类 G_l 的中心, 计算每个样本到类中心的距离, 将每个样本指派到与其最近的中心的类中, 构成聚类结果 $C^{(t)}$
 3. 计算新的类中心。对聚类结果 $C^{(t)}$, 计算当前各个类中的样本的均值, 作为新的类中心 $m^{(t+1)} = (m_1^{(t+1)}, \dots, m_l^{(t+1)}, \dots, m_k^{(t+1)})$
 4. 如果迭代收敛或符合停止条件, 输出 $C = C^{(t)}$ 。否则, 令 $t = t + 1$ 返回2。
- k 均值聚类算法的复杂度是 $O(mnk)$, 其中 m 是样本维数, n 是样本个数, k 是类别个数。

奇异值分解

奇异值分解基本定理

若 A 为一 $m \times n$ 实矩阵, $A \in \mathbf{R}^{m \times n}$, 则 A 的奇异值分解存在

$$A = U \Sigma V^T \quad (111)$$

其中 U 是 m 阶正交矩阵, V 是 n 阶正交矩阵, Σ 是 $m \times n$ 矩形对角矩阵, 其对角线元素非负, 且按降序排列。(不唯一)

紧奇异值分解 compact singular value decomposition

设有 $m \times n$ 实矩阵 A , 其秩为 $\text{rank}(A) = r, r \leq \min(m, n)$

$$A = U_r \Sigma_r V_r^T \quad (112)$$

其中 U_r 是 $m \times r$ 矩阵, V_r 是 $n \times r$ 矩阵, Σ_r 是 r 阶对角矩阵

矩阵 U_r 由完全奇异值分解中 U 的前 r 列、矩阵 V_r 由 V 的前 r 列、矩阵 Σ_r 由 Σ 的前 r 个对角线元素得到

紧奇异值分解的对角矩阵 Σ_r 的秩与原始矩阵 A 的秩相等

截断奇异值分解 truncated singular value decomposition

在矩阵的奇异值分解中，只取最大的 k 个奇异值（ $k < r$ ， r 为矩阵的秩）对应的部分，就得到矩阵的截断奇异值分解。实际应用中提到矩阵的奇异值分解时，通常指截断奇异值分解。

设 A 为 $m \times n$ 实矩阵，其秩 $\text{rank}(A) = r$ ，且 $0 < k < r$

$$A \approx U_k \Sigma_k V_k^T \quad (113)$$

其中 U_k 是 $m \times k$ 矩阵， V_k 是 $n \times k$ 矩阵， Σ_k 是 k 阶对角矩阵

矩阵 Σ_k 由完全奇异值分解中 U 的前 k 列、矩阵 V_k 由 V 的前 k 列、矩阵 Σ_k 由 Σ 的前 k 个对角线元素得到
 对角矩阵 Σ_k 的秩比原始矩阵 A 的秩低

矩阵的最优近似

奇异值分解是在平方损失(弗罗贝尼乌斯范数)意义下对矩阵的最优近似，即数据压缩。

设矩阵 $A \in \mathbf{R}^{m \times n}$ ，矩阵的秩 $\text{rank}(A) = r$ ，并设 $\mathcal{M}$ 为 $\mathbf{R}^{m \times n}$ 中所有秩不超过 k 的矩阵集合， $0 < k < r$ ，则存在一个秩为 k 的矩阵 $X \in \mathcal{M}$ ，使得

$$\|A - X\|_F = \min_{S \in \mathcal{M}} \|A - S\|_F \quad (114)$$

称矩阵 X 为矩阵 A 在弗罗贝尼乌斯范数意义下的最优近似。

本书不证明这一定理，将应用这个结果，通过矩阵 A 的奇异值分解求出近似矩阵 X 。

设矩阵 $A \in \mathbf{R}^{m \times n}$ ，矩阵的秩 $\text{rank}(A) = r$ ，有奇异值分解 $A = U \Sigma V^T$ ，并设 $\mathcal{M}$ 为 $\mathbf{R}^{m \times n}$ 中所有秩不超过 k 的矩阵的集合， $0 < k < r$ ，若秩为 k 的矩阵 $X \in \mathcal{M}$ 满足

$$\|A - X\|_F = \min_{S \in \mathcal{M}} \|A - S\|_F \quad (115)$$

$$\|A - X\|_F = (\sigma_{k+1}^2 + \sigma_{k+2}^2 + \cdots + \sigma_n^2)^{\frac{1}{2}} \quad (116)$$

特别地，若 $A' = U \Sigma' V^T$ ，其中

$$\Sigma' = \begin{bmatrix} \sigma_1 & & & & \\ & \ddots & & & \\ & & \sigma_k & & \\ & & & 0 & \\ 0 & & & & \ddots \\ & & & & & 0 \end{bmatrix} = \begin{bmatrix} \Sigma_k & 0 \\ 0 & 0 \end{bmatrix} \quad (117)$$

$$\|A - A'\|_F = (\sigma_{k+1}^2 + \sigma_{k+2}^2 + \cdots + \sigma_n^2)^{\frac{1}{2}} = \min_{S \in \mathcal{M}} \|A - S\|_F \quad (118)$$